

희소 관측 조건에서 물리경험식 유사라벨 증강과 기계학습을 이용한 영구동토 활동층 두께 예측

[DECISION: 저자, 소속, 교신 저자]

교신 저자 전자우편: [DECISION: 교신 저자 전자우편]

초록

관측이 드문 영구동토 지역에서 Stefan 식과 기계학습 (ML) 으로 활동층 두께 지도를 만드는 라벨 수별 워크플로를 제시한다. ML 모델은 대개 학습 지역 안에서, 라벨 수 하나로, 재보정 기준선 없이 시험되어 왔다. 이 연구는 다섯 지역을 100 km 완충 구역과 함께 학습에서 빼고, 라벨 0 개부터 전량까지 평균 제공된 오차 (RMSE) 를 원천 계수와 재보정 계수의 Stefan 식과 비교하였다 (내부 사전 등록). 라벨이 없을 때 Stefan 유사라벨은 섞은 유사라벨보다 오차가 낮았다 (-1.6 cm, 95% 신뢰구간 $[-2.0, -1.0]$). 라벨 10 개에서는 재보정이 원천 계수보다 4 지역 평균 오차를 낮추었고 (-2.5 cm, $[-3.0, -1.9]$, 오차가 낮아진 지역 1 곳), 잔차 ML 의 추가 차이는 확인하지 못했다. 이 결과를 본 뒤 설계한 분석에서 대상 라벨 안 교차검증으로 방법을 고르면 고정 잔차 레시피에 대한 RMSE 변화가 라벨 40 개와 160 개에서 -0.87 cm 와 -1.3 cm 였다 (2 지역, 변화는 캐나다에서 옴). 알래스카 안에서 잔차 ML 의 RMSE 는 13.9 cm, 재보정 Stefan 식은 14.4 cm 였고 (라벨 1000 개), 오차 제공 감소의 약 99%(라벨 전량) 는 기후 격자 셀 사이에 있었다. 라벨 100 개를 블록에 흩어 놓을 때 무작위 추출에 대한 RMSE 변화는 캐나다 -2.5 cm, 레나델타 $+1.7$ cm 였다. 다음으로 필요한 것은 격자 안 공변량이다. [PENDING: XE-a, XE-b, satellite inputs (stage 2); registered deadline 8 October 2026, 14:22 KST]

핵심어: 활동층 두께, 영구동토, Stefan 식, 물리 기반 기계학습, 공간 전이, 라벨 배치

서론

활동층 두께 (active-layer thickness, ALT) 는 영구동토 위 지표층이 계절에 따라 녹는 최대 깊이이며, 그 변화는 영구동토 위에 지은 기반 시설에 영향을 준다^{1,2}. ALT 는 제한된 지점에서만 측정되며, 그 가운데 상당수가 35 년에 걸친 Circumpolar Active Layer Monitoring(CALM) 자료에 있다³. 이 연구에서 평가한 다섯 지역의 ALT 측정값 (라벨) 수는 러시아 동부 30 개부터 알래스카 13,606 개까지다 (표 1). Stefan 해⁴ 는 ALT 를 계수 E 와 용해 도일 (thawing degree-days, TDD) 제공근의 곱으로 예측하며, E 는 현지 용해 깊이 측정으로 보정한다⁵. 라벨이 있는 셀에서 E 의 기하 평균은 레나델타 1.31 cm ($^{\circ}\text{C d}$)^{-1/2}, 러시아 서부 2.51, 티베트 고원 11.03 이다 (그림 1b). 새 영구동토 지역 (대상 지역) 에는 측정이 적으므로, 그곳 ALT 지도의 오차는 다른 지역 (원천 자료) 에 맞춘 모델에 달려 있다.

Stefan 식이나 Kudryavtsev 식의 출력은 기계학습 (machine learning, ML) 의 입력 특징으로 쓰였고^{6,7}, E 는 공변량으로 예측되었으며^{2,8}, 물리 규칙으로 만든 라벨로 영점 장막 (zero curtain) 검출기를 학습시킨 연구가 있다⁹. 과정 모델 사전 학습과 잔차 모델링은 다른 환경 분야에서 쓰인다¹⁰⁻¹². Gautam 등은 알래스카 CALM 68 개 지점에서 무작위 70/30 분할 한 번으로 랜덤 포레스트와 Stefan 식을 비교하였다 (시험 결정계수 0.24 와 0.54)¹³. 대규모 ALT 지도는 거리 블록으로 검증되었다^{1,14,15}. 군집된 공간 자료에서는 무작위 교차검증이 지도 정확도를 과대평가할 수 있고¹⁶⁻¹⁸, 편향 없는 지도 정확도를 얻으려면 공간 교차검증보다 설계 기반 추론을 쓰는 확률 표본이 필요하다는 주장이 있다¹⁹. 위의 ALT 평가는 모두 라벨 조건 하나를 쓴다. 이웃 분야에서는 학습에서 뺀 지역이나 현지 관측이 적은 조건에서 모델을 평가하였고, 일부는 보정된 과정 모델과 비교하였다. 그 대상은 호수 수온^{10,11,20}, 계측소 없는 유역^{21,22}, 지하 온도²³, 공간 위험 예측²⁴ 이다. 우리가 아는 범위에서, 영구동토 ALT 나 연평균 지중온도 연구 가운데 학습 자료에서 뺀 지역의 오차를 대상 라벨 수의 함수로, 같은 라벨로 재보정한 Stefan 식과 비교해 보고한 연구는 없다.

새 지역에는 대상 라벨이 쌓이는 동안 Stefan 식과 ML 을 결합하는 규칙과 라벨을 더하는 절차가 필요하다. 이 연구는 세 질문을 다룬다. (1) 대상 라벨이 없을 때 물리 정보는 ML 에 무엇을 더하며, 그 이득은 어디에서 오는가? (2) 대상 라벨이 10 개에서 수천 개로 늘 때 ML 은 같은 라벨로 재보정한 Stefan 식에 얼마나 더하며, 그 이득은 어느 공간 규모에서 생기는가? (3) 라벨이 쌓일 때 방법은 어떻게 고르고, 새 라벨은 어떤 절차로 배치해야 하는가?

각 대상 지역은 100 km 완충 구역과 함께 원천 자료에서 빼고, 그 지역 0.5° 블록의 절반에서 라벨을 뽑아 나머지 절반에서 오차를 채점하였다. 라벨 수는 0, 3, 10, 40, 160, 320, 1000 개와 쓸 수 있는 전량이다 (그림 1c,d). 라벨이 많은 지역 안에서는 앞선 결과를 본 뒤 설계한 블록 홀드아웃 시험으로 재보정 모델에 대한 ML 의 이득을 측정하였다. 대비는 블록 부트스트랩 95% 신뢰구간 (confidence interval, CI) 과 ± 0.5 cm 동등 한계로 판정하였고, 전이 분석은 내부 사전 등록하였다. 대상 라벨이 없을 때 Stefan 유사라벨 (Stefan 예측을 학습 라벨로 쓴 것) 은 섞은 유사라벨보다 주 4 지역 (레나델타, 캐나다, 러시아 서부, 러시아 동부) 의 평균 제곱근 오차 (root-mean-square error, RMSE) 평균을 낮추었다. 라벨 10 개로 Stefan 계수를 재보정하면 원천 계수보다 이 값이 낮아졌다 (오차가 낮아진 지역은 4 곳 가운데 1 곳). 알래스카 안에서 라벨 전량을 쓸 때 재보정 모델에 대한 ML 이득의 거의 전부는 기후 격자 셀 사이의 편향 보정에서 왔다. 이 연구의 기여는 평가 설계, 음성 결과를 포함한 그 결과, 그리고 그 결과로 만든 라벨 수별 워크플로다.

결과

평가 설계와 검증 사다리

앞에서 설명한 홀드아웃 절차 (그림 1c,d; 표 1) 에서 모든 방법을 같은 대상 라벨을 쓰는 두 Stefan 기준선과 비교하였고, 이는 호수 수문 연구와 같은 방식이다^{10,11}. 하나는 원천 셀에서 계수 E_0 를 추정한 원천 계수 Stefan 식 (표 1) 이고, 다른 하나는 대상 라벨로 계수를 다시 맞추되 E_0 쪽으로 수축한 재보정 Stefan 식 ($\kappa = 10$) 이다²⁵. 4 지역 평균은 레나델타, 캐나다, 러시아 서부, 러시아 동부에 같은 가중을 주며, 학습에서 뺀 참조 대상인 알래스카는 넣지 않는다. 구간은 블록 등가중이라고 적지 않으면 셀 가중이다.

다섯 지역을 같은 가중으로 평균하면 직접 ML 의 RMSE 는 무작위 셀 분할의 22.9 cm 에서 지역 홀드아웃의 33.3 cm 로 커졌다 (차이 10.3 cm, 95% CI [7.3, 12.8], 블록 등가중 6.1 cm [4.7, 7.6]). 같은 조건에서 학습 셀에 최소제곱으로 계수를 맞춘 Stefan 식은 26.8–27.0 cm 에 머물렀다 (그림 1e). 10.3 cm 증가는 확인적 결과가 아니라 효과 크기로 보고하며, 등록 대비인 500 km 완충 군집 홀드아웃과 무작위 셀의 차이는 8.2 cm 였다 (95% CI [5.6, 10.4]; 보충 표 S2). 무작위 셀 분할에서 k 겹 최근접 거리 정합 (k-fold nearest-neighbour distance matching, kNNDM) 분할²⁶ 로 가면 직접 ML 의 RMSE 는 알래스카, 레나델타, 캐나다에서 5.76 cm, 8.17 cm, 14.20 cm 늘었고, 학습 셀에 맞춘 Stefan 식의 RMSE 는 0.29 cm, 0.51 cm, 4.28 cm 늘었다 (셀 가중; 서술, 앞선 결과를 본 뒤 설계; 그림 1e; 보충 표 S13). 확률 표본에서는 무작위 검증이 지도 정확도의 타당한 추정이라는 견해가 있으나¹⁹, 이 연구의 라벨은 군집된 비확률 표본이므로 아래의 오차는 학습에서 뺀 블록에서의 예측 오차다.

대상 라벨 없는 전이

대상 라벨이 없을 때 Stefan 식의 유사라벨은 섞은 유사라벨보다 RMSE 를 1.6 cm 낮추었다 (95% CI [1.0, 2.0], 블록 등가중 [0.6, 1.5], 4 지역, Holm 보정 $P = 0.001$). 사후 집계에서 원천 계수 Stefan 식보다 오차가 2 cm 넘게 커진 대상은 30 개 가운데 물리 유사라벨 증강에서 2 개, 직접 ML 에서 18 개였다 (그림 3b; 그림 6a,b). 두 상수 위약에 대한 감소는 1.7 cm 와 3.6 cm 였고, $\sqrt{\text{TDD}}$ 에 선형인 위약에 대해서는 0.48 cm 였다 (등록 판정: 혼재). 2 cm 문턱은 전이 결과를 본 뒤 정하였고, 30 개 대상에는 하위 지역 또는 라벨 확충판 23 개가 들어 있으며, 구간에 근거한 집계도 같은 순서를 보였다 (사후; 보충 표 S5).

주 구간과 공통 대표집 구간의 판정이 일치한 학습기 5 종에서 직접 ML 은 원천 계수 Stefan 식보다 4 지역 평균 오차가 높았다 (그림 6c). 주 학습기인 CatBoost 에서 차이는 2.2 cm (95% CI [1.1, 3.4], Holm 보정 $P = 0.023$) 였고, CatBoost 의 다른 설정 2 종과 TabPFN v2, TabICL v2 에서는 0.85–1.9 cm 였다. 이 다섯 판정은 분할 독립 가정에 의존하며, TabPFN v2 의 판정은 보정 전에만 유의하였다 (Holm 보정 $P = 0.117$). 원천 계

수 앵커에 낮은 가중 ($\lambda = 0.25$) 을 준 잔차 모델은 학습기 3 종에서 그 Stefan 식과 ± 0.5 cm 안에서 동등하였다 (분할 독립 가정에 의존).

알래스카를 학습에서 뺐을 때 물리 유사라벨은 원천 계수 모델보다 오차가 1.8 cm 높았다 (95% CI [0.4, 2.6]). 원천 계수가 지역 값과 멀리 떨어진 티베트 고원 (그림 1b) 에서는 직접 ML 의 오차가 60.0 cm 낮았다 (비맹검 이고 교차 환경인 비교에서 예상된 결과). 라벨 10 개에서 직접 TabICL v2 는 4 지역 평균 오차가 2.9 cm 낮았으나 (95% CI [1.1, 3.6]; 분할 독립 가정 의존), 알래스카를 포함한 3 지역 평균에서는 6.0 cm 높았다.

같은 블록에서 제품 학습 지점으로부터 5 km 또는 25 km 안의 블록을 가린 뒤 (등록 이탈; 앞선 결과를 본 뒤 설계), 라벨 없는 기존 CCI v5 지도는 원천 계수 Stefan 식보다 오차가 23.79 cm 높았고 (Holm 보정 $P = 0.0006$; 레나델타, 캐나다, 러시아 동부에서 높음), 잔차 ML 은 같은 라벨 10 개와 전량으로 재보정한 CCI v5 보다 오차가 8.37 cm 와 7.51 cm 낮았다 (CCI v5 대비는 비맹검 부분 포함). 대상 지역 안의 CALM 지점도 일부 학습에 쓴 Wei v2 지도 (제품 결측 대체 47.4%) 에서는 차이를 확인하지 못했다 (ALT 정의가 서로 다름; 보충 표 S13).

라벨 3--10 개의 계수 재보정

대상 라벨 10 개로 Stefan 계수를 재보정하면 원천 계수보다 4 지역 평균 RMSE 가 2.5 cm 낮아졌다 (95% CI [1.9, 3.0], 블록 등가중 [1.9, 3.3], Holm 보정 $P = 0.001$). 오차가 낮아진 지역은 4 곳 가운데 1 곳 (러시아 서부, 12.0 cm) 이었고, 캐나다에서는 오차가 높아졌으며 (2.3 cm, 95% CI [0.7, 2.9]), 레나델타와 러시아 동부에서는 차이를 확인하지 못했다 (그림 2; 그림 3a). [MISSING: 중앙값과 러시아 서부 제외 값, build_numbers.py 에서 lgw_bundle.csv 지역 행으로 생성] 재보정 앵커에 잔차 ML 을 더하면 RMSE 가 추가로 -0.18 cm 달라졌다 (95% CI $[-0.53, -0.01]$, Holm 보정 $P = 0.136$). 이 차이는 보정 전에만 유의하고, 크기가 0.5 cm 미만이며, 분할 독립 가정에 의존한다.

라벨 전량에서 라벨을 쓰는 보정 (다음 절의 선정 규칙) 의 오차 감소는 라벨 10 개로 잔 원천 계수 편향과 순위 상관을 보였다 (Spearman $\rho = 0.38$, 95% CI [0.17, 0.55], 28 대상, 단측 $P = 0.0002$; 라벨 격자 결과를 본 뒤 설계). 편향의 부호는 감소와 관계가 없었다 ($\rho = -0.01$; 그림 4a,b; 보충 표 S8). 사후 분석에서 이 편향의 크기와의 관계는 재보정 이득, 선정 규칙이 더한 몫, 재보정을 넘어선 ML 몫의 어느 것에서도 확인하지 못했다 (마지막 몫은 대상 고정 보조 구간에서만 양이었고, 약한 쪽 범주로 적었다)(그림 4d; 보충 표 S13).

라벨 10 개 이하에서 잔차 구조는 Stefan 출력을 입력으로 받는 ML(물리 입력 ML) 보다 4 지역 평균 오차가 낮았다. 차이는 라벨 0 개에서 2.7 cm, 라벨 10 개에서 3.7 cm(95% CI [2.8, 5.2], Holm 보정 $P = 0.001$) 였다 (그림 3c). [MISSING: 중앙값과 러시아 서부 제외 값, build_numbers.py 에서 lgw_bundle.csv 지역 행으로 생성] 재보정 Stefan 값을 물리 입력으로 주어도 잔차 구조의 오차는 2.5 cm 낮았으나 캐나다에서는 3.1 cm 높았고, 이 지역 판정은 분할 독립 가정에 의존한다 (보충 표 S6).

잔차 ML 에 물리 유사라벨을 더한 결과는 라벨 10 개에서 ± 0.5 cm 안의 동등이었고, 라벨 40 개의 레나델타와 캐나다에서는 오차가 0.34 cm 높았다 (0.5 cm 미만; 보충 표 S6). 물리식과 제품을 라벨 가중으로 적층한 결과는 라벨 10 개에서 재보정이나 잔차 ML 과의 차이를 확인하지 못했고, 이 라벨 수에서 적층은 추출의 36% 에서 재보정으로 대체되었다 (앞선 결과를 본 뒤 설계, 비맹검 부분 포함; 보충 표 S13).

라벨 수십--수백 개의 방법 선정

대상 라벨 안에서 5 겹 블록 교차검증으로 방법을 고르면 고정 잔차 레시피 ($\lambda = 0.25$) 보다 라벨 160 개에서 RMSE 가 1.3 cm 낮아졌고 (95% CI [0.7, 1.7], 블록 등가중 [0.8, 1.8], 레나델타와 캐나다, 공통 재표집에서도 같음), 라벨 40 개와 160 개에서 비열등이었다 (한계 0.5 cm). 두 결과 모두 캐나다에서 나왔으며, 이 규칙은 라벨 격자 결과를 본 뒤 설계하였다 (그림 4c; 그림 7d). 라벨 40 개에서의 감소 0.87 cm(95% CI [0.27, 1.20]) 는 분할 독립 가정에 의존한다. 레나델타에서는 차이를 확인하지 못했다 (그림 4c). 주 4 지역의 라벨 10 개에서는 비열등을 확인하지 못했고, 레나델타에서 규칙의 오차가 0.70 cm 높았다. 라벨 전량에서의 비열등은 분할 독립 가정에 의존한다. 규칙은 재보정 Stefan 식보다 오차가 낮은 대상의 수를 늘리지 않았다 (보충 표 S8).

캐나다에서는 원천 계수 Stefan 식과의 차이를 확인하지 못했다 (보충 표 S8). 알래스카를 학습에서 뺐을 때

규칙은 라벨 10, 40, 160 개에서 원천 계수 모델보다 오차가 높았다 (서술적 곡선 대비; 보충 표 S8).

라벨 40 개와 160 개에서 레나델타와 캐나다의 잔차 ML 은 물리 입력 ML 보다 오차가 1.9-2.4 cm 높았다 (2.4 cm 대비는 분할 독립 가정에 의존)(그림 3c). 이 차이는 캐나다에서 생겼고, 알래스카를 학습에서 뺐을 때는 잔차 ML 의 오차가 낮았다. 이 라벨 수에서 잔차 ML 과 더 강한 재보정 기준선 (토양 보정 Stefan 식을 $\kappa = 10$ 으로 재보정한 것) 사이의 차이는 확인하지 못했다.

원천 지역 하나 제외 교차검증으로 신경망을 조정한 결과는 학습기마다 달랐고, 학습기 전반에 대한 문장을 쓸 등록 조건을 채운 학습기는 없었으며, 이 조정은 대상 라벨 안의 선택과 비교하지 않았다 (보충 표 S8). 같은 지역을 다시 무작위로 나눈 분할에서 (재사용 지역의 재검정, 앞선 결과를 본 뒤 설계, 비맹검 부분 포함) 순차 워크플로는 무작위 배치와 고정 잔차 레시피보다 라벨 160 개에서 오차가 0.93 cm 낮았고 (레나델타와 캐나다; 캐나다 -2.41 cm, 레나델타 +0.54 cm 미결정), 라벨 40 개에서는 차이를 확인하지 못했다 (최소 검출 효과 약 0.5 cm; 레나델타 +0.21 cm). 워크플로의 배치 단계가 무작위 추출로 바뀌었으므로 이 대비는 같은 라벨에서 방법 규칙과 고정 레시피를 비교한 것이다. 같은 분할에서 워크플로는 라벨 10 개, 40 개, 160 개에서 재보정 Stefan 식에 비열등이었고 (라벨 10 개는 5 지역 평균, 40 개와 160 개는 레나델타와 캐나다 평균) 라벨 40 개와 160 개에서는 오차가 1.35 cm 와 1.51 cm 낮았으나, 이는 풀 평균에 대한 것이다. 러시아 동부의 라벨 10 개 (+1.34 cm), 선택 계열인 알래스카의 라벨 40 개와 160 개 (+1.51 cm 와 +2.34 cm), 레나델타의 라벨 160 개 (+0.53 cm) 에서는 0.5 cm 넘게 나뉘었다 (그림 7e; 보충 표 S13). 지역 안의 보조 팔에서 규칙은 라벨 200 개에서 잔차 ML 과 동등하였고, 라벨 500 개와 1000 개에서는 차이를 확인하지 못했다. 적층은 라벨 40 개와 160 개에서도 차이를 확인하지 못했다 (레나델타와 캐나다; 앞선 결과를 본 뒤 설계, 비맹검 부분 포함; 보충 표 S13).

라벨이 많은 지역 안의 이득

알래스카 안에서 재보정 Stefan 앵커 위의 잔차 ML 은 같은 라벨로 재보정한 Stefan 식보다 라벨 1000 개에서 RMSE 를 0.54 cm 낮추었다 (95% CI [0.32, 0.69], 블록 등가중 [0.40, 0.80], 14.4 cm 에서 13.9 cm, 공통 재표집에서도 같음). 라벨 전량에서 오차 제공 감소의 약 99% 는 ERA5-Land 기후 격자 셀 사이에 있었다²⁷(그림 7a,c). 이 시험은 앞선 결과를 본 뒤 설계하고 실행 전에 등록하였다 (방법).

라벨 500 개와 전량의 감소 (0.39 cm 와 0.52 cm) 는 분할 독립 가정에 의존하며, 원천 계수 Stefan 식과의 차이는 라벨 1000 개와 전량에서 확인하지 못했다 (보충 표 S7). 레나델타와 캐나다에서는 같은 대비의 차이를 시험한 어느 라벨 수에서도 확인하지 못했다 (보충 표 S7).

오차를 기후 격자 셀 사이와 안으로 나누면 (대용: 0.5° 블록과 ERA5-Land TDD; 방법; 앞선 결과를 본 뒤 설계, 실행 전 등록), 라벨 전량의 잔차 ML 은 재보정 모델보다 격자 사이 RMSE 를 1.0 cm 낮추었고 (95% CI [0.6, 1.3]), 격자 안 RMSE 는 ± 0.5 cm 안에서 동등하였다 (-0.01 cm, 95% CI [-0.03, 0.04]). 토양 온도 격자 정의에서도 같았다 (그림 7c). 격자 안 변동은 재보정 Stefan 식 오차 제공의 72% 를 차지하였고, 잔차 ML 은 그 가운데 알래스카에서 1% 미만, 세 지역의 어느 설정에서도 8% 미만을 설명하였다. 이득을 격자 규모의 편향 보정으로 보는 것은 사후 서술이다 (채점 블록별 오차 변화는 그림 7b).

등록된 격자 안 가설에서 잔차 ML 의 격자 안 예측은 라벨 전량에서 층화 지역 평균의 오차를 키웠다 (+0.09 cm, 95% CI [0.02, 0.40]). 토양 온도 정의와 캐나다에서도 같았고, 모두 통계적으로 구별되나 크기는 0.5 cm 미만이었다 (보충 표 S10). 전이에서는 격자 안 예측이 관측 변동과 맞는다는 근거가 없었다. 더 따뜻한 블록으로의 외삽에 대한 등록 시험은 판정할 수 없었다 (캐나다의 채점 블록 3 개; 보충 표 S10). 다음 세 분석은 앞선 결과를 본 뒤 설계하였다 (보충 표 S13). 같은 시기의 따뜻한 블록을 쓴 공간 대용 (외삽 폭은 $\sqrt{\text{TDD}}$ 에서 $0.97 (\text{°C d})^{1/2}$) 은 실제 외삽 시험이 아니며, 여기서 잔차 ML 은 재보정 Stefan 식보다 라벨 100 개와 전량에서 오차가 2.44 cm 와 2.41 cm 낮았고 (비열등), 직접 ML 과 두 모델 사이의 외삽 손실 차이는 확인하지 못했다. 지형, 수체, 수목 피복 입력 10 개를 더해도 잔차 ML 의 격자 안 오차는 모든 라벨 수에서 ± 0.5 cm 안에서 동등하였다 (보조 대비, 비맹검 부분 포함). [PENDING: XE-a, XE-b, satellite inputs (stage 2); registered deadline 8 October 2026, 14:22 KST] 적층 잔차는 라벨 500 개와 1000 개에서 재보정 앵커 잔차보다 오차가 0.55 cm 와 0.498 cm 낮았고 (3 지역 가운데 2 지역; 뒤의 것은 0.5 cm 미만), 라벨 200 개와 전량에서는 차이를 확인하지 못했으며, 알래스카에서 적층은 재보정 Stefan 식에 비열등이었다 (비맹검 부분 포함).

새 라벨의 위치

캐나다에서 라벨을 0.5° 블록이나 공변량 공간에 흩어 놓으면 무작위 셀 추출보다 RMSE 가 전이 라벨 40 개에서 2.4 cm(95% CI [0.5, 3.4], 블록 등가중 [0.8, 2.5], 공변량 최대 최소 거리 추출), 지역 안 라벨 50–100 개에서 2.5–3.2 cm 낮아졌다. 레나델타에서는 블록 층화가 라벨 100 개에서 RMSE 를 1.7 cm 높였다 (95% CI [0.9, 2.4], 블록 등가중 [0.1, 1.6])(그림 5). 모든 대비는 같은 분할에서 잔차 ML($\lambda = 0.25$) 을 썼고, 앞선 결과를 본 뒤 설계하고 실행 전에 등록하였다.

전이 라벨 10 개에서 어느 전략도 다섯 지역 가운데 오차가 높아진 곳이 없었으나, 이는 비열등 결과가 아니다. 한 가중에서는 레나델타의 블록 층화 (+1.9 cm) 와 러시아 동부의 공변량 분산 (+0.36 cm) 이 오차 증가를 보였기 때문이다 (그림 5f; 보충 표 S9).

라벨 100 개에서 알래스카 최선 전략인 공변량 군집 층화는 레나델타에서 RMSE 를 높였다 (+0.33 cm, 0.5 cm 미만). 내부 사전 등록한 블록 층화 대 무작위 셀 추출의 지역 평균 대비는 라벨 10 개와 40 개에서 미결정이었다 (2 단 재표집; 비맹검 부분 포함; 전이 대비와 같은 라벨 집합; 보충 표 S9). 평가 전에 고정한 배치 절차 (방법) 도 순차 워크플로 안에서 시험하였다 (그림 7e). 같은 지역을 다시 무작위로 나눈 분할에서 이 절차는 셀 무작위 추출로 바뀌었으므로 배치 단계는 기여한 것이 없고, 그 효과는 시험하지 않았다 (방법). 이 절차는 알래스카 계열에서 골랐고, 평가 지역의 셀은 배치와 방법 규칙의 설계에 쓰였으며, 평가 분할은 같은 셀을 새로 나눈 것이다. 블록 배분과 공변량 덮임을 합친 배치는 라벨 10 개와 40 개에서 무작위 배치와의 차이를 확인하지 못했고, 그 네 설정은 블록 또는 공변량 분산 배치와의 비교 16 개 가운데 8 개에서 비열등 (2 개는 보정 전에만 유의), 2 개에서 오차가 높았으며 (0.5 cm 미만), 레나델타를 겨냥한 사후 설계인 설계 가중 계수는 알래스카와 캐나다에서 오차를 키웠다 (탐색; 앞선 결과를 본 뒤 설계, 비맹검 부분 포함; 보충 표 S13). 후보는 이미 측정한 셀이므로 현장 후보로 이득이 옮겨진다는 보장이 없다.

독립 지역

얕은 활동층을 가진 약관 확인 새 지역인 러시아 중부 (라벨 57 개) 에서 대상 라벨 없는 직접 ML 은 원천 계수 Stefan 식보다 RMSE 를 2.7 cm 높였다 (95% CI [2.1, 4.1], 블록 등가중 [3.2, 6.6], 공통 재표집에서도 같음). 이 지역을 포함한 얕은 레짐 5 지역 풀에서 라벨 전량의 잔차 ML 은 같은 모델보다 RMSE 를 3.2 cm 낮추었다 (95% CI [2.2, 4.2], 블록 등가중 [1.5, 3.7])(표 1). [MISSING: 5 지역 풀 대비 (라벨 전량 잔차 ML – 원천 계수 Stefan, 라벨 10 개 잔차 ML – 재보정 Stefan) 의 지역 중앙값, 오차 감소·증가 지역 수, 러시아 서부 제외 값. 새 지역 판정표 (약관 확인본 판) 의 지역 행에서 수치 생성 스크립트로 만든다] 이 결과에는 교차 환경 표지가 붙는다. 풀이 두 계산 플랫폼에서 맞춘 지역을 합치기 때문이다 (방법). 4 지역 풀과 5 지역 풀의 어느 지역에서도 라벨 0–40 개의 직접 ML 은 원천 계수 모델보다 오차가 낮지 않았다. 라벨 10 개에서 잔차 ML 과 재보정 Stefan 식은 5 지역 풀에서 ± 0.5 cm 안에서 동등하였으므로 (−0.13 cm), 이 라벨 수의 4 지역 결과는 이 풀에서 유지되지 않았다. 러시아 중부만 보면 라벨 전량의 잔차 ML 은 차이를 확인하지 못했다. 두 가중의 판정이 엇갈렸기 때문이다 (보충 표 S11).

깊은 활동층을 가진 티베트 고원은 따로 보고하며 독립 지역의 근거로 쓰지 않는다 (채점 셀이 원천 고도 범위 밖에 있음; 비맹검 대비). 그곳에서 라벨 10 개의 잔차 ML 은 수축 재보정보다 RMSE 가 20.9 cm 낮았으나, 같은 라벨에 최소제곱으로 맞춘 Stefan 식보다 낮지 않았다 (+19.1 cm; 보충 표 S11). 자료 약관이 일부 확인되지 않은 북대서양 지역은 보충 표 S11 에만 있다. [PENDING: XF, new public regions; registered data deadline 11 October 2026, 14:22 KST; no eligible new macro region found so far] [PENDING: XC-F3, external-family test of the workflow; not tested so far, because placement reduced to random sampling makes its ten-label contrast identical, and no eligible new region; registered sentence after the XF data deadline, 11 October 2026, 14:22 KST] 티베트 고원에서 지온 유도 보조 행은 라벨 3 개와 10 개로 재보정한 모델의 전이 오차를 8.14–83.17 cm 줄였다 (앞선 결과를 본 뒤 설계, 비맹검 부분 포함). 이 라벨은 직접 측정과 정의가 달라 이 결과를 일반화하지 않으며, 원천 쪽 설계는 시험하지 않았다 (약관 근거 미기록; 보충 표 S13).

예측 구간

대상 라벨이 없을 때 지역을 묶음으로 보정한 계층 conformal 구간²⁸은 학습에서 뺀 관측의 평균 0.86을 포함하였다 (95% CI [0.80, 0.92], 명목 0.90, 4 지역). 보정 지역이 4 개이므로 유한 표본 보장은 없다 (앞선 규약으로 내부 사전 등록; 보충 표 S12). 알래스카에서 conformalized quantile regression으로 보정한 분위 구간²⁹은 학습에서 뺀 네 지역에서 0.32–0.73을 포함하였다 (보충 표 S12). 계층 구간의 폭을 정하는 다섯 방식에서 포함률은 0.86–0.95, 평균 폭은 81.3–132.4 cm였다 (그림 6d). 구간 점수³⁰에서는 셀별 흐름 척도와 지역 안에서 폭을 섞은 위약 사이, 그리고 어느 척도와 상수 폭 사이에서도 차이를 확인하지 못했다. 라벨 10 개에서 계층 예측 분포와 보정된 상수 폭 구간 사이의 구간 점수 차이는 확인하지 못했다 (+9.5 cm, Holm 보정 $P=0.277$). 라벨 40 개와 160 개에서 잔차 ML 구간은 레나델타, 캐나다, 알래스카에서 0.84–0.90을 포함하였다 (그림 6e).

고찰

결과는 새 영구동토 지역을 위한 라벨 수별 워크플로를 정한다 (그림 7d). 대상 라벨이 없을 때 기준은 원천 계수 (또는 연도 정합) Stefan 식이며, ML은 물리 유사라벨이나 저가중 잔차로만 들어간다. 라벨 3–10 개에서는 계수를 재보정하고 (오차가 낮아진 지역은 4 곳 가운데 1 곳) 저가중 잔차를 더한다. 라벨 40 개부터는 대상 라벨 안 교차검증으로 방법을 고르며, 그 이득은 캐나다에서 생겼다. 이 폴에서 라벨 3–160 개에 원하는 방법의 점 추정 오차는 원천 계수 모델보다 높았다 [DECISION: Fig 7d 경로의 y 기준과 폴, 그림 명세 D-13]. 라벨이 수천 개인 지역 안에서는 잔차 ML이 뒤따르며, 그 이득은 기후 격자 셀 사이에 있다 (그림 7a–c). 배치는 사전 지정한 절차로만 들어간다. 라벨을 흘려 놓는 것이 캐나다에서는 오차를 낮추었고 레나델타에서는 낮추지 못했기 때문이다 (그림 5).

이득은 Stefan 계수 E 의 수준 보정과 기후 격자 규모의 편향 보정에서 왔다. E 는 토양 열전도도, n-인자, 토양 수분과 얼음의 잠열을 한데 묶은 계수이며³¹, 그래서 지역 Stefan 지도는 토지 피복별 계수를 썼다^{5,32}. 이 연구에서 E 는 용해 지수의 편향과 라벨 정의도 흡수한다 (보충 주석 1). 라벨 전량에서 원천 계수에 대한 잔차 ML의 4 지역 평균 감소 가운데 85%는 재보정 몫이었고, 이 평균은 러시아 서부가 지배하였다 (14.0 cm 가운데 재보정 13.5 cm; 사후 산술). 캐나다의 지역 계수는 주 지역 가운데 원천 값에 가장 가까웠으나 라벨 블록과 채점 블록 사이에서 달랐다. 라벨 10 개 재보정은 그곳의 오차를 키웠고, 선정 규칙은 대개 잔차 가중 1.0을 골랐으며, 우리는 이를 라벨 위치의 이질성을 보정한 것으로 해석한다.

라벨 0 개 결과는 랜덤 포레스트가 Stefan 식보다 일반화가 나뉘던 알래스카 무작위 분할 비교와 방향이 같다¹³. 앞선 알래스카 지역 내 분석 [DECISION: 대회 보고서 인용 여부]은 56 개 설정 가운데 최선인 물리 잔차에서 이 연구의 더 엄격한 시험보다 큰 Stefan 식 대비 이득을 보고하였다 (보충 주석 2). kNNNDM²⁶은 이 군집 표본 (알래스카 13,606 행이 343 개 위치에 있음)에서 지도와 라벨 사이의 거리를 흉내 낼 뿐이다.

다른 설명의 가능성은 낮다. Stefan 유사라벨은 섞은 유사라벨과 상수 유사라벨보다 오차가 낮았고 (그림 3b), 선형 용해 지수 위약과의 차이는 0.5 cm 미만이었다. 따라서 이득은 제공된 형태보다 셀 수준의 용해 지수 정보를 반영한다. 재보정 이득은 러시아 서부와 동부의 단년 라벨에서도 유지되었고, 캐나다에서는 점 라벨일 때 1 km 위치 평균일 때보다 0.86 cm 작았다 (중앙값, 라벨 10 개). 이 결과가 워크플로의 라벨 단위를 정한다. 물리식과 CatBoost 결과는 계산 환경 사이에서 일치하였고 (최대 차이 3.6×10^{-14} cm) 신경망은 최대 5.6 cm 달랐으므로, 워크플로는 결정적인 이 방법들만 쓴다.

워크플로는 측정 지점의 순위를 매기지 않고 기후 격자 셀 안의 변동을 예측하지 않는다. 1 km 지도 (보충 그림 S10–S14)는 표시 해상도이고, 그 정보 해상도는 기후 입력 (약 10 km)과 토양 입력 (약 5 km)에 묶인다. 결론은 지표 투과 레이더 (ground-penetrating radar) 라벨을 포함한 원천 자료에 한정되며, 훈련 범위보다 따듯한 기후는 평가할 수 없었다. 원천 자료의 알래스카 비중 (원천 셀의 78–94%)은 라벨이 적을 때 가장 크게 작용한다. 원천 계수가 재보정 계수에서 라벨 10 개의 가중을 갖기 때문이다. 확인적 근거는 재사용한 주 지역 4 곳과 얇은 레짐의 새 지역 1 곳에서 온다. 비맹검인 티베트 고원은 유일한 깊은 레짐 지역이라 따로 보고하므로, 결과를 이 지역들 너머로 일반화하지 않는다. 값은 시험 설계에 따라 달라지므로 (그림 1e), 무작위 분할 연구와는 직접 비교할 수 없다. 격자 셀 안의 토양 수분, 유기층 두께, 적설 기간, 미지형은 공변량에 거의 없으므로, 알래스카에서 설명한 격자 안 비율 (1% 미만)은 물리적 한계가 아니라 이 입력의 한계를 나타낸다. 방법 선정, 배치,

라벨이 많은 지역의 시험, 편향 상관, 이득 분해는 앞선 결과를 본 뒤 설계하였으므로 내부 사전 등록한 대비보다 약한 근거다.

각 단계에는 조건이 있다. 라벨은 1 km 위치 평균이고, 재보정은 라벨 10 개 대비에 근거하며, 대상 라벨 안 교차검증 선정은 라벨이 덮는 0.5° 블록 수에 좌우되고 라벨 10 개의 레나델타에서 고정 레시피보다 오차를 키웠다. 워크플로 전체는 같은 지역을 다시 무작위로 나눈 분할에서만 시험하였고, 그 배치 단계는 무작위 추출로 바뀌었으며, 재보정 Stefan 식에 대한 비열등은 풀 평균에서만 성립하고 러시아 동부, 알래스카, 레나델타에서는 성립하지 않았다. 다음에 필요한 자료는 개발에 쓰지 않은 독립 지역 [PENDING: XF, new public regions; registered data deadline 11 October 2026, 14:22 KST; no eligible new macro region found so far], 같은 블록에서 채점한 기존 ALT 지도^{15,33}(이 연구에서는 등록 이탈로 비교; 보충 표 S13), 그리고 무엇보다 기후 격자 셀 안에서 변하는 공변량이다. 알래스카에서 재보정 Stefan 식 오차 제곱의 72% 가 격자 셀 안에 있었다. [PENDING: XE-a, XE-b, satellite inputs (stage 2); registered deadline 8 October 2026, 14:22 KST]

방법

연구 지역과 라벨

주 지역의 활동층 두께 (ALT) 라벨은 GTN-P/CALM 기록³, 레나강 삼각주 지역의 ALLena 자료³⁴, 알래스카와 캐나다의 ABoVE 자료 2 판³⁵ 에서 가져왔다. 한 위치의 반복 측정이 독립 라벨로 들어가지 않도록 기록을 셀로 모았다. 셀은 소수 넷째 자리로 반올림한 좌표 (ABoVE 와 ALLena) 이거나 CALM 지점 하나이며, 셀의 라벨은 그 관측의 평균이다 (보충 방법 1). 셀 표는 17,572 행이고, 그 가운데 17,467 행이 기계식 탐침이나 지표 투과 레이더 (ground-penetrating radar, GPR) 로 켜 직접 라벨이다. 메타자료에 지중 온도나 융해 관 (thaw tube) 이 적힌 CALM 셀 68 개는 라벨로 쓰지 않는다. 지온에서 유도한 셀 20 개 (알래스카 15, 캐나다 4, 티베트 고원 1) 는 표를 고정된 뒤에 발견되어 표지를 단 채 직접 라벨 범주에 남아 있다. 라벨 연도는 1990–2024 년이므로, 예측은 정적이며 2015–2020 년 공변량 기후값을 기준으로 한다.

광역 지역은 분석 전에 지리적으로 정하였으며, 알래스카, 레나델타, 캐나다, 러시아 서부, 러시아 동부, 러시아 중부, 그린란드다 [DECISION: 지역 이름 표기] [DECISION: 러시아 중부의 영문 표기]. 알래스카와 주 지역 4 곳의 라벨 행 수는 러시아 동부 30 개부터 알래스카 13,606 개까지다 (표 1). 하위 지역 10 곳 (보충 표 S1) 은 라벨 없이 0.5° 블록 중심을 k -평균으로 군집해 정하였고, 본 실행 전에 고정하였다.

라벨 수 n 은 행의 수이며, 행의 뜻은 지역마다 다르다. 행은 러시아 서부와 동부에서 CALM 지점의 다년 평균이고, 레나델타에서는 대개 한 번 방문한 관측이며, 알래스카와 캐나다에서는 대부분 점 관측이고, 추가 지역에서는 약 1 km 범위의 평균이다. 1 km 위치당 행 수는 알래스카 39.7, 레나델타 15.1, 캐나다 8.7 이며, 알래스카 13,606 행은 74 개 블록의 343 개 위치에 있다.

추가 지역은 어떤 적합보다 먼저 정한 규칙에 따라 공개 자료에서 모았다 (보충 방법 2). 라벨은 1990 년 이후의 계절 말 융해 깊이를 직접 켜 값이어야 하고, 기존 라벨 지역에서 100 km 이상 떨어져야 하며, 약 1 km 셀로 모았다. 유효 분할의 채점 블록 합집합이 8 개 이상인 지역만 신뢰구간 산출에 적격으로 보았다. 재배포 약관이 확인되지 않은 자료는 주 판정을 정하는 약관 확인판에서 뺐다 (보충 표 S17). 이 판에서는 러시아 중부 (57 행, 13 블록, 얇은 레짐) 와 티베트 고원 (132 행, 34 블록, 깊은 레짐) 이 적격이다. 북대서양 묶음 (41 행) 은 전체 판에서만 적격이며 보충 정보에 보고한다.

공변량

모든 학습 방법은 모든 지역에서 쓸 수 있는 공변량 25 개를 쓴다. 지형 공변량 6 개는 고도, 경사, 사면 방향의 사인과 코사인, 33×33 화소 창 지형 위치 지수와 거칠기이며, Copernicus DEM GLO-30 에서 계산하였다 [미확인: Copernicus DEM GLO-30 인용 형식]. 기후 공변량 8 개는 연평균 기온, 융해 도일 (TDD), 동결 도일, $\sqrt{\text{TDD}}$, 최난월과 최한월 기온, 1 층 토양 온도, 적설 수량이며, 2015–2020 년 ERA5-Land 월평균에서 얻었다²⁷. 토양 공변량 9 개는 5–15 cm 깊이의 점토, 모래, 실트 함량, 용적 밀도, 조립 파편, pH 와 세 깊이의 토양 유기탄소이며, 250 m SoilGrids 2.0 층³⁶ 을 약 5 km 로 재표본해 추출하였다. 모델 기반 공변량 2 개는 ESA CCI Permafrost ALT 제품 4.0 판의 1997–2021 년 평균과 그 유효 표지다³⁷. 이 제품은 같은 재분석 자료로 일

부 구동한 모델 산출물이므로 관측으로 다루지 않는다.

TDD와 Stefan 해⁴는 다음과 같다.

$$\text{TDD} = \sum_m \max(\bar{T}_m, 0) d_m, \quad \text{ALT} \approx E s, \quad s = \sqrt{\text{TDD}}, \quad (1)$$

여기서 $\bar{T}_m$ 은 m 월의 2 m 기온 월평균, d_m 은 그 달의 일수이고, E 의 단위는 $\text{cm} (\text{°C d})^{-1/2}$ 이다. 셀은 라벨, CCI 값, 1 층 토양 온도로 계산한 TDD가 모두 유효할 때만 채점하며, 모든 방법이 같은 채점 셀을 쓴다. 관측 횟수나 연도처럼 라벨에서 유도한 양은 입력에서 빼며, 단위 시험으로 이를 강제한다. 입력의 정보 해상도는 기후가 약 0.1° , 토양이 약 5 km다.

Stefan 기준선과 계수 재보정

계수 E 는 토양 열 특성, 함수량, 지표 조건을 흡수하며, 지역 적용에서는 현지 측정으로 보정한다⁵. 대상의 원천 집합 S 는 대상 지역과 그 둘레 100 km 완충 구역 밖의 모든 라벨 셀이며, 원천 계수는 원점을 지나는 최소제곱 기울기다.

$$E_0 = \frac{\sum_{i \in S} s_i y_i}{\sum_{i \in S} s_i^2}, \quad (2)$$

여기서 y_i 는 관측 ALT다. 원천 계수 Stefan 식은 $E_0 s$ 를 예측한다. 주 대상의 원천 집합에서 알래스카 셀은 78–94%를 차지하므로, E_0 는 이 대상들 사이에서 거의 같다 ($1.59\text{--}1.62 \text{ cm} (\text{°C d})^{-1/2}$; 표 1). 같은 추정량을 대상 라벨 n 개로 계산한 값을 E_{ls} 라 하면, 재보정 Stefan 식은 다음 E_n 으로 $E_n s$ 를 예측한다.

$$E_n = \frac{n E_{ls} + \kappa E_0}{n + \kappa}, \quad \kappa = 10. \quad (3)$$

따라서 원천 계수는 라벨 10개의 가중을 가지며, 이는 라벨이 적을 때 재보정이 오차를 키울 수 있기 때문이다²⁵. κ 값은 이 과제의 앞선 실험에서 정하였으므로 맹검이 아니며, $\kappa = 3$ 과 $\kappa = 30$ 은 민감도 사례다. 현지 최소제곱 Stefan 식은 수축 없이 E_{ls} 를 쓴다. 기계학습 (ML)의 이득은 같은 라벨로 맞춘 재보정 모델에 대해서만 말한다. 원천 계수에 대한 이득에는 재보정의 이득이 들어 있기 때문이다.

물리 모델과 ALT 제품을 비교한 등록 분석에서 더 강한 기준선 두 가지를 더하였다. 연도 정합 Stefan 식은 각 라벨의 관측 연도 (2010–2024년 안, 그 이전 라벨은 2010–2014년)에 대해 평균한 $\sqrt{\text{TDD}}$ 에 E_0 를 적용하며, 라벨 0개와 전량에서 보고한다. 라벨 40개와 160개에서는 토양 보정 Stefan 식 (보충 방법 3)의 출력을 식 (2)과 식 (3)으로 재보정해 더 강한 재보정 기준선으로 보고한다.

기계학습 방법과 결합 구조

전이 설계에서 학습 행은 원천 셀과 대상 라벨 n 개이며 가중은 같다. 앵커를 쓰는 방법은 다음 꼴이다.

$$\hat{y}(x) = a(x) + \lambda g(x), \quad (4)$$

여기서 a 는 물리 앵커이고 g 는 그 잔차로 학습한 학습기다. 직접 ML은 $\sqrt{\text{TDD}}$ 와 CCI 값을 포함한 공변량으로 ALT를 회귀한다. 물리 유사라벨 증강은 대상의 라벨 절반에 있는 셀에 값이 $E_n s$ 인 행을 원천 행 하나당 10개씩 더하며, 추출된 셀은 관측값을 유지한다. 원천 앵커 잔차 결합은 $a = E_0 s$ 를 쓴다. 재보정 앵커 잔차 결합 (잔차 ML)은 $a = E_n s$ 를 쓰며, 잔차 목표는 원천 행에서 $y - E_0 s$, 대상 행에서 $y - E_n s$ 다. 증강·앵커·잔차 결합은 라벨 절반의 셀에 값이 0인 잔차 행을 더한다. 물리 입력 ML은 Kudryavtsev 형 모델 [미확인: Kudryavtsev 1974 서지]과 토양 보정 Stefan 식의 출력, 또는 앵커 값을 직접 ML의 입력에 더한다. Stefan·CCI 앵커는 CCI 값이 유효한 곳에서 $E_n s$ 와 그 값의 평균이다. 본 실험의 다른 방법 네 가지는 보충 방법 3에 적었다. 잔차 가중 $\lambda \in \{0.25, 0.5, 1.0\}$ 은 적합 뒤에 적용한다. 판정의 기준 가중은 본 실험 전에 정하였으며, 잔차 구조에서 0.25, 직접 구조와 물리 입력 구조에서 1.0이다. 가중 0.25의 원천 앵커 잔차 결합을 저가중 잔차라 부른다.

위약 네 가지로 증강의 이득이 셀 수준 Stefan 값에서 오는지 시험하였다. 위약은 유사라벨을 셀 사이에서 섞은 같은 값, 대상 수준 평균, 원천 ALT 평균, 원천에 맞춘 TDD의 선형 함수로 바꾼 것이다.

방법 비교의 학습기는 CatBoost³⁸다 (반복 200회, 학습률 0.05, 깊이 3, seed 2개). 대상 라벨 없는 직접 ML에서는 학습기 10종을 비교하였다. 이 설정, 더 큰 CatBoost, 원천 지역 하나 제외 교차검증으로 조정한

CatBoost, 랜덤 포레스트, 미세 조정 없는 TabPFN v2³⁹ 와 TabICL v2⁴⁰, 그리고 원천 자료에서 원천 지역 하나 제외 교차검증으로 초모수를 고른 신경망 4 종이다^{41,42}. 신경망은 다층 퍼셉트론, 다중 헤드 퍼셉트론 (TabM⁴³ 과 다름), 축소 FT-Transformer 형 모델⁴⁴, RealMLP⁴⁵ 다 (설정은 보충 방법 5). 그림에서는 이 방법들을 Source Stefan, Year-matched Stefan, Recalibrated Stefan, Anchor + residual ML, Source anchor + residual, Physics pseudo-labels, Direct ML, Physics-input ML, Stefan-CCI anchor 로, 아래에 적은 규칙은 Target-label CV selection 으로 표시한다.

전이 시험 설계

가까운 라벨 셀에서 정보가 새지 않도록, 대상의 원천은 대상 지역과 100 km 완충 구역을 뺀다. 하위 지역은 상위 지역을 원천에서 뺀 방식과, 라벨이 있는 지역 안의 새 구역을 흉내 내도록 상위 지역의 나머지를 남긴 방식으로 평가하였다. 대상 27 개는 알래스카를 뺀 3 판 지역 6 곳, 알래스카, 두 방식의 하위 지역 10 곳이다.

각 대상의 0.5° 블록을 무작위로 순서를 바꾼 뒤 셀이 적은 쪽 절반에 차례로 배정하여 절반 A 와 B 로 다섯 번 나누었으므로, 라벨 셀과 채점 셀은 블록 경계로 떨어진다¹⁶. 라벨은 A 에서 뽑고 오차는 B 의 채점 셀에서 잔다. A 의 크기보다 작은 {0, 3, 10, 40, 160, 320, 1000} 의 각 n 과 A 의 전체 셀에 대해, 대상, 방식, 분할, n , 추출로 정한 seed 로 다섯 번 무작위 추출하여 모든 방법이 같은 라벨을 쓰게 하였다. 러시아 서부와 동부는 A 의 셀이 14-17 개이므로, 라벨 40 개와 160 개의 풀 평균에는 레나델타와 캐나다만 들어간다.

주 지역 4 곳 (레나델타, 캐나다, 러시아 서부, 러시아 동부) 이 확인적 풀이다. 이 지역들은 이 과제의 앞선 실험에 쓰였으므로, 그 판정은 재사용 지역의 재검정이다. 알래스카는 참조 대상으로 따로 보고하며, 레나델타, 캐나다와 함께 보조 3 지역 평균에 넣는다. 3 판 표의 러시아 중부와 그린란드는 점 추정으로만 보고하고, 상위 지역과 셀을 공유하는 하위 지역은 판정 범주별로 센다. 추가 지역은 얇은 레짐 5 지역 확장 풀과 티베트 고원을 포함한 6 지역 확장 풀에 들어간다. 티베트 고원의 채점 셀은 모두 원천 셀 고도의 99.5 백분위수보다 높으므로, 티베트 대비는 독립 지역의 근거로 쓰지 않는다.

검증 사다리는 알래스카와 주 지역 4 곳에서 직접 ML 과 학습 폴드에 맞춘 Stefan 식을, 무작위 셀부터 지역 홀드아웃까지 설계상 분리가 커지는 여덟 방식으로 채점하였다 (보충 방법 3). 앞선 알래스카 분석은 k 겹 최근 접 거리 정합 (kNNDM)²⁶ 을 더하였는데, 이 방식은 시험과 학습 사이의 거리를 예측 격자와 라벨 사이의 거리에 맞춘다.

지역 내 시험 설계와 이득 분해

지역 내 시험은 라벨이 수백에서 수천 개인 곳에서 ML 이 무엇을 더하는지 묻으며, 전이 결과를 본 뒤 설계하였다. 알래스카, 레나델타, 캐나다에서 라벨은 절반 A 에서 뽑았고 유일한 학습 행이었다. 전이 설계의 원천 계수를 사전값으로 썼고, λ 는 뽑은 라벨 안의 블록 교차검증으로 {0.25, 0.5, 1.0} 에서 골랐으며, 증강은 라벨 하나당 유사라벨 10 개를 썼다. 첫 시험 (분할 5 개, 라벨 1000 개 이상, 비교 상대는 교차검증으로 고른 최선의 물리 보정식, 알래스카에서는 SAR 공변량 9 개 추가) 은 기각되었다. 두 번째 시험은 네 요소를 바꾸었다. 비교 상대 (재보정 Stefan 식), 분할 (25 개, 레나델타는 24 개 유효), 레시피 (Stefan·CCI 앵커와 직접 ML 추가), 라벨 범위 (200, 500, 1000 개와 전량) 다. 두 시험을 모두 보고한다.

이득 분해는 ML 이 어느 공간 규모에서 오차를 줄이는지 묻는다. 채점 셀을 0.5° 블록과 기온 $\sqrt{TDD}$ 로 묶어, 한 묶음 안에서 Stefan 예측과 기후 공변량 8 개가 일정하게 하였다. 묶음 g 의 셀 수를 N_g , 평균을 $\bar{y}_g$ 와 $\hat{\bar{y}}_g$ 라 하면 다음과 같다.

$$SSE = \sum_g \sum_{i \in g} [(y_i - \bar{y}_g) - (\hat{y}_i - \hat{\bar{y}}_g)]^2 + \sum_g N_g (\bar{y}_g - \hat{\bar{y}}_g)^2, \quad (5)$$

여기서 두 항은 격자 안 성분과 격자 사이 성분이다. 격자 안 RMSE 는 셀이 2 개 이상인 묶음을 쓰며, Stefan 식에서는 관측의 묶음 내 표준편차와 같다. 성분의 RMSE 차이는 더해지지 않으므로, 감소의 비율은 SSE 로 계산한다. 등록 문서는 묶음 기준으로 토양 $\sqrt{TDD}$ 를 적었으나 실행은 Stefan 예측의 기온 $\sqrt{TDD}$ 를 썼다. 그래서 토양 기준 묶음의 민감도 분석을 등록하고 실행하였다 (두 묶음 사이 수정 Rand 지수는 알래스카 0.999, 캐나다 0.997, 레나델타 0.832).

라벨 배치 절차

배치 전략은 능동 선정을 빼고는 라벨 값을 쓰지 않고 절반 A의 셀을 고른다. 셀 무작위 추출 외의 전략은 블록 증화, 공변량 군집 증화, 공변량 최대 최소 거리 추출, 원천 외삽 우선, 잔차 학습기의 예측 분산에 따른 능동 선정, $\sqrt{TDD}$ 우선이다 (보충 방법 8). 지역 안에서는 라벨 20–500 개에서 비교하였고, 블록 증화와 최대 최소 거리 추출은 전이에서 라벨 10 개와 40 개로도 비교하였다. 이 시험들은 결과를 본 뒤 설계하였고, 본 실험의 블록 분산 대비는 결과 전에 등록하였다.

알고리즘 P는 블록 배분과 공변량 범위를 결합한 절차이며, 워크플로 분석에서 시험한 사전 지정 배치 절차다. 입력은 후보 셀의 표준화 공변량 (라벨 값 없음), 블록 크기 N_b , 라벨 10, 40, 160 개의 중첩 예산, 배분 지수 γ , seed 다.

1. seed 로 고른 블록이나 기존 라벨이 있는 블록에서 시작해, 블록의 공변량 중심 μ_b 를 가장 먼 점 우선 순회로 정렬한다.
2. 예산 n_k 에서 블록 b 에 $q_b = n_k N_b^\gamma / \sum_{b'} N_{b'}^\gamma$ 개의 라벨을 최대 나머지 방식으로 배분하되 N_b 를 넘지 않게 한다.
3. 남은 부족분이 가장 큰 블록을 채운다. 그 블록에 라벨이 없으면 μ_b 에 가장 가까운 셀을, 있으면 이미 고른 모든 라벨에서 가장 먼 셀을 고른다.
4. 예산이 늘어도 앞서 고른 라벨은 유지한다.

후보 설정은 $\gamma = 0, 0.5, 1$, 블록의 첫 셀을 가장 먼 점 우선으로 고르는 변형, 블록 증화, 최대 최소 거리 추출이다. 평가 지역이 선택에 영향을 주지 않도록 알래스카 대상만으로 기계적 규칙에 따라 후보 하나를 고른다. 이 규칙에서 모든 후보가 제외되어 Algorithm P는 셀 무작위 추출이며, Algorithm P대 무작위 배치의 워크플로 대비는 시험하지 않았다. 따라서 워크플로의 배치 단계는 기여한 것이 없다. 라벨 10 개에서는 워크플로와 그 무작위 배치 비교 대상이 같은 라벨과 모델을 쓰고, 라벨 40 개와 160 개에서 무작위 배치와 고정 잔차 레시피에 대한 비교는 같은 라벨에서 선정 규칙과 고정 레시피를 비교한 것이다. 등록한 보고 규칙에 따라 측정 위치의 순위를 매긴 지도는 만들지 않았다.

방법 선정 규칙과 편향 진단

선정 규칙은 대상 라벨만으로 방법을 고른다.

1. 라벨이 10 개보다 적으면 재보정 Stefan 식을 쓴다.
2. 라벨이 있는 블록을 최대 5 개 폴드에 무작위로 배정한다 (블록이 하나면 셀 폴드). 폴드가 2 개보다 적으면 재보정 Stefan 식을 쓴다.
3. 각 폴드에서 E_n 을 다시 계산하고 후보 7 개를 맞춘다. 후보는 원천 계수, 재보정, 현지 최소제곱 Stefan 식, $\lambda = 0.25$ 와 1.0 의 잔차 ML, 증강·앵커·잔차 결합, 물리 유사라벨이다.
4. 교차검증 RMSE 가 가장 낮은 후보를 고른다 (동률이면 작은 λ 와 앞선 후보).
5. 고른 후보를 모든 라벨로 다시 맞춘다.

이 규칙은 라벨 격자 결과를 본 뒤 등록하였고, 대상 30 개 (전이 대상 27 개와 약관 확인 추가 지역 대상 3 개) 의 라벨 10, 40, 160 개와 전량에 적용하였다. 비교 상대는 고정 잔차 레시피이며 비열등 한계는 0.5 cm 다.

편향 진단값은 한 추출의 라벨 10 개에서 원천 계수 Stefan 식이 보인 평균 오차의 절댓값을 추출과 분할에 걸쳐 평균한 값이다. 재보정도 쓰는 라벨만 쓰므로, 어떤 학습기를 맞추기 전에 알 수 있다. 이 진단값과 라벨 전량에서 선정 규칙이 원천 계수 모델에 대해 보인 이득의 Spearman 상관을 대상 28 개에서 계산하였다. 이 이득에는 재보정이 들어 있으므로, 상관은 라벨을 쓰는 보정 (재보정과 잔차) 에 관한 것이다. 재보정을 넘어서 이득의 몫은 따로 사후 분석으로 살폈다 (추가 등록 분석).

통계 분석

절반 B의 블록 b 에서 오차 제곱합을 SSE_b , 채점 셀 수를 N_b 라 할 때, 두 가지 평균 제곱근 오차 (RMSE, cm)를 계산하였다.

$$RMSE_{\text{cell}} = \left(\frac{\sum_b SSE_b}{\sum_b N_b} \right)^{1/2}, \quad RMSE_{\text{block}} = \frac{1}{|B|} \sum_b \left(\frac{SSE_b}{N_b} \right)^{1/2}, \quad (6)$$

여기서 $|B|$ 는 채점 블록 수다. 셀 가중 값이 주 값이고, 블록 등가중 값은 표본이 조밀한 블록의 영향을 줄인다. 대비 Δ 는 첫 방법의 RMSE에서 둘째 방법의 RMSE를 뺀 값으로, 분할, 추출, seed로 짚지어 분할에 걸쳐 평균하므로 음수는 첫 방법의 오차가 낮다는 뜻이다. 층화 평균은 지역에 같은 가중을 준다.

신뢰구간 (CI)은 각 분할 안에서 채점 블록을 부트스트랩한 95% 백분위 구간이며, 두 방법에 같은 재표집 블록을 쓴다. 라벨 격자 하네스가 모은 가설 (본 실험과 추가 지역 실험)과 예측 구간 실험은 반복 1000회를, 다른 모든 대비는 10,000회를 썼다. 두 팔이 서로 다른 라벨 집합을 쓰는 본 실험의 블록 분산 대비와 워크플로 분석은 추출도 재표집하는 2단 부트스트랩을 썼고, 배치 시험은 라벨 추출을 조건으로 한 구간을 보고한다. 보조 구간은 한 지역 블록의 합집합을 모든 분할에 대해 한 번 재표집하였다. 이 구간이 판정을 바꾸는 경우 결과를 분할 독립 가정에 의존한다고 적으며, 이 단서가 없는 문장은 두 판정이 일치해야 한다. 지역은 유효 분할의 채점 블록 합집합이 8개 이상일 때 풀 구간에 들어갔다.

대비는 셀 가중과 블록 등가중 CI의 상한이 모두 0보다 작으면 오차 감소, 하한이 모두 0보다 크면 오차 증가, 둘 다 아니고 네 한계가 모두 ± 0.5 cm 안에 있으면 동등 (유의수준 2.5%의 두 단측 검정⁴⁶), 그 밖에는 미결정 ('차이를 확인하지 못했다')이다. 한계는 어떤 결과보다 먼저 정하였다. 이 한계는 주 지역에서 원천 계수 Stefan 식의 셀 가중 RMSE (21.7–43.0 cm)의 약 1–2%이며, 측정 오차가 아니라 관례다. 1.0 cm와 그 RMSE의 2%를 한계로 한 경우는 민감도 사례다. $|\Delta| < 0.5$ cm인 오차 감소나 오차 증가는 크기가 0.5 cm 미만인 구별 가능한 차이로 보고한다. 비열등은 단측이며 두 상한이 모두 +0.5 cm보다 작아야 한다. 대비의 최소 라벨 수 n^* 는 셀 가중 CI 상한이 0보다 작고, 분할의 3분의 2 이상과 추출의 75% 이상에서 $\Delta < 0$ 인 가장 작은 n 이다.

유의수준은 양측 $\alpha = 0.05$ 이며, 단측 0.025에 해당한다. P 값은 두 가중의 양측 부트스트랩 P 값 가운데 큰 값이며, 모든 등록 대비의 보정 전과 Holm 보정 P 값은 보충 표 S2에 있다. 결과 전에 정한 대비 10개만 초록에서 판정어를 쓸 수 있다. 이들의 P 값은 가족 크기를 10으로 고정한 Holm 절차⁴⁷로 보정하였고, 보정 P 가 0.05보다 작을 때만 초록에 방향을 적는다. 그렇지 않으면 초록에는 차이를 확인하지 못했다고 적고, 본문에 '보정 전에만 유의'를 더한다. 지역 내 시험, 배치 시험, 선정 시험과 추가 분석의 결과는 초록에 수치로만 나온다. 다른 등록 가족에서 Holm 보정 P 값은 보조 값이며, 워크플로 시험과 제품 비교에서만 문구를 정한다.

풀 대비는 4–7개 지역에 근거하므로 재표집 단위는 0.5° 블록 (지역당 13–74개)이며, 모든 풀 평균에 지역 값과 범위를 함께 적는다. 지역 일반에 관한 문장을 위해 핵심 대비를 주 지역 4곳과 알래스카의 분할 50개로 다시 계산하고, 부호 검정, 부호 뒤집기 순열 검정, Hartung-Knapp 확률효과 평균⁴⁸으로 요약하였다. 이런 문장은 Hartung-Knapp 구간이 0을 벗어날 때만 쓰며, 지역이 4곳이면 가장 작은 양측 부호 검정 P 는 0.125다. 순위상관은 Spearman 계수이며, 구간은 블록과 추출의 결합 재표집으로 얻었다. 오차 하한은 지형이 아닌 거친 공변량이 같은 셀 5개 이상의 묶음 안에서 관측의 합동 분산이며 (알래스카 13,333 셀), 효과 크기의 분모로만 쓴다.

앞선 결과를 본 뒤 설계한 분석은 그렇게 표시하고, 사후 서술에는 판정어를 쓰지 않는다. 등록 가설마다 맹검 표지 네 가지 가운데 하나를 단다. 맹검, 부분 비맹검 (다른 규약에서 방향을 봄), 재현 (비맹검) (같은 대비의 방향을 봄), 등록 시점에 결과 존재 (열지 않음)다. 예측 구간은 경험적 포함률과, $a = 0.1$ 인 중앙 구간 $[L, U]$ 의 구간 점수 $(U - L) + (2/a)(L - y)_+ + (2/a)(y - U)_+$ 로 평가하였다³⁰. 계층 conformal 구간은 원천 지역을 묶음으로 썼으며²⁸, 묶음이 2–4개이므로 유한 표본 보장이 없다 (보충 방법 4). $\pm$ 뒤에 값을 적지 않는다.

내부 사전 등록과 등록 이탈

가설, 대비, 판정 규칙, 허용 문장은 해당 결과를 가져오기 전에 과제의 git 저장소에 커밋하였다 (내부 사전 등록). 커밋에는 제삼자 시간 인증이 없으며, 시각은 한국 표준시의 커밋 시각이다 (전체 표는 보충 방법 6). 라벨 격자 실험 (LG, L1–L8)은 2026년 9월 29일 15:45:46에 커밋 40be64c로 등록하였다. 그 확장 (LGX), 파운

데이션 모델과 추가 지역 실행 (LGT, LGD), 구간 실험 (LGU), TabICL 과 조정 신경망 실행 (LGF), 초록 묶음 AB1-AB10 을 포함한 보고 규칙 (WRAPUP, 316714c, 2026 년 9 월 30 일 03:02:42) 이 뒤따랐고, 모두 그날 07:20:22 의 첫 결과 회수보다 앞섰다.

워크플로 실험은 이 결과를 본 뒤 설계하고 실행 전에 등록하였다. WF0-WF5 는 4168331(2026 년 10 월 1 일), WF6-WF8 은 1b42b4d(2026 년 10 월 1 일), WF9 와 WF10 은 8180632(2026 년 10 월 2 일), 토양 기준 묶음 민감도는 7da0064(2026 년 10 월 2 일) 다. WF0 은 사후 서술이고, WF5 로 계획한 우선순위 지도는 만들지 않았다. 분석 XA-XJ 는 어떤 적합보다 먼저 커밋 2678100(2026 년 10 월 4 일 14:22:39) 으로 등록하였다. 실행 전 등록 확인 시험으로 표시한 것은 XC-F3 뿐이며, XA 는 사후 분석이다. 각 분석을 본문에 돌지 보충 정보에 돌지는 결과 전에 정하였다.

등록 이탈과 사후 변경은 다음과 같다.

1. 이득 분해 (WF9) 는 등록한 토양 $\sqrt{TDD}$ 가 아니라 기온 $\sqrt{TDD}$ 로 셀을 묶었고, 토양 기준 묶음의 민감도 분석을 더하였다.
2. 첫 지역 내 시험 (WF1-a) 이 기각된 뒤 두 번째 시험 (WF6) 은 비교 상대, 분할, 레시피, 라벨 범위를 바꾸었다.
3. 제품 비교 (XG) 는 구간 가설 (LGU-B2) 에 조건을 둔 서술 표로 등록되었다. 그 가설이 미결정으로 끝난 뒤 XG 는 Holm 보정 대비 6 개로 다시 등록하였고 등록 이탈 표지를 단다.
4. 워크플로 분할 (XC) 은 seed 1-200 이 이미 쓰였으므로 (LGX-N4) seed 6-15 에서 201-210 으로 옮겼고, XC 판정어를 초록에 쓰자는 제안은 철회하였다.
5. AB4 에는 결과 전 민감도 계산이 같은 양의 분할 분포를 보여 주었다는 주석을 단다.
6. 표를 고정한 뒤 발견한 지온 유도 셀 20 개는 표지를 단 채 직접 라벨 범주에 남아 있다.
7. 기술적 수정 네 건 (ff1be02, 2026 년 9 월 30 일 11:44:30) 은 첫 회수 뒤에, 그러나 어떤 결과도 풀거나 열기 전에 커밋하였으며, 가설, 대비, 판정 규칙을 바꾸지 않는다. [DECISION: 수용 여부, 방법 초안 183 행]
8. CatBoost 는 교차 환경 점검 (i) 을 통과하지 못했으므로, 플랫폼을 섞은 확장 풀 행에는 교차 환경 표지를 단다.
9. 등록 규칙에 따라 측정 우선순위 지도는 만들지 않았다.
10. 기후 외삽 시험 (WF10) 은 캐나다의 외삽 집합이 블록 3 개여서 판정할 수 없었다.
11. XA 는 등록한 7 개 계열이 아니라 8 개 대상 계열로 재표집하였다. 28 대상 집합의 북대서양 대상이 등록 계열 목록에 없었기 때문이다 (봉인 결과와 함께 기록한 구현 이탈).

추가 등록 분석

분석 10 개 (XA-XJ) 는 위의 규약을 따르며, 각 분석을 본문과 보충 정보 가운데 어디에 돌지는 결과 전에 정하였다 (보충 방법 9; 결과는 보충 표 S13).

XA(본문, 사후) 는 원천 계수 모델에 대한 이득을 재보정 몫, 남은 수축 몫, 재보정을 넘어서 ML 몫으로 나누고, 두 정의의 계수 오차와 각 몫의 순위상관을 추정하며, 구간은 대상 계열과 블록의 결합 재표집으로 얻는다. 등록 목록은 7 개 계열이었고, 그 목록에 없는 북대서양 대상은 8 번째 단일 대상 계열로 재표집하였으며, 등록한 7 개 계열의 27 대상은 결과 범주가 같은 등록 밖 민감도로 분석하였다. 결과는 0 을 벗어난 구간이거나 '확인하지 못함' 으로만 적는다. XB(보충) 는 교차 적합으로 대상 라벨에서 물리 모델과 ALT 제품의 블록 가중을 학습하며, 잔차 학습기가 있는 경우와 없는 경우를 본다. XC(본문) 는 알고리즘 P, 라벨 10 개 진단, 방법 규칙을 얹은 레짐 5 지역의 새 분할에 차례로 적용한다. Holm 보정 가설 8 개는 라벨 40 개와 160 개에서 워크플로를 무작위 배치와 고정 잔차 레시피에 비교하고, 라벨 10, 40, 160 개에서 재보정 Stefan 식에 대한 비열등을 시험하며, 선

정 규칙 아래에서 알고리즘 P 를 무작위 배치와 비교하고, 새로 얻은 지역에서 라벨 10 개의 워크플로를 시험한다. 평가 셀이 구성 요소 설계에 쓰였으므로, 마지막 가설을 뺀 모두가 부분 비맹점이다.

XD(보충) 는 알래스카 대상에서 알고리즘 P 의 설정을 고르고, 다른 계수 추정량을 시험하며, 학습된 배치 정책을 알래스카 밖에서 P 값 없이 한 번 평가한다. XE(보충) 는 지역 안 잔차 ML 에 10–500 m 의 공개 입력을 더하고, 격자 안 RMSE 를 공변량 25 개 모델과 재보정 Stefan 식에 비교한다. XF(보충, 맹검) 는 새 공개 자료에 적격 규칙을 적용하고 적격 지역마다 핵심 대비를 되풀이한다. XG(본문) 는 제품 학습 지점에서 5 km 나 25 km 안의 블록을 가린 뒤 기존 ALT 지도를 같은 블록에서 채점하며, 원래 값은 원천 계수 모델에, 재보정 값은 잔차 ML 에 비교한다. XH(본문) 는 세 지역에서 무작위 셀, 지점, 블록, kNNDM, 지역 홀드아웃 검증에 따른 재보정 Stefan 식, 잔차 ML, 직접 ML 의 오차를 판정어 없이 서술한다. XI 는 약관 확인 캐나다 확충 표에서 기후 외삽 시험을 되풀이하고, XJ 는 지온 유도 라벨을 저가중 보조 행으로 시험한다 (둘 다 보충).

계산 환경과 재현성

물리 모델과 CatBoost 는 CPU 에서 결정적으로 실행된다. 라벨 격자 실험과 그 확장은 CPU 64 코어와 NVIDIA T4 GPU 4 개를 가진 클라우드 노드 (Rescale) 에서, 워크플로 실험과 추가 분석은 한 프로세서 계열 (AMD EPYC Milan 96 코어, Milan-X 64 코어) 의 클라우드 CPU 노드에서 실행하였다. 파운데이션 모델, 조정 신경망, 구간 실험, 추가 지역 실험은 NVIDIA RTX 3090 GPU 를 가진 공유 로컬 서버를 썼다. 패키지 판은 고정하였고 (모든 플랫폼에서 CatBoost 1.2.10; 보충 표 S16), 각 산출물은 코드 해시, 설정 해시, 패키지 판, 장치를 기록한다.

물리식과 CatBoost 결과는 클라우드와 로컬 실행 사이에서 34,360 개 키에 걸쳐 3.6×10^{-14} cm 안에서 일치하였고, 클라우드 노드 두 종류는 공통 키 11,814 개에서 같은 오차를 냈다. 신경망은 플랫폼 사이에서 재현되지 않았다. FT-Transformer 키 288 개 가운데 43 개가 0.5 cm 넘게 달랐고 (최대 5.61 cm), 한 플랫폼 안의 재적합은 같았다. 릿지 앵커 위의 CatBoost 는 최대 0.46 cm 달랐다. 따라서 대비의 양쪽은 한 플랫폼에서 오고, 플랫폼을 넘는 폴 평균에는 교차 환경 표지를 달며, 워크플로는 CatBoost 와 닫힌 형태의 물리식만 쓴다.

지도와 색표

지도는 70° N 에서 축척이 참인 북극 평사 투영을 쓰고 중심 경도는 각 설명문에 적으며, 티베트 고원은 Lambert 방위 정적 투영의 삽도로 넣었다. 육지는 Natural Earth(1:50m), 영구동토 구역은 [미확인: 영구동토 구역 자료의 이름과 판] 에서 가져왔고, 지도는 Cartopy [미확인: Cartopy 판] 로 그렸다. 과학 색표^{49,50} 를 썼다. ALT 에는 oslo 를 뒤집어 0.12–0.90 범위로, 오차 차이에는 0 을 중심으로 한 broc 을, 잔차에는 bam 을, 구간 폭에는 acton 을 뒤집어 0.05–0.95 범위로 썼다.

대형 언어 모델 사용

[DECISION: LLM 사용 기재 문구]

코드 가용성

자료 준비, 실험, 통계, 그림, 시험에 쓴 코드는 [DECISION: 공개 저장소 주소와 공개 시점] 에서 받을 수 있고, 판 DOI 와 함께 보관한다 [DECISION: Zenodo DOI]. 주요 구성 요소는 라벨 격자 실험 (scripts/3_deep_learning/h40_label_grid.py), 검증 사다리 (scripts/2_evaluation/h41_validation_ladder.py), 확장 실험 (scripts/3_deep_learning/h42_label_grid_ext.py), 워크플로 실험 (scripts/3_deep_learning/h54_workflow.py), 초록 대비 집계기 (scripts/2_evaluation/h39_scenarios.py), 사후 재분석 (scripts/2_evaluation/wf0_reanalysis.py), 추가 분석 (x_*.py), 단위 시험 (tests/), 클라우드 작업 설정 (configs/rescale/) 이며, 등록 문서와 그 개정 이력도 함께 둔다. 추가 분석은 catboost 1.2.10, scikit-learn 1.9.1, pandas 2.3.3, scipy 1.17.1, numpy 2.1.1 을 고정한다. TabPFN v2 와 TabICL v2 의 사전 학습 가중치는 재배포하지 않으며 제공처에서 받는다.

자료 가용성

주 지역의 활동층 라벨은 GTN-P/CALM 자료³(PANGAEA, <https://doi.org/10.1594/PANGAEA.972777>), 레나강 삼각주의 ALLena 자료³⁴(PANGAEA, <https://doi.org/10.1594/PANGAEA.973813>), ABoVE 토양 수분·활동층 두께 자료 2 판³⁵(ORNL DAAC, <https://doi.org/10.3334/ORNLDAAC/2369>)에서 받을 수 있다. 추가 지역의 라벨은 공개된 자료⁵¹⁻⁶⁴에서, 라벨 정의 시험에만 쓴 지온 유도 라벨은 티베트 고원 자료⁶⁵에서 가져왔다. 식별자와 약관은 보충 표 S17에 있다. 재배포 약관이 확인되지 않은 자료의 라벨은 주 결과에 쓴 약관 확인판에서 뺐고 재배포하지 않으며, 보충 표 S17에 적은 원 제공처에서 받을 수 있다. 이런 라벨을 포함한 북대서양 전체 판은 보충 정보에만 보고한다.

공변량은 ERA5-Land 월평균 자료²⁷(Copernicus Climate Data Store, <https://doi.org/10.24381/cds.68d2bb30>), SoilGrids 2.0³⁶ [미확인: 접근 시점의 SoilGrids 판 표지], Copernicus DEM GLO-30(<https://doi.org/10.5270/ESA-c5d3d65>) [미확인: Copernicus DEM 인용 형식], ESA CCI Permafrost 활동층 두께 제품 4.0 판³⁷(CEDA, <https://doi.org/10.5285/d34330ce3f604e368c06d76de1987ce5>)에서 만들었다. 알래스카 지역 내 시험의 합성 개구 레이더 (SAR) 공변량은 2017년 ABoVE 항공 L·P 밴드 SAR 활동층 추정(ORNL DAAC, <https://doi.org/10.3334/ORNLDAAC/2004>)과 알래스카 북부의 P 밴드 편파 SAR 활동층 상향 지도⁶⁶에서 가져왔다 [미확인: PolSAR 상향 ALT 자료의 DOI, 후보 10.3334/ORNLDAAC/2332]. 지도 가림에는 ESA CCI Permafrost 범위 제품 [미확인: 영구동토 범위 자료의 DOI와 판]과 JRC Global Surface Water 출현 빈도 층⁶⁷을 썼다.

조립한 라벨·공변량 표, 실행 산출물, 집계·판정 표, 셀 단위 예측, 모든 그림의 원자료는 [DECISION: 저장소와 DOI]에 올릴 예정이다. 약관이 확인되지 않은 자료의 행은 올리는 표에서 뺐다. [DECISION: KPDC 자료, SI 포함 여부와 식별자, 이용 조건]

참고문헌

- [1] Karjalainen, O. *et al.* Circumpolar permafrost maps and geohazard indices for near-future infrastructure risk assessments. *Sci. Data* **6**, 190037 (2019).
- [2] Ran, Y. *et al.* Permafrost degradation increases risk and large future costs of infrastructure on the Third Pole. *Commun. Earth Environ.* **3**, 238 (2022).
- [3] Streletskiy, D. A. *et al.* GTN-P CALM: 35 years of Active Layer Thickness (ALT) across latitudinal and elevational gradients in the Northern Hemisphere. PANGAEA (2025). URL <https://doi.org/10.1594/PANGAEA.972777>.
- [4] Stefan, J. Über die Theorie der Eisbildung, insbesondere über die Eisbildung im Polarmeere. *Annalen der Physik* **278**, 269–286 (1891).
- [5] Nelson, F. E. *et al.* Estimating active-layer thickness over a large region: Kuparuk River basin, Alaska, U.S.A. *Arct. Alp. Res.* **29**, 367–378 (1997).
- [6] Pilyugina, P. *et al.* A physics-informed machine learning framework for permafrost stability assessment. *IEEE Access* **13**, 96423–96433 (2025).
- [7] Wang, G. *et al.* Simulation of active layer thickness based on multi-source remote sensing data and integrated machine learning models: a case study of the Qinghai-Tibet Plateau. *Remote Sens.* **17**, 2006 (2025).
- [8] Zhang, C., Douglas, T. A., Brodylo, D., Bosche, L. V. & Jorgenson, M. T. Combining a climate-permafrost model with fine resolution remote sensor products to quantify active-layer thickness at local scales. *Environ. Res. Lett.* **19**, 044030 (2024).

- [9] Gay, B. A. *et al.* Resolving circumarctic zero-curtain phenomena with AI-integrated earth observations. *Sci. Rep.* **16**, 28715 (2026).
- [10] Read, J. S. *et al.* Process-guided deep learning predictions of lake water temperature. *Water Resour. Res.* **55**, 9173–9190 (2019).
- [11] Jia, X. *et al.* Physics-guided machine learning for scientific discovery: an application in simulating lake temperature profiles. *ACM/IMS Trans. Data Sci.* **2**, 20 (2021).
- [12] Willard, J., Jia, X., Xu, S., Steinbach, M. & Kumar, V. Integrating scientific knowledge with machine learning for engineering and environmental systems. *ACM Comput. Surv.* **55**, 66 (2022).
- [13] Gautam, S., Mishra, U., Scott, S. N. & Lara, M. J. Machine learning and process-based modeling of spatiotemporal changes in active layer thickness across Alaska. *Sci. Rep.* **15**, 42420 (2025).
- [14] Aalto, J., Karjalainen, O., Hjort, J. & Luoto, M. Statistical forecasting of current and future circum-Arctic ground temperatures and active layer thickness. *Geophys. Res. Lett.* **45**, 4889–4898 (2018).
- [15] Ran, Y. *et al.* New high-resolution estimates of the permafrost thermal state and hydrothermal conditions over the Northern Hemisphere. *Earth Syst. Sci. Data* **14**, 865–884 (2022).
- [16] Roberts, D. R. *et al.* Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography* **40**, 913–929 (2017).
- [17] Ploton, P. *et al.* Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nat. Commun.* **11**, 4540 (2020).
- [18] Meyer, H. & Pebesma, E. Machine learning-based global maps of ecological variables and the challenge of assessing them. *Nature Communications* **13**, 2208 (2022).
- [19] Wadoux, A. M. J.-C., Heuvelink, G. B. M., de Bruin, S. & Brus, D. J. Spatial cross-validation is not the right way to evaluate map accuracy. *Ecol. Model.* **457**, 109692 (2021).
- [20] Willard, J. D. *et al.* Predicting water temperature dynamics of unmonitored lakes with meta-transfer learning. *Water Resour. Res.* **57**, e2021WR029579 (2021).
- [21] Pool, S., Viviroli, D. & Seibert, J. Value of a limited number of discharge observations for improving regionalization: a large-sample study across the United States. *Water Resour. Res.* **55**, 363–377 (2019).
- [22] Feng, D., Beck, H., Lawson, K. & Shen, C. The suitability of differentiable, physics-informed machine learning hydrologic models for ungauged regions and climate change impact assessment. *Hydrol. Earth Syst. Sci.* **27**, 2357–2373 (2023).
- [23] O'Malley, D. *et al.* In-context learning enables continental-scale subsurface temperature prediction from sparse local observations. arXiv:2605.16665 (2026). arXiv:2605.16665.
- [24] Portes, C., Ienco, D. & Gabriel, E. When machine learning extrapolates in space: how local data shape spatial transferability. *Spat. Stat.* **74**, 101009 (2026).
- [25] Steyerberg, E. W., Borsboom, G. J. J. M., van Houwelingen, H. C., Eijkemans, M. J. C. & Habbema, J. D. F. Validation and updating of predictive logistic regression models: a study on sample size and shrinkage. *Stat. Med.* **23**, 2567–2586 (2004).

- [26] Linnenbrink, J., Milà, C., Ludwig, M. & Meyer, H. kNNDM CV: k-fold nearest-neighbour distance matching cross-validation for map accuracy estimation. *Geoscientific Model Development* **17**, 5897–5912 (2024).
- [27] Muñoz-Sabater, J. *et al.* ERA5-Land: a state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data* **13**, 4349–4383 (2021).
- [28] Dunn, R., Wasserman, L. & Ramdas, A. Distribution-free prediction sets for two-layer hierarchical models. *Journal of the American Statistical Association* **118**, 2491–2502 (2023).
- [29] Romano, Y., Patterson, E. & Candès, E. J. Conformalized quantile regression. *Advances in Neural Information Processing Systems* **32**, 3538–3548 (2019).
- [30] Gneiting, T. & Raftery, A. E. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association* **102**, 359–378 (2007).
- [31] Riseborough, D., Shiklomanov, N., Etzelmüller, B., Gruber, S. & Marchenko, S. Recent advances in permafrost modelling. *Permafrost and Periglacial Processes* **19**, 137–156 (2008).
- [32] Shiklomanov, N. I. & Nelson, F. E. Active-layer mapping at regional scales: a 13-year spatial time series for the Kuparuk region, north-central Alaska. *Permafrost and Periglacial Processes* **13**, 219–230 (2002).
- [33] Wei, Y., Wu, Z., Wang, J. *et al.* A 1 km resolution dataset of Northern Hemisphere permafrost active layer thickness (2000–2024). *Earth System Science Data Discussions* (2026).
- [34] Veremeeva, A. *et al.* ALLena: Thaw depth measurements of the active layer in the Lena River Delta region from 1998 to 2022, Northeastern Siberia. PANGAEA (2025). URL <https://doi.org/10.1594/PANGAEA.973813>.
- [35] Moore, M. A. *et al.* ABoVE: Soil moisture and active layer thickness in Alaska, USA and Canada, 2005–2024, version 2. ORNL Distributed Active Archive Center (2025). URL <https://doi.org/10.3334/ORNLDAAAC/2369>.
- [36] Poggio, L. *et al.* SoilGrids 2.0: producing soil information for the globe with quantified spatial uncertainty. *SOIL* **7**, 217–240 (2021).
- [37] Westermann, S. *et al.* ESA Permafrost Climate Change Initiative (Permafrost_cci): Permafrost active layer thickness for the Northern Hemisphere, v4.0. NERC EDS Centre for Environmental Data Analysis (2024). URL <https://doi.org/10.5285/d34330ce3f604e368c06d76de1987ce5>.
- [38] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. & Gulin, A. CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems* **31**, 6639–6649 (2018).
- [39] Hollmann, N. *et al.* Accurate predictions on small data with a tabular foundation model. *Nature* **637**, 319–326 (2025).
- [40] Qu, J., Holzmüller, D., Varoquaux, G. & Le Morvan, M. TabICLv2: a better, faster, scalable, and open tabular foundation model. Preprint at <https://arxiv.org/abs/2602.11139> (2026).
- [41] Bergstra, J. & Bengio, Y. Random search for hyper-parameter optimization. *Journal of Machine Learning Research* **13**, 281–305 (2012).

- [42] Cawley, G. C. & Talbot, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research* **11**, 2079–2107 (2010).
- [43] Gorishniy, Y., Kotelnikov, A. & Babenko, A. TabM: advancing tabular deep learning with parameter-efficient ensembling. *International Conference on Learning Representations* (2025).
- [44] Gorishniy, Y., Rubachev, I., Khrulkov, V. & Babenko, A. Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems* **34**, 18932–18943 (2021).
- [45] Holzmüller, D., Grinsztajn, L. & Steinwart, I. Better by default: strong pre-tuned MLPs and boosted trees on tabular data. *Advances in Neural Information Processing Systems* **37** (2024).
- [46] Schuirmann, D. J. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. *Journal of Pharmacokinetics and Biopharmaceutics* **15**, 657–680 (1987).
- [47] Holm, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics* **6**, 65–70 (1979).
- [48] Hartung, J. & Knapp, G. A refined method for the meta-analysis of controlled clinical trials with binary outcome. *Statistics in Medicine* **20**, 3875–3889 (2001).
- [49] Crameri, F. Scientific colour maps. Zenodo (2018).
- [50] Crameri, F., Shephard, G. E. & Heron, P. J. The misuse of colour in science communication. *Nature Communications* **11**, 5444 (2020).
- [51] Du, E. *et al.* Code for “A first 90 m resolution active layer moisture dataset across the Qinghai-Tibet Plateau permafrost region derived from multi-model machine learning fusion”, v2.0.0. Zenodo (2026). URL <https://doi.org/10.5281/zenodo.21999366>.
- [52] Grosse, G. Active layer data of the geo-located sites around Cape Mamontov Klyk, Appendix 4.2. PANGAEA (2007). URL <https://doi.org/10.1594/PANGAEA.611409>.
- [53] Palmtag, J. *et al.* Detailed pedon data on soil carbon and nitrogen for the northern permafrost region, version 1. Bolin Centre Database (2022). URL <https://doi.org/10.17043/palmtag-2022-pedon-1>.
- [54] Talucci, A. *et al.* FireALT dataset: estimated active layer thickness for paired burned unburned sites measured from 2001–2023. NSF Arctic Data Center (2024). URL <https://doi.org/10.18739/A2RN3092P>.
- [55] Pohl, E. *et al.* Thermo-hydrological observatory in a permafrost river valley landscape in Syrdakh, Central Yakutia. Zenodo (2026). URL <https://doi.org/10.5281/zenodo.19890671>.
- [56] Makarieva, O., Nesterova, N., Lebedeva, L. & Sushansky, S. Thaw depth and snow height time series at different sites within Kolyma Water-Balance Station (KWBS), 1954–1997. PANGAEA (2017). URL <https://doi.org/10.1594/PANGAEA.881754>.
- [57] Liang, M. *et al.* Thaw depth of tree mounds from northeastern Siberia (S4). PANGAEA (2023). URL <https://doi.org/10.1594/PANGAEA.961876>.

- [58] Walker, D. A. *et al.* (Table 20) Thaw depth of active layer at transects and relevés sampled along the Yamal Transect, 2007–2008. PANGAEA (2009). URL <https://doi.org/10.1594/PANGAEA.842711>.
- [59] Scheer, J. *et al.* Mapping the frost susceptibility of the ground from thaw-season InSAR surface displacements and extrapolated active layer thicknesses, Ilulissat, West-Greenland. PANGAEA (2024). URL <https://doi.org/10.1594/PANGAEA.964306>.
- [60] Martin, J. *et al.* T-MOSAiC 2021 myThaw data set. PANGAEA (2023). URL <https://doi.org/10.1594/PANGAEA.956039>.
- [61] Boike, J. *et al.* T-MOSAiC 2022 myThaw data set. PANGAEA (2024). URL <https://doi.org/10.1594/PANGAEA.971586>.
- [62] Hammar, J. *et al.* 2023 myThaw data set. PANGAEA (2025). URL <https://doi.org/10.1594/PANGAEA.974461>.
- [63] Zastruzny, S., Elberling, B., Jensen, K. H., Sjöberg, Y. & Liu, Y. Field data from Disko Island for thermal-hydrological investigations. PANGAEA (2024). URL <https://doi.org/10.1594/PANGAEA.967139>.
- [64] Sannel, A. B. K. Ground temperature, thaw depth and snow depth in a permafrost peatland in Tavvavuoma, northern Sweden, version 1. Bolin Centre Database (2020). URL <https://doi.org/10.17043/sannel-2020-temperature-1>.
- [65] Fu, Z. Permafrost ground temperature and active layer thickness data on the Qinghai-Tibet Plateau (2001–2020). figshare (2025). URL <https://doi.org/10.6084/m9.figshare.29206613.v1>.
- [66] Whitcomb, J. *et al.* Maps of active layer thickness in northern Alaska by upscaling P-band polarimetric synthetic aperture radar retrievals. *Environ. Res. Lett.* **19**, 014046 (2024).
- [67] Pekel, J.-F., Cottam, A., Gorelick, N. & Belward, A. S. High-resolution mapping of global surface water and its long-term changes. *Nature* **540**, 418–422 (2016).

감사의 글

[DECISION: Acknowledgements, Author contributions, Competing interests 문구] 자료 가용성에 적은 자료 제공처에 감사한다. 활동층 두께 공변량은 ESA Climate Change Initiative Permafrost_cci 과제의 자료를 썼다. 지형 공변량은 Copernicus WorldDEM-30 © DLR e.V. 2010–2014 와 © Airbus Defence and Space GmbH 2014–2018 로 만들었으며, 이 자료는 유럽연합과 ESA 가 COPERNICUS 로 제공하고 모든 권리는 보유자에게 있다. [미확인: Copernicus DEM 사용 허가가 요구하는 귀속 문구의 원문 대조] [미확인: ERA5-Land(Copernicus Climate Change Service) 사용 허가가 요구하는 귀속 문구] [DECISION: KPDC 자료, SI 포함 여부와 식별자, 이용 조건] [DECISION: 대회 보고서 인용 여부] [DECISION: 연구비 지원 기관과 과제 번호, 또는 지원 없음]

저자 기여

[DECISION: Acknowledgements, Author contributions, Competing interests 문구] [DECISION: 저자, 소속, 교신 저자]

추가 정보

이해 상충: [DECISION: Acknowledgements, Author contributions, Competing interests 문구]
교신과 자료 요청은 [DECISION: 저자, 소속, 교신 저자] 에게 한다.

그림 설명

그림 1. 연구 지역, Stefan 계수, 평가 설계. (a) 약관이 확인된 라벨 표의 라벨 셀을 0.5° 블록으로 모았다. 원의 면적은 블록 안 1 km 라벨 위치 수에 비례하고, New regions 는 라벨 표를 고정한 뒤 더한 지역이다 (러시아 중부 확충판; 티베트 고원은 삽도; 표 1). 음영은 연속 영구동토 (영구동토 비율 $\geq 90\%$) 와 불연속 영구동토 (50–90%) 다 (ESA CCI Permafrost fraction v4.0, 1997–2021 년 평균). 사각형은 c 와 d 의 범위이다. (b) 지역 별 라벨 셀의 Stefan 계수 $E = ALT/\sqrt{TDD}$ (로그 축). ALT 는 활동층 두께, TDD 는 ERA5-Land²⁷ 기온 융해 지수다 ($^\circ\text{C d}$, 2015–2020 년 평균). 지역마다 최대 400 셀과 중앙값, 사분위 범위를 보이며, Source coefficient 는 그 지역을 학습에서 뺐을 때 원천 풀에서 맞춘 계수다. (c) 지역 홀드아웃. 레나델타의 라벨 셀과 그로부터 100 km 안의 모든 셀 (Buffer) 을 학습 자료에서 뺐다. (d) 같은 지역을 라벨 블록과 채점 블록으로 나눈 분할 (5 개 가운데 하나) 과 라벨 블록에서 뽑은 라벨 셀 40 개. 오차는 채점 블록에서만 잔다. 지역 내 시험은 원천 자료 없이 같은 블록 분할을 쓰며, 전이 결과를 본 뒤 설계하였다. (e) 무작위 셀부터 지역 홀드아웃까지의 검증에서 RMSE 를 채점 셀에서 가장 가까운 학습 셀까지의 거리 중앙값에 대해 그렸다 (선은 3 지역 평균, 기호는 셀 가중 95% 구간을 붙인 지역 값, 속이 빈 기호는 원천 계수 Stefan). 무작위 셀 분할에서 kNNDM 분할로 가면 직접 ML 의 RMSE 는 5.76 cm, 8.17 cm, 14.20 cm, 재보정 Stefan 의 RMSE 는 0.29 cm, 0.51 cm, 4.28 cm 늘었다 (알래스카, 레나델타, 캐나다; 셀 가중; 서술, 앞선 결과를 본 뒤 설계). 약관이 확인되지 않은 셀 (캐나다 38, 북대서양 19, 러시아 서부 1) 은 그리지 않았다. 북극 평사 투영 (중심 경도 127°E), 축척 막대는 70°N 기준이며, c 와 d 도 같은 투영이다. 티베트 고원 삽도는 Lambert 방위 정적 투영이고 축척 막대가 따로 있다. 해안선은 Natural Earth 50 m(c 와 d 는 10 m), Cartopy 0.23.

그림 2. 라벨 10 개에서 Stefan 재보정은 4 지역 평균 오차를 낮추었고, 잔차 ML 의 추가 차이는 확인하지 못했다. 오차 변화는 학습에서 뺐 각 지역의 채점 블록에서 한 방법의 평균 제공근 오차 (RMSE) 에서 원천 계수 Stefan 식 (0 선) 의 RMSE 를 뺐 값이며, 음수는 오차가 낮다는 뜻이다. Recalibrated Stefan 은 대상 라벨 n 개로 계수 E 를 다시 맞추되 원천 계수 쪽으로 수축하고 ($\kappa = 10$), Anchor + residual ML 은 가중 0.25 의 CatBoost 잔차를 더하며, Direct ML 은 물리 앵커 없는 CatBoost 이고, Year-matched Stefan 은 라벨 연도의 융해 도일을 쓴다. (a) 주 4 지역 (레나델타, 캐나다, 러시아 서부, 러시아 동부) 평균, 라벨 10 개까지. (b) 후보 라벨이 40 개 이상인 레나델타와 캐나다의 평균. All 은 모든 라벨이며, Year-matched Stefan 은 점 추정이다. (c–f) 지역별. 후보 풀보다 큰 라벨 수 (러시아 서부·동부 14–17 셀, 캐나다 325–406 셀) 는 가렸고, 패널 e 는 세로 범위가 따로다 (-12.5 cm 까지). 선은 분할 5 개의 셀 가중 평균이고, 띠는 재보정 기반 두 방법의 95% 블록 부트스트랩 신뢰구간 (CI) 이다 (패널 a, b 의 구성 고정 평균은 재표집 10,000 회, 패널 c–f 는 1000 회). 라벨 10 개에서 재보정은 4 지역 RMSE 를 2.5 cm 낮추었고 (95% CI [1.9, 3.0] cm, Holm 보정 $P = 0.001$), 오차가 낮아진 곳은 러시아 서부뿐이었으며 (12.0 cm, 95% CI [10.5, 13.6] cm), 캐나다에서는 오차가 높아졌다 (2.3 cm, 95% CI [0.7, 2.9] cm). 잔차를 더하면 RMSE 가 -0.18 cm 달라졌다 (95% CI $[-0.53, -0.01]\text{ cm}$, 보정 전 $P = 0.034$, Holm 보정 $P = 0.136$). 그린 모든 대비의 판정은 보충 표 S2 에 있다. 라벨 격자 분석은 내부 사전 등록하였고 한 계산 플랫폼에서 실행하였다.

그림 3. 물리 유사라벨은 섞은 유사라벨보다 오차를 낮추었고, 더 나은 결합 구조는 라벨 수에 따라 달랐다. (a) 러시아 서부 라벨 셀 31 개로 그린 개념도. 융해 도일 제공근에 대한 활동층 두께와, 원천 계수 Stefan 직선 (Source Stefan, $1.59\text{ cm } (^\circ\text{C d})^{-1/2}$), 뽑은 라벨 10 개로 재보정한 직선 (Recalibrated Stefan, 2.11), 잔차 ML 이 학습하는 그 라벨들의 편차 (Residual) 를 보인다. 두께는 아래로 갈수록 커진다. (b) 물리 유사라벨로 학습한 직접 ML 에서 위약 유사라벨로 학습한 같은 모델을 뺐 값, 4 지역 평균, 라벨 0 개와 10 개. (c) 잔차 구조에서 물리 입력 구조를 뺐 값을 라벨 수에 대해 그렸다. 입력 집합은 두 가지다 (Physics inputs 는 두 물리 모델의 출력, Recalibrated inputs 는 원천 계수와 재보정 Stefan 예측). 범례는 등록 라벨 수 (0 과 10) 와 보조 라벨 수를 구분하며, 라벨 40 개와 160 개의 값은 레나델타와 캐나다의 평균이다. (d) Stefan 계수의 현지 최소제곱 재보정에서 수축 재보정을 뺐 값 (서술; 양수는 수축이 유리), 라벨 10 개까지는 4 지역 평균, 그 위는 레나델타와 캐나다 평균. 구간은 95% 블록 부트스트랩 신뢰구간 (CI; 0.5° 채점 블록 재표집 10,000 회) 이며, 범례에 표시한 대로 셀 가중과 블록 등가중이다 (패널 d 는 셀 가중). 회색 띠는 $\pm 0.5\text{ cm}$ 다. 패널 b 에서 물리 유사라벨은 섞은 유사라벨보다 라벨 0 개의 오차를 1.6 cm 낮추었고 (95% CI [1.0, 2.0] cm, Holm 보정 $P = 0.001$), 선

형 용해 지수 유사라벨과의 차이는 라벨 0 개에서 0.48 cm, 라벨 10 개에서 ± 0.5 cm 안이었다. 패널 c 에서 라벨 10 개까지 잔차 구조의 오차는 두 가중 모두에서 2.5–3.7 cm 낮았고 (라벨 10 개의 물리 입력에서 Holm 보정 $P = 0.001$), 라벨 40 개와 160 개에서는 물리 입력 구조의 오차가 1.9–2.4 cm 낮았으며 이 차이는 캐나다에서 왔다 (대비 4 개 가운데 1 개는 분할 독립 가정에 의존). 위약과 결합 구조 분석은 내부 사전 등록하였다.

그림 4. 라벨을 쓰는 보정의 오차 감소는 라벨 10 개로 전 원천 계수 편향과 순위상관을 보였다. (a) 재보정이 원천 계수 Stefan 식보다 오차를 낮춘 (Recalibration) 시험 라벨 수의 최솟값 n^* 와, 잔차 ML 이 재보정 모델보다 오차를 낮춘 (Residual ML) n^* (앞 격자 값부터의 구간). 판정은 등록된 세 조건을 따른다 (방법). Not reached 는 시험한 가장 큰 라벨 수까지 n^* 가 없는 대상이다. 행은 b 의 라벨 10 개 편향 순서이며, 하위 지역은 독립이 아니다. (b) 대상 라벨 안 교차검증으로 고른 방법의 오차 변화 (라벨 전량, 원천 계수 Stefan 식 기준) 를 처음 라벨 10 개에서 그 모델이 보인 평균 편향의 절댓값에 대해 그렸다 (Spearman $\rho = 0.38$, 95% CI [0.17, 0.55], 28 대상; 부호 있는 편향은 $\rho = -0.01$). 티베트 고원은 축 밖에 있으며 (편향 227.7 cm; 오차 변화는 b 에서 -159.6 cm, d 에서 -135.7 cm 와 -5.9 cm), 북대서양은 점 추정이다. (c) 교차검증 선정에서 고정 잔차 레시피 ($\lambda = 0.25$) 를 뺀 값. 선정은 레나델타와 캐나다 평균의 라벨 40 개와 160 개에서 비열등이었고 (한계 0.5 cm), 라벨 160 개에서 오차가 1.3 cm 낮았다. 라벨 40 개의 0.87 cm 감소와 라벨 전량의 비열등은 분할 독립 가정에 의존하며, 라벨 10 개에서는 비열등이 성립하지 않았다. 이득은 캐나다에서 왔고 (2.1 cm 와 2.7 cm), 레나델타의 변화는 +0.35 cm 와 +0.07 cm 였다. (d) 라벨 전량에서 재보정의 오차 변화와, 더 나은 재보정 Stefan 식을 넘어선 잔차 ML 의 오차 변화를 같은 편향에 대해 그렸다. 편향과 재보정 오차 감소의 관계 ($\rho = 0.37$, 95% CI [-0.11, 0.93]) 와 재보정을 넘어선 감소의 관계 ($\rho = 0.28$, [-0.19, 0.80]; 대상 고정 구간 [0.18, 0.54]) 는 확인하지 못했다 (사후 분석). 구간은 0.5° 채점 블록 (d 에서는 대상 계열도) 을 10,000 회 재표집한 95% 신뢰구간 (CI) 이며, 범례에 표시한 대로 가중한다. 회색 띠는 ± 0.5 cm 다. b 와 c 의 분석은 앞선 결과를 본 뒤 설계하였다.

그림 5. 라벨을 블록과 공변량 공간에 흩어 놓으면 캐나다에서는 무작위 셀보다 오차가 낮았고 레나델타에서는 그렇지 않았다. (a–c) 캐나다 라벨 100 개를 지도 위에 적은 세 배치 절차로 한 번 뽑은 결과 (지역 내 시험, 분할 1; 방법). 작은 점은 라벨 블록의 후보 셀이고, 원의 면적은 지점마다 고른 라벨 수에 비례한다 (40 km 보다 가까운 블록은 합침). 지도는 절차를 보여 줄 뿐 지점의 순위를 매기지 않는다. (d) Anchor + residual ML (잔차 가중 0.25) 의 무작위 셀 대비 오차 변화를 캐나다, 레나델타, 알래스카 안의 라벨 수에 대해 그렸다. (e) 같은 대비를 전이에서 라벨 10 개와 40 개로 본 것. 구간은 95% 블록 부트스트랩 신뢰구간 (CI; 0.5° 채점 블록 재표집 10,000 회, 라벨 추출 조건부) 이며, 범례에 표시한 대로 셀 가중과 블록 등가중이다. 회색 띠는 ± 0.5 cm 다. 패널 d 에서 두 분산 전략은 캐나다의 라벨 50 개와 100 개에서 오차를 2.5–3.2 cm, 라벨 200 개에서 1.3–1.4 cm 낮추었다. 레나델타에서 블록 층화의 오차 변화는 라벨 20–500 개에서 +1.5 cm 부터 +2.0 cm 까지였고, 라벨 100 개에서는 두 가중 모두 오차가 높았다 (+1.7 cm; 분할 독립 가정에 의존). 알래스카의 라벨 50–200 개에서는 두 가중의 판정이 엇갈렸다 (블록 등가중 -1.1 cm 부터 -1.7 cm 까지, 셀 가중 +0.28 cm 부터 +0.74 cm 까지). 분산 기반 능동 선정은 알래스카와 레나델타의 라벨 50–200 개에서 오차가 0.69–2.8 cm 높았고 (대비 6 개 가운데 1 개는 분할 독립 가정에 의존), 캐나다에서는 흩어 놓기보다 이득이 작았다. 패널 e 에서 공변량 분산은 캐나다의 라벨 40 개에서 오차를 2.4 cm 낮추었다 (95% CI [0.5, 3.4] cm; 분할 독립 가정에 의존). 라벨 10 개에서는 두 가중 모두에서 오차가 높아진 지역이 없었으나, 레나델타 블록 층화의 셀 가중 구간은 0 보다 위에 있었다 (+1.9 cm). 배치 시험은 앞선 결과를 본 뒤 설계하고 실행 전에 등록하였다. 캐나다 중심의 평사 투영, 축척 막대는 패널 a. 해안선은 Natural Earth 50 m, Cartopy [미확인: 판].

그림 6. 대상 라벨이 없을 때 2 cm 넘게 손해를 본 대상은 30 개 가운데 물리 유사라벨에서 2 개, 직접 ML 에서 18 개였다. (a, b) 각 대상의 라벨 셀 중심에서 직접 ML(a) 과 물리 유사라벨을 쓴 직접 ML(b) 의 원천 계수 Stefan 식 대비 오차 변화 (대상 17 개; 원천에서 상위 지역을 뺀). -40 cm 보다 작은 값은 끝 색으로 칠한다 (a 의 티베트 고원, -60.0 cm). 알래스카 대상은 확대하였고, 레나델타 대상은 지시선으로 옮겨 그렸다. 제목의 개수는 대상 30 개에 대한 사후 집계다 (지역 안 하위 지역과 라벨 확충판 3 개를 더함; 점 추정 문턱). (c) 학습 기별 직접 ML 과 두 물리 기준선, 4 지역 평균. 랜덤 포레스트, 물리 모델 입력을 받는 CatBoost, 원천 지역 하나 제외 교차검증으로 설정한 신경망 4 종은 오차가 높았다 (2.4–5.2 cm). 주 CatBoost 학습기 (2.2 cm, 95% CI [1.1, 3.4] cm, Holm 보정 $P = 0.023$) 를 포함한 나머지 학습기 5 종도 주 구간에서 오차가 높았고, 이는

분할 독립 가정에 의존한다. Year-matched Stefan 은 오차가 1.0 cm 낮았고, 이것도 같은 가정에 의존한다. Anchor ensemble 은 척도 보정 Stefan, Kudryavtsev, ESA CCI 앵커의 평균이다. 기존 ALT 지도 (등록 이 탈; 앞선 결과를 본 뒤 설계; 제품 학습 지점 5 km 블록 제거): CCI v5 는 오차가 높았고 (+23.79 cm, 95% CI [15.34, 30.16], 화살표), Wei v2(레나델타와 캐나다; 절측 대체 47.4%) 는 차이를 확인하지 못했다. (d) 라벨이 없을 때 구간 척도 다섯 가지에서 90% 예측 구간의 포함률을 평균 폭에 대해 그렸다. 4 지역 평균 (95% 부트스트랩 구간, 재표집 1000 회) 과 지역 값이며, 겹쳐 적은 이름은 거의 같은 두 평균이고 위쪽이 포함률이 높다. 선 은 명목 0.90 이다. (e) 라벨 40 개와 160 개에서 잔차 모델 구간의 포함률을 라벨 0 개 대비 폭에 대해 그렸다. 띠 는 0.85–0.95 다. c 와 e 의 구간은 95% 블록 부트스트랩 신뢰구간 (CI; 0.5° 채점 블록 재표집 10,000 회) 이며, c 는 셀 가중과 블록 등가중이다 (범례). ± 0.5 cm 띠는 동등 한계다. 북극 평사 투영 (중심 경도 127° E; 알래스카 확대도 157° W), 축척 막대는 70° N 기준. 티베트 고원 삽도는 Lambert 방위 정적 투영. 영구동토 구역은 ESA CCI Permafrost fraction v4.0(1997–2021 년 평균), 해안선은 Natural Earth 50 m, Cartopy 0.23.0.

그림 7. 알래스카 안에서 재보정 Stefan 식에 대한 잔차 ML 의 이득은 1 cm 미만이었고, 기후 격자 규모의 편향 보정에서 왔다. (a) 지역 내 시험 (0.5° 블록의 절반을 채점, 분할 25 개). 같은 라벨로 재보정한 Stefan 식 대비 Anchor + residual ML(교차검증 잔차 가중) 과 Direct ML 의 오차 변화. Error floor 는 공변량 조건부 하한 (알래스카 11.31 cm, 레나델타 14.83 cm, 캐나다 17.90 cm) 에서 재보정 Stefan RMSE 를 뺀 값이며, 캐나다 선 (−10.6 cm 부터 −10.8 cm 까지) 은 축 아래에 있다. 알래스카의 라벨 1000 개에서 잔차 모델은 오차가 0.54 cm 낮았다. 라벨 500 개와 전량의 감소 (0.39 cm 와 0.52 cm) 는 공통 재표집 구간에서 유지되지 않았다. 레나델타와 캐나다에서는 차이를 확인하지 못했다. (b) 알래스카, 라벨 전량. 채점 블록별 오차 변화 (분할 25 개 합산) 와 라벨 위치 343 곳. 채점 셀이 10 개 미만인 블록은 가렸다. (c) ERA5-Land 기후 셀 사이와 안으로 나눈 오차 변화. 알래스카에서 오차 제곱 감소의 약 99% 는 셀 사이 성분에서 왔고 (−1.03 cm; 셀 안 −0.01 cm), 3 지역 평균에서는 셀 안 예측이 오차를 0.09 cm 키웠다. (d) 라벨 구간별 권장 방법. 원천 계수 Stefan 식 대비 오차 변화, 레나델타와 캐나다 전이 풀 (점 추정의 2 지역 평균; 라벨 320 개와 1000 개는 시험하지 않음). 아래에는 배치와 진단 단계를 적었다. 라벨 40 개부터의 선정은 고정 레시피에 대한 비열등에 근거한다 (그림 4c). (e) 같은 지역을 다시 무작위로 나눈 분할에서 워크플로 (d; 배치는 무작위 추출로 바뀜) 를 무작위 배치와 고정 레시피 (−0.86 cm, −0.93 cm; 라벨 40 개, 160 개), 재보정 Stefan 식 (+0.08 cm, −1.35 cm, −1.51 cm; 라벨 10 개, 40 개, 160 개) 과 비교하였다. 기호는 재보정 Stefan 식보다 0.5 cm 넘게 나쁜 지역이다. 앞선 결과를 본 뒤 설계, 재사용 지역의 재검정, 비맹검 부분 포함. 구간은 95% 블록 부트스트랩 신뢰구간 (CI; 0.5° 채점 블록 재표집 10,000 회) 이며, 셀 가중과 블록 등가중이다 (범례). ± 0.5 cm 띠는 동등 한계다. 패널 a–d 는 전이 결과를 본 뒤 설계하였다. 알래스카 중심의 평사 투영, 축척 막대는 70° N 기준. 해안선은 Natural Earth 50 m, Cartopy 0.23.0.

표 설명

표 1. 대상 지역, 라벨, 자료원. Labels 는 라벨 행 수이고, 1 km locations 는 0.009° 셀 색인으로 행을 묶은 위치 수이며, 0.5° blocks 는 라벨과 채점 분할의 단위다. Splits 는 전이 설계의 유효 블록 분할 수이고, E_0 는 그 지역을 학습에서 뺐을 때 원천 풀에서 맞춘 Stefan 계수 ($\text{cm } (^\circ\text{C d})^{-1/2}$) 이며, Alaska share of source cells 는 원천 셀 가운데 알래스카에 있는 비율이다. 주 지역은 앞선 실험에 쓰였고 여기서 재검정하며, 알래스카는 주 지역과 평균하지 않는 참조 대상이고, 새 지역은 라벨 표를 고정한 뒤에 더하였다 (약관 확인판). 하위 지역, 점 추정만 있는 대상, 북대서양 묶음은 보충 표 S1 에 있다. 이용 조건은 자료 가용성에 적었다.

표 1. 대상 지역, 라벨, 자료원. 표 본체는 영문판과 같은 생성 파일 (Table1_data.tex) 이며 열 이름은 표 설명에 풀이하였다.

Region	Label source	Labels	1 km locations	0.5° blocks	Splits	Source coefficient E_0 (cm per $\sqrt{(^{\circ}\text{C d})}$)	Alaska share of source cells (%)
<i>Main regions</i>							
Lena Delta	Points (ALLena)	3037	201	20	5	1.62	94
Canada	Points (ABoVE)	750	86	39	5	1.59	81
W Russia	CALM site means	31	29	21	5	1.59	78
E Russia	CALM site means	30	30	21	5	1.59	78
<i>Reference</i>							
Alaska	Points (ABoVE)	13,606	343	74	5	1.50	0
<i>New regions</i>							
Central Russia (expanded)	1 km cell means	57	57	13	5	1.59	78
Tibetan Plateau	1 km cell means	132	132	34	5	1.59	78




그림 1




그림 2




그림 3







그림 4




그림 5




그림 6




그림 7