물리 잔차 기반 기계학습 워크플로를 활용한 영구동토 활동층 두께 예측과 지역별 편차 분석

백승원[1*] and [공저자] [극지연구소][2]

[1*] 에너지시스템공학부, 서울대학교, 서울, 대한민국.
[2] 극지연구소, 인천, 대한민국.

*Corresponding author(s). E-mail(s): [교신 저자 전자우편];

초록

활동층 두께 (ALT) 는 해마다 달라지지만, 기존 1 km ALT 제품은 대부분 여러 해의 조건에 맞춰 만들어졌고 같은 셀·같은 해의 관측과 비교된 적이 드물다. 이 연구는 알래스카, 레나 델타, 캐나다 북서부의 셀-연도 ALT 관측 19,172 개 (2010–2024 년) 를 모으고, 각 관측에 관측 연도의 ERA5-Land 융해 도일을 관측일까지 누적한 값을 대응시켰다. 이 자료로 Stefan 모델, 직접 기계학습 (ML), 그리고 재보정한 Stefan 모델의 잔차를 gradient boosting 으로 학습하는 물리 잔차 워크플로를 비교하였다. 공간 블록 교차검증에서 물리 잔차 모델은 Stefan 모델의 오차를 레나 델타에서 3.6 cm, 캐나다에서 3.7 cm 줄였고 알래스카에서는 같은 수준이었다. 한 지역을 학습에서 뺀 시험에서 레나 델타의 직접 ML 오차는 17.8 cm 늘었으나, 물리 잔차 모델은 Stefan 모델 수준을 유지하였다. 레나 델타에서는 그 지역 라벨 25 개로 정확도가 회복되었고, 외부 영구동토 관측 지역에서는 라벨 5 개로 오차가 56.2 cm 에서 40.3 cm 로 낮아졌다. 같은 셀·같은 해 비교에서 레나 델타의 오차 (21.1 cm) 는 공개 제품 5 종 (28.4–34.6 cm) 보다 낮았다. 이 워크플로는 2011–2024 년의 연도별 1 km 지도를 산출한다.

핵심어: 영구동토, 활동층 두께, Stefan 모델, 물리 기반 기계학습, 공간 교차검증, ERA5-Land

서론

활동층은 영구동토 위에서 여름에 녹고 겨울에 다시 어는 지층이다. 활동층 두께 (ALT) 는 계절 융해의 깊이, 기반 시설의 안정성, 분해에 노출되는 토양 탄소의 양을 정한다[1–3]. ALT 는 여름 열량에 따라 해마다 달라지며, CALM(Circumpolar Active Layer Monitoring) 같은 관측망이 기록하는 것도 이 연도별 변화이다[4,5]. 그러나 관측은 드물

고 고르지 않다. 대부분의 측정은 소수의 집중 관측과 장기 격자에서 나오고, 한 번만 방문한 지점이 많다[6,7].

북반구 영구동토 지역에는 1 km ALT 제품이 여러 개 있다. ESA CCI Permafrost 같은 과정 기반 추정은 위성 지표 온도로 열전도 모델을 구동한다[8,9]. 통계·기계학습 (ML) 제품은 지점 관측과 기후·지형·토양 공변량의 관계를 학습한다[10–13]. 이 제품들은 대개 여러 해의 평균 조건이나 여러 해의 지점 관측을 합쳐 학습하고, 서로 다른 지점 집합과 검증 방식으로 평가된다. 따라서 제품 값을 특정 셀·특정 해의 관측과 바로 비교할 수 없고, 같은 셀에서도 제품 간 차이가 수십 cm 에 이른다. 검증 설계도 불확실성을 더한다. 공간적으로 모인 관측에 무작위 교차검증을 쓰면 새 장소에 대한 ML 모델의 정확도가 과대평가된다[14–17].

물리 모델은 다른 접근을 제공한다. Stefan 해 $\mathrm{ALT} = E\sqrt{\mathrm{TDD}}$ 는 융해 깊이를 그 계절의 융해 도일 (TDD) 과 하나의 계수 E 로 잇는다. E 는 토양의 열적 성질과 수분에 따라 정해진다[18,19]. 이 식은 계절 융해의 진행을 재현하고 해마다의 기후에 반응하지만, 지역마다 계수 하나를 쓰면 토양 유기탄소와 지형에 따라 체계적인 잔차가 남는다. 물리 모델이 주된 반응을 맡고 ML 이 물리 모델이 놓친 부분을 학습하는 결합은 여러 환경 예측에서 정확도를 높였다[20]. ALT 에서도 알래스카를 대상으로 과정 기반 추정과 ML 을 결합한 연구가 있다[21]. 그러나 입력 기후를 관측 연도와 맞췄을 때, 라벨이 없는 지역으로 옮겼을 때 이런 결합이 어떻게 작동하는지, 새 지역에 라벨이 몇 개 필요한지는 밝혀지지 않았다.

이 연구는 셀-연도 설계로 이 질문들을 다룬다. 모든 ALT 관측은 특정 해의 1 km 셀이고, 모든 기후 입력은 그 해의 ERA5-Land 자료로 관측일까지 누적해 계산한다[22]. 알래스카, 레나 델타, 캐나다 북서부의 2010–2024 년 셀-연도 관측 19,172 개로 Stefan 모델, 직접 ML, 재보정한 Stefan 모델의 잔차를 gradient boosting 으로 학습하는 물리 잔차 워크플로를 비교하였다. 모델은 다섯 가지 검증 설계, 지역 안·지역 간 라벨 수 사다리, 외부 영구동토 관측 지역, 같은 셀·같은 해의 공개 제품 6 종과의 비교로 평가하였다. 결과로 (1) 관측 연도 기후 입력의 효과, (2) 물리 잔차 모델의 Stefan 모델 대비 이득과 그 조건, (3) 새 지역에 필요한 라벨 수, (4) 공개 제품과의 차이를 보고하고, 2011–2024 년의 연도별 1 km 지도를 제시한다.

결과

관측 자료와 관측 연도 기후 입력

라벨은 알래스카 15,540 개 셀-연도 (13,253 개 셀, 2010–2024 년), 레나 델타 2,436 개 (2,206 개 셀, 2010–2022 년), 캐나다 북서부 1,196 개 (730 개 셀, 2010–2019 년과 2021–2024 년) 이다 (그림 1a,b, 표 1). 관측 연도는 고르지 않다. 알래스카 셀-연도의 51% 가 2014 년에 관측되었고, 레나 델타 라벨은 13 개 해에 퍼져 있다. 관측은 대부분 8 월, 융해가 끝나기 전에 이루어졌다 (보충 그림 S1; 관측일 중앙값 알래스카 224, 레나 델타 234, 캐나다 237 번째 날). 따라서 관측일까지 누적한 융해 도일은 계절 전체 값보다 작고, 그 비의 중앙값은 0.73, 0.81, 0.89 이다 (그림 1d). 이 연구의 모든 모델은 2010–2024 년 ERA5-Land 월자료에서 관측 연도의 기후를 관측일까지 누적해 입력으로 쓴다. 대조 입력은 같은 변수의 2011–2024 년 평균이며, 기존 제품의 다년 입력에 해당한다 (그림 1c,d). 물리 잔차 워크플로, 비교한 네 모델 구조, 다섯 검증 설계는 그림 2 에 정리하였다.

평년 기후 입력을 관측 연도 기후 입력으로 바꾸면 레나 델타에서 재보정 Stefan 모델 (-1.4 [-2.6, -0.8] cm) 과 물리 잔차 모델 (-1.6 [-2.4, -1.0] cm) 의 공간 블록 오

차가, 캐나다에서 물리 잔차 모델의 오차 (−1.5 [−2.0, −0.4] cm) 가 줄었다 (그림 3a). 알래스카에서는 변화를 판정할 수 없었다 (Stefan +1.8 [−0.1, +3.9] cm). 라벨 대부분이 한 해에 몰려 있어 관측 연도 입력이 공간 분포 이상의 정보를 거의 더하지 못하기 때문이다. 관측 연도 입력은 연도가 명시된 지도의 전제이기도 하다. 모든 예측이 명시된 해의 기후를 가리킨다.

검증 설계와 학습에서 뺀 지역으로의 전이

방법의 순위는 검증 설계에 따라 달랐다 (그림 3b). 셀 단위 무작위 교차검증에서 직접 ML 의 오차가 가장 낮았고 (알래스카 11.8 cm), 0.5° 블록의 공간 블록 교차검증에서는 직접 ML 의 오차가 알래스카 5.4, 레나 델타 3.6, 캐나다 9.9 cm 커졌다. 연도 전체를 빼면 라벨이 여러 해에 퍼진 레나 델타에서 직접 ML 의 오차가 15.9 cm 에서 20.2 cm 로 커졌고, 블록과 연도를 함께 빼는 설계는 세 지역 모두에서 모든 방법의 지역 안 오차가 가장 컸다. 한 지역 전체를 빼고 다른 두 지역으로 학습하면 레나 델타에서 직접 ML 의 오차가 39.3 cm 로 커졌고, 다른 지역의 계수를 쓴 Stefan 모델은 21.5 cm 였다 (차이 +17.8 [+8.0, +23.9] cm). 같은 시험에서 물리 잔차 모델은 Stefan 모델 수준을 유지하였고 (+2.0 [−0.8, +3.4] cm), 캐나다에서는 Stefan 모델보다 나았다 (−3.5 [−5.1, −0.1] cm). 이하에서는 공간 블록 교차검증을 주 설계로, 지역 홀드아웃을 전이 시험으로 쓴다.

물리 잔차 모델의 이득과 조건

관측 연도 입력과 2010–2024 년 라벨로 공간 블록 교차검증을 하면, 물리 잔차 모델은 재보정 Stefan 모델의 오차를 레나 델타에서 21.0 cm 에서 17.4 cm 로 (−3.6 [−7.8, −0.8] cm), 캐나다에서 30.6 cm 에서 26.9 cm 로 (−3.7 [−4.8, −0.8] cm) 줄였다. 알래스카에서는 두 모델이 약 18.4 cm 로 같았다 (−0.2 [−0.6, +0.1] cm). 이 이득에는 지형과 토양 공변량이 필요하였다 (그림 3c). 기후 공변량만 쓰면 잔차 모델은 알래스카 (+5.9 [−0.3, +14.2] cm) 와 캐나다 (+3.9 [−5.1, +10.3] cm) 에서 Stefan 모델을 개선하지 못하였고, 지형과 토양을 더해야 위의 이득이 생겼다. MODIS 식생·적설 시기 (2010–2024 년) 나 고해상 토양·피복 분류를 더한 효과는 레나 델타와 캐나다에서 0.5 cm 미만이었고, 알래스카에서는 고해상 토양·피복 분류가 작은 이득을 더하였다 (−0.8 [−1.4, −0.2] cm).

물리 정보가 들어가는 위치도 결과를 바꾸었다 (보충 그림 S2). Stefan 모델의 유사 라벨을 학습 자료에 더하면 Stefan 모델을 재현하는 데 그쳤고 (레나 델타 −0.3 [−0.4, −0.1] cm), Stefan 예측을 입력으로 쓰면 직접 ML 과 비슷하였다. 지역 안 라벨을 모두 쓰면 레나 델타에서 직접 ML 의 점추정 오차가 물리 잔차 모델보다 낮았지만 (15.9 cm 대 17.4 cm), 레나 델타와 알래스카에서 Stefan 대비 구간이 0 을 포함하였고 지역 홀드아웃에서는 크게 나빠졌다. CatBoost 대신 랜덤 포레스트, 다층 퍼셉트론, TabM, FT-Transformer 를 써도 레나 델타와 캐나다에서 물리 잔차 이득의 부호는 바뀌지 않았다.

여덟 공변량의 지역 안 3 분위로 나누면, 이득은 레나 델타 (23 개 3 분위 가운데 19 개에서 구간이 0 제외) 와 캐나다 (23 개 가운데 17 개) 의 대부분 조건에서 나타났고, Stefan 모델의 오차가 큰 조건일수록 컸다. 3 분위 간 Stefan 오차와 이득의 상관은 레나 델타 −0.99, 캐나다 −0.79 였다 (그림 3d). 레나 델타의 가장 따뜻한 TDD 3 분위에서 이득은 −6.2 [−12.0, −0.7] cm 였다. 알래스카에서는 어느 3 분위도 0.9 cm 를 넘게 바뀌지 않았다. 따라서 잔차 모델은 토양과 지형 때문에 계수가 지역 값에서 벗어나는

곳에서 Stefan 계수를 보정하는 역할을 한다. 입력 기여도 이와 맞는다. 잔차 모델의 평균 절대 SHAP 값 가운데 지형이 레나 델타에서 50%, 토양이 캐나다에서 39% 를 차지하였다 (보충 그림 S3).

적은 라벨과 새 지역

라벨 수 사다리는 라벨이 적을 때의 거동을 보여 준다 (그림 4a). 한 지역의 2010–2024 년 셀-연도에서 학습 라벨 25 개를 뽑으면, 물리 잔차 모델은 같은 라벨로 재보정한 Stefan 모델과 같거나 나았고 (알래스카 −0.9 [−1.9, +0.1], 레나 델타 −0.8 [−2.2, −0.1], 캐나다 −0.3 [−3.2, +1.7] cm), 라벨 100 개에서는 세 지역 모두에서 이득의 구간이 0 을 제외하였다 (−0.7 [−1.4, −0.0], −2.0 [−5.3, −0.3], −1.9 [−3.7, −0.3] cm). 라벨 25 개의 직접 ML 은 알래스카 (+2.8 [−0.3, +4.5] cm) 와 캐나다 (+1.2 [−1.5, +3.4] cm) 에서 Stefan 보다 점추정 오차가 컸다.

전이 실험에서는 다른 두 지역의 라벨과 대상 지역 라벨 n 개로 학습한 모델로 대상 지역을 예측하였다 (그림 4b). 대상 라벨이 없을 때 레나 델타에서 직접 ML 은 39.5 cm, 원천 계수 Stefan 모델은 21.5 cm 였다. 대상 라벨 25 개를 더하면 물리 잔차 모델은 19.9 cm, 직접 ML 은 21.3 cm 로 낮아졌다. 알래스카에서는 물리 잔차 모델이 모든 n 에서 가장 낮았다 (대상 라벨 0 개에서 17.8 cm). 캐나다에서는 원천 지역으로 학습한 직접 ML 이 가장 정확하였고 (24.2 cm), 캐나다 라벨 25 개로 Stefan 계수를 다시 맞추면 오차가 27.7 cm 에서 31.3 cm 로 커졌고, 이 기준값을 쓰는 물리 잔차 모델도 24.3 cm 에서 26.3 cm 로 커졌다. 캐나다 지점들의 융해 깊이 범위가 넓기 때문이다.

같은 절차를 모델 개발에 쓰지 않은 외부 CALM 지역 8 곳 (73 개 셀, 2010–2024 년 관측) 에 적용하였다 (그림 4c, 보충 그림 S4). Wei 등, Liu 등, ESA CCI v5 값이 모두 있는 7 개 지역 474 개 셀-연도에서, 세 연구 지역으로 학습한 물리 잔차 모델은 지역 라벨 없이 56.2 cm 였다. 같은 외부 지역의 라벨 5 개를 더하면 40.3 cm, 25 개를 더하면 39.7 cm 로 낮아졌고, 직접 ML 은 라벨 25 개에서 47.5 cm 였다. 라벨 5 개에서 물리 잔차 모델은 ALT 관측으로 학습하지 않은 ESA CCI v5(60.7 cm) 보다 낮았다 (차이 −19.5 [−31.3, −9.2] cm). Wei 등과 Liu 등은 이 지점들을 학습 자료로 썼으며 18.0 cm 와 23.2 cm 였다. 이득의 대부분은 Stefan 계수의 재보정에서 나왔고, 잔차 모델은 이 지점들에서 추가 이득을 내지 않았다 (라벨 5 개에서 +0.4 [−0.5, +1.2] cm). 서·중부 시베리아와 스발바르의 융해 깊이가 연구 지역의 범위를 넘기 때문이다.

같은 셀·같은 해의 공개 제품 비교

제품과 모델은 Wei 등, Liu 등, ESA CCI v4 가 모두 관측 연도 값을 가진 셀-연도에서 비교하였고, 이 조건으로 비교 기간은 2010–2020 년이다 (그림 5a). 레나 델타에서 물리 잔차 모델은 21.1 cm 로, ESA CCI v5(28.4 cm), Aalto 등 (30.6 cm), ESA CCI v4(31.0 cm), Liu 등 (33.0 cm), Wei 등 (34.6 cm) 보다 낮았다. 제품 학습 지점에서 25 km 넘게 떨어진 셀에서 짝지은 차이는 Wei 등 대비 −12.5 [−15.6, −5.8] cm, ESA CCI v5 대비 −5.0 [−9.5, −2.5] cm 였다. 알래스카 (17.1 cm 대 17.9 ·18.8 cm) 와 캐나다 (25.8 cm 대 27.0 ·27.9 cm) 에서는 모델과 두 ML 제품이 같은 수준이었다.

지역 간 차이는 제품의 학습 자료와 대응한다. 알래스카 라벨 셀은 Wei 등의 학습 지점에서 중앙값 7 km 떨어져 있고, Liu 등은 같은 알래스카·캐나다 현장 자료의 이전 판으로 학습하였다. 레나 델타 셀은 중앙값 107 km 떨어져 있고 (보충 그림 S5), 두 제품 모두 델타 북부의 얇은 활동층을 과대 추정한다 (북위 72° 이북 평균 편향 +21.1 cm

와 +19.9 cm). 레나 델타 라벨 없이 학습한 모델도 같은 셀-연도에서 이미 Wei 등보다 정확하였다 (26.0 cm 대 30.3 cm, −4.3 [−6.1, −0.8] cm).

연도별로 보면 물리 잔차 모델은 셀-연도 30 개 이상인 레나 델타의 6 개 해 (2013–2017 년과 2020 년) 모두에서 Wei 등과 Stefan 보다 오차가 낮았고, 알래스카 (2010–2022 년) 에서는 13 개 해 가운데 Wei 등 대비 7 개 해, Stefan 대비 9 개 해, 캐나다에서는 8 개 해 가운데 Stefan 대비 7 개 해에서 낮았다 (그림 5b). 여러 해 관측된 알래스카 셀에서 관측과 예측의 연도 간 변화 상관은 물리 잔차 모델 0.28, Wei 등 0.15, Liu 등 0.12 였다. 레나 델타에서는 제품이 연도 간 변화를 더 잘 따랐다 (0.55 와 0.42 대 0.29).

잔차 모델은 제품 위에도 얹을 수 있다. 레나 델타 라벨로 Wei 등의 제품을 선형 재보정하고 같은 잔차 학습기를 더하면 재보정 제품 대비 오차가 −2.3 [−7.4, −0.4] cm 바뀌었고, Stefan 기준 모델은 이 제품 기준 모델보다 여전히 정확하였다 (−2.8 [−6.2, −0.1] cm, 보충 그림 S6). 알래스카와 캐나다에서는 두 기준의 차이를 판정할 수 없었다.

연도가 명시된 1 km 지도

알래스카와 레나 델타의 모든 셀-연도로 학습한 물리 잔차 모델을 2011–2024 년 각 해의 ERA5-Land 기후로 1 km 격자에 적용하였다 (그림 6). 격자는 ESA CCI 영구동토 확률 50% 이상인 셀이다 (알래스카 858,517 개, 레나 델타 38,086 개). 2011–2024 년 평균 대비 지역 평균 편차는 알래스카에서 2012 년 −3.2 cm 부터 2019 년 +7.1 cm 까지, 레나 델타에서 2017 년 −9.4 cm 부터 2020 년 +10.0 cm 까지였고, 공간 분포도 해마다 달랐다 (그림 6b). 레나 델타에서 관측 셀의 평균 편차는 셀-연도 50 개 이상인 10 개 해 (2012–2021 년) 가운데 8 개 해에서 예측 지역 편차와 부호가 같았다 ($r = 0.75$). 해마다 관측 셀 구성이 바뀌는 알래스카에서는 일치가 약했고 ($r = 0.25$), 예측의 연도 간 범위 (10.2 cm) 가 관측 셀의 범위 (17.7 cm) 보다 작았다 (그림 6c). 적용 가능 영역 안의 셀은 알래스카 56%, 레나 델타 62% 이고, 90% 예측 구간의 반폭은 25.5 cm 와 24.5 cm 이다. 적용 가능 영역 밖의 셀은 주로 산지와 영구동토 지대의 남쪽 가장자리이며 지도에 표시하였다 (보충 그림 S7). 보충 그림 S8 은 알래스카 2014 년과 레나 델타 2016 년의 우리 지도와 Wei 등·Liu 등의 지도를 비교하고, 보충 그림 S9 는 잔차 모델이 Stefan 모델에 더하는 보정량을 보여 준다.

고찰

이 연구는 라벨, 기후 입력, 채점이 같은 셀·같은 해를 가리키는 셀-연도 설계로 ALT 모델을 평가하였다. 결과는 세 가지로 정리된다. 첫째, 관측 연도의 기후를 관측일까지 누적해 입력하면, Stefan 잔차를 학습하는 gradient boosting 모델이 Stefan 모델의 오차를 레나 델타에서 3.6 cm, 캐나다에서 3.7 cm 줄였고 알래스카에서는 같은 수준이었다. 둘째, 같은 모델은 한 지역을 학습에서 빼거나 라벨이 몇 개뿐일 때도 안정적이었고, 직접 ML 은 학습에서 뺀 레나 델타에서 실패하였으며 더 많은 라벨이 필요하였다. 셋째, 같은 셀·같은 해 비교에서 이 모델은 레나 델타에서 공개 제품 5 종보다 정확하였고, 알래스카와 캐나다에서는 두 ML 제품과 같은 수준이었다.

물리 잔차 구조가 작동하는 이유는 두 부분이 서로 다른 정보를 맡기 때문이다. Stefan 항은 해마다의 융해기 기후에 대한 반응을 맡고, 물리적으로 제한된 형태로 새 지역과 새 해에 외삽된다. 잔차 모델은 토양과 지형 때문에 생기는 지역 계수의 편차를 보정한다. 이득에는 지형과 토양 공변량이 필요하였고, Stefan 오차가 가장 큰 조건에서 가장 컸으며, 잔차 모델의 기여 분석은 레나 델타에서 지형, 캐나다에서 토양 유기탄소를 가리켰다. Stefan 유사라벨을 더하면 학습기가 Stefan 모델 쪽으로 끌려가 정확

도가 늘지 않았고, 기후 반응을 라벨에서 직접 배워야 하는 직접 ML 은 학습에서 뺀 레나 델타에서 정확도를 17.8 cm 잃었다. 한 지역의 라벨을 모두 쓰면 직접 ML 도 잔차 모델과 비슷하거나 낮은 점추정 오차에 이를 수 있다. 잔차 구조의 장점은 그 정확도가 같은 지역의 많은 라벨에 의존하지 않는다는 점이다.

기존 제품이 보고한 정확도는 서로 다른 지점 집합과 검증 방식에 따른 값이어서 (예: Liu 등의 무작위 10 겹 RMSE 21.6 cm[12], Wei 등의 지점 하나 제외 RMSE 60.5 cm[13]) 서로 비교할 수 없다. 모델과 제품을 같은 셀·같은 해에서 채점하면 이 모호함이 없어진다. 이 비교에서 나타난 지역 차이는 제품의 학습 자료와 대응한다. Wei 등과 Liu 등은 알래스카 라벨 셀에서 몇 km 안에 있는 CALM, GTN-P, ABoVE 관측으로 학습하였고, 알래스카와 캐나다에서 우리 모델과 같은 정확도를 보였다. 레나 델타는 Wei 등의 가장 가까운 학습 지점에서 약 107 km 떨어져 있고, 두 제품 모두 이곳의 얇은 활동층을 과대 추정한다. 레나 델타 라벨 없이 학습한 모델도 이곳에서 이미 Wei 등보다 정확하였고, 레나 델타 라벨을 쓰면 오차가 21.1 cm 로 낮아져 제품의 28.4–34.6 cm 보다 작았다. 잔차 학습기는 제품을 기준값으로 쓸 때에도 정확도를 높였다. 따라서 지역 라벨과 잔차 학습을 결합하면 Stefan 모델뿐 아니라 기존 제품도 그 제품이 학습하지 않은 지역에 맞춰 보정할 수 있다.

라벨 실험은 새 지역에 적용하는 순서를 제시한다. 지역 라벨이 없을 때는 직접 ML 이 실패할 수 있으므로 다른 지역 계수의 Stefan 모델이 더 안전한 출발점이다. 라벨이 25 개 정도 모이면 Stefan 계수를 다시 맞추고 잔차를 학습해 레나 델타의 정확도를 회복하였다. 외부 CALM 지역에서는 라벨 5 개로 오차가 56.2 cm 에서 40.3 cm 로 낮아져 ESA CCI v5 제품보다 작아졌다. 외부 지점은 전이의 한계도 보여 준다. 서·중부 시베리아와 스발바르의 융해 깊이는 연구 지역의 범위를 넘고, 그곳의 이득은 잔차 모델이 아니라 계수 재보정에서 나왔다. 캐나다는 반대의 경우로, 원천 지역으로 학습한 직접 ML 이 더 정확하였고 적은 캐나다 표본으로 다시 맞춘 계수는 오차를 키웠다. 따라서 필요한 지역 라벨 수는 새 지역이 학습 범위에서 얼마나 떨어져 있는지에 따라 달라지며, 연구 지역과 비슷한 지역에서는 토양과 지형 범위를 덮는 라벨 25–100 개가 적절한 목표이다.

연도가 명시된 지도는 이 설계의 두 번째 산출물이다. 각 지도는 명시된 해의 ERA5-Land 기후로 계산되므로 같은 해의 관측이나 다른 제품과 비교할 수 있고, 편차를 해마다 추적할 수 있다 (예: 알래스카 2019 년 +7.1 cm). 지도는 적용 가능 영역과 90% 예측 구간을 함께 제공하여 예측이 학습 조건을 벗어나는 셀을 표시한다. 예측의 연도 간 범위는 관측 셀 평균의 범위보다 작다 (장기 관측 셀은 보충 그림 S10). 관측 셀이 캠페인마다 바뀌고, 잔차 모델이 주로 공간 대비로 학습되기 때문이다.

한계는 다음과 같다. 알래스카 라벨의 절반이 2014 년 자료여서 그곳에서는 관측 연도 입력의 효과를 판정하지 못하였다. 레나 델타 라벨은 한 자료원의 16 개 블록에서 나와 구간이 넓다. 기후 입력은 월자료이고 토양 공변량은 정적이어서 짧은 기상 사건과 토양 수분 변화는 반영되지 않는다. 주로 산지와 영구동토 지대의 남쪽 가장자리에 있는 약 3 m 보다 두꺼운 활동층은 학습 범위 밖이다. 일 단위 기후 입력, 적설·토양 수분 정보, 그리고 CALM 과 집중 관측 자료가 함께 있는 서시베리아 같은 네 번째 지역의 라벨이 다음 단계이다.

요약하면, 지역 라벨로 재보정하고 잔차 학습기로 보정한 Stefan 모델은 토양과 지형이 중요한 곳에서 Stefan 모델보다 정확하고, 라벨이 없는 지역에서도 안정적이며, 적은 라벨로 적응하는 연도별 ALT 를 제공한다. 같은 셀·같은 해로 평가하면 이 모델은 제품이 학습하지 않은 지역에서 공개 제품보다 정확하고, 제품이 학습한 지역에서는 같은 수준이다. 같은 절차는 다른 영구동토 지역에 적용할 수 있고, 기존 제품을 기

준값으로 쓸 수도 있으며, 적용 가능 영역이 명시된 연도별 1 km 지도로 활동층 감시에 쓰일 수 있다.

방법

연구 지역과 ALT 라벨. ALT 관측은 공개 자료 세 가지에서 가져왔다. 알래스카와 캐나다 북서부는 ABoVE 토양 수분·활동층 두께 자료 v2[6] 에서 8–10 월 탐침 측정 가운데 $0 < \mathrm{ALT} < 300$ cm 인 값을 쓰고 (1–7 월 측정은 계절 초 융해 깊이로 보아 제외), CALM 계절 말 격자 값[5] 을 더하였다. 레나 델타는 ALLena 융해 깊이 자료[7] 에서 측정 한계 초과 표지가 없는 8–9 월 값을 쓰고, 위치·연도별 계절 최댓값을 취하였다. 관측은 1 km 셀에 배정해 셀·연도별로 평균하였고, 측정일의 평균 연중 일수를 보존하였다. 날짜가 없는 CALM 값은 244 번째 날 (9 월 1 일) 로 두었다. 연도별 기후 입력이 있는 2010–2024 년만 썼다. 라벨은 알래스카 15,540 개 셀-연도 (2010–2024 년), 레나 델타 2,436 개 (2010–2022 년), 캐나다 1,196 개 (2010–2019 년과 2021–2024 년) 이며, 0.5° 블록 73, 16, 26 개에 있다 (표 1). 4 개 해 이상 관측된 셀은 203, 25, 48 개이다.

관측 연도 기후 입력. 2010 년 1 월–2024 년 12 월 ERA5-Land 월자료[22](2 m 기온, 표층 토양 온도, 적설 수당량) 를 각 1 km 셀의 가장 가까운 육지 격자에서 추출하였다 (해안 셀은 0.5° 까지 대체). 각 셀과 연도 y 에 대해 기후 변수 여덟 개를 계산하였다. 연평균 기온, TDD(양의 월평균 기온 $\times$ 일수의 합), $\sqrt{\mathrm{TDD}}$, 가장 따뜻한 달의 평균 기온, 직전 겨울 (10 월 $y-1$–4 월 y) 의 동결 도일과 가장 추운 달의 평균 기온, 표층 토양 온도 평균, 수문년 (10 월 $y-1$–9 월 y) 적설 수당량 평균이다. 2010 년의 겨울 변수는 1–4 월만 쓴다. 주 입력 (관측 연도 기후 입력) 은 관측 연도의 월 누적 TDD 를 관측일까지 선형 보간해 누적한다. 같은 셀-연도에서 두 가지 대안을 함께 실행하였다. 관측 연도의 계절 전체 TDD, 그리고 연도별 값의 2011–2024 년 평균 (평년 기후 입력) 으로, 후자는 기존 제품의 다년 입력에 해당한다. 지도는 각 해의 계절 전체 TDD 를 쓴다 (계절 말 ALT).

정적 공변량. 지형 변수 (고도, 경사, 사면 방향의 사인·코사인, 지형 위치 지수, 거칠기) 는 30 m Copernicus DEM[23] 에서 각 셀 둘레 33×33 화소 창 (약 1 km) 으로 계산하였다. 토양 변수 (5–15 cm 의 점토, 모래, 실트, 용적 밀도, 조립질, pH 와 0–5, 5–15, 15–30 cm 의 토양 유기탄소) 는 250 m SoilGrids 2.0[24] 에서 추출하였다. 주 입력 묶음 (23 개) 은 기후 8 개, 지형 6 개, 토양 9 개이다. 민감도 묶음은 기후만, 기후와 지형, 주 묶음에 MODIS 여름 NDVI ·EVI 와 눈 소실 시기를 더한 묶음 (AppEEARS 로 받은 2010–2024 년 MOD13Q1 ·MOD10A2 v6.1[25,26]), 주 묶음에 고해상 토양 탄소·피복 분류를 더한 묶음[27], 전년 기후를 포함한 전체 변수이다. ESA CCI 영구동토 확률 (1997–2021 년 평균)[8] 은 모델 입력이 아니라 지도 범위 (확률 50% 이상) 를 정하는 데만 썼다.

공개 제품. 라벨 셀에서 제품 6 종을 추출하였다. Wei 등[13](1 km, 2000–2024 년), Liu 등[12](1 km, 2003–2020 년), ESA CCI Permafrost ALT v4(1997–2021 년) 와 v5(1997–2023 년)[8,9], Yi 와 Kimball[28](알래스카, 2001–2015 년), Aalto 등[10](2000–2014 년 기준기, 셀당 값 하나) 이다. 연도별 제품은 관측 연도의 값을 썼고, 라벨 셀에서 값이 있는 해는 Wei 등 2010–2024, Liu 등 2010–2020, CCI v4 2010–2021, CCI v5 2010–2023, Yi 와 Kimball 2010–2015 년이다. 제품은 비교 대상으로만 썼다. Wei 등은 학습 지점 좌표를 공개하였고, 각 라벨 셀에서 가장 가까운 학습 지점까지의 거리를 25 km 마스크에 썼다.

모델. Stefan 모델은 $\mathrm{ALT} = E\sqrt{\mathrm{TDD}}$ 이다[18]. 원천 계수 Stefan 모델은 다른 두 지역에서 최소제곱으로 맞춘 E 를, 재보정 Stefan 모델은 그 지역 학습 라벨로 맞춘 E 를 쓴다. 직접 ML 은 23 개 입력으로 CatBoost gradient boosting[29](반복 600, 학습률 0.03, 깊이 6, L2 정칙화 3) 을 학습한다. 물리 입력 ML 은 재보정 Stefan 과 Kudryavtsev[30] 예측을 입력에 더한다. 물리 유사라벨은 채점 겹 셀의 공변량과 학습 겹 Stefan 예측 (관측값 없음) 으로 만든 같은 수의 행을 학습 자료에 더한다. 물리 잔차 모델은 재보정 Stefan 예측 $\hat{y}_P$ 를 기준값으로 두고 잔차의 CatBoost 모델 g 를 더한다.

$$\hat{y} = E\sqrt{\mathrm{TDD}} + \lambda\, g(\mathbf{x}), \qquad g \approx y - \hat{y}_P \tag{1}$$

여기서 $\lambda = 0.5$ 이며, 0.25, 1, 내부 블록 교차검증으로 고른 값을 민감도로 실행하였다. 모든 학습 모델은 씨앗 3 개로 실행해 예측을 평균하였다. 학습기 민감도에서는 CatBoost 대신 랜덤 포레스트, 다층 퍼셉트론, TabM, FT-Transformer[31–33] 를 썼다. 잔차 모델과 직접 모델의 SHAP 값[34] 은 지역별 전체 라벨로 학습한 모델에서 CatBoost 구현으로 계산하였다.

검증 설계. 지역마다 다섯 가지 설계를 적용하였다[14,15]. 셀-연도 단위 무작위 5 겹, 0.5° 블록을 셀-연도 수가 고르게 겹에 배정한 공간 블록 5 겹 (주 설계), 셀-연도 20 개 이상인 각 관측 연도를 나머지 해로 학습한 모델로 채점하는 연도 홀드아웃, 채점 셀-연도의 블록 겹과 연도를 모두 학습에서 빼는 블록 × 연도, 시험 지역에서 100 km 안의 학습 셀을 뺀 뒤 다른 두 지역으로 학습한 모델로 채점하는 지역 홀드아웃이다. 지역 홀드아웃에서는 대상 라벨이 없으므로 재보정 Stefan 모델이 원천 계수 모델과 같다.

라벨 수 사다리, 전이, 외부 지역. 지역 안 사다리에서는 공간 블록 겹마다 학습 라벨을 $n = 25, 50, 100, 250, 500, 1000, 2500$ 개 또는 전량으로 줄이고 (무작위 3 회), 같은 n 개 라벨로 Stefan 계수를 다시 맞춘 뒤 시험 겹 전체를 채점하였다 (모든 모델 구조는 보충 그림 S11). 전이 사다리에서는 다른 두 지역의 라벨 전량과 대상 지역 학습 겹에서 뽑은 $n = 0, 25, 50, 100, 250, 500$ 개 라벨로 학습한 모델로 대상 지역의 공간 블록 겹을 채점하였다. Stefan 계수는 대상 라벨 n 개로 다시 맞추었고 ($n \geq 3$), 잔차 모델은 원천 행 (원천 계수 기준값) 과 대상 행 (다시 맞춘 기준값) 으로 학습하였다. 외부 시험에는 세 연구 지역과 산악 영구동토 (스위스, 카자흐스탄) 밖의 2010–2024 년 CALM 관측[5] 을 1 km 셀에 배정해 썼다. 검열값, 이른 측정·화재·침수·탐침 미도달 표지가 있는 값, 연구 라벨에서 100 km 안의 지점 (레나 델타의 사모일로프, 비코프스키) 을 빼고, 8 개 지역 (서·중부·북동 시베리아, 유럽 러시아, 추코트카, 캄차카, 스발바르, 그린란드) 의 73 개 셀 816 개 셀-연도를 남겼다. 기후 입력과 공변량은 같은 방법으로 계산하였다. 외부 지역마다 블록 하나씩 (블록이 하나인 그린란드는 셀 하나씩) 채점하였고, 세 연구 지역과 같은 외부 지역의 다른 블록에서 뽑은 라벨 $n = 0, 5, 10, 25, 50$ 개 또는 전량으로 학습하였다. 학습 범위 밖인 평균 ALT 약 6 m 의 스발바르 시추공 한 곳은 뺐다.

채점과 통계. 겹 밖 예측으로 RMSE, 편향, Pearson 상관을 계산하였다. 두 방법의 차이 ($\Delta\mathrm{RMSE}$ = 앞 방법의 RMSE − 뒤 방법의 RMSE) 는 같은 셀-연도에서 계산하고, 0.5° 블록을 2,000 회 (사다리는 1,000 회) 재추출한 부트스트랩으로 95% 신뢰 구간을 구하였다. 구간이 0 을 제외하면 차이가 판정된 것으로 쓴다. 이득의 조건은 공변량 여덟 개 (관측 연도의 계절 전체 TDD, 동결 도일, 적설 수당량, 토양 유기탄소, 점토, 경사, 고도, 여름 NDVI) 의 지역 안 3 분위에서 보았고, 셀-연도 30 개 또는 블록 5 개 미만인 3 분위는 채점하지 않았다. 연도별 RMSE 는 셀-연도 30 개 이상인 해에서, 관측과 예측의 연도 간 변화 상관은 여러 해 관측된 셀에서 계산하였다.

공개 제품 비교. 제품과 모델은 같은 셀-연도에서 비교하였다. 공통 셀 비교는 Wei 등, Liu 등, ESA CCI v4 가 모두 관측 연도 값을 가진 셀-연도 (2010–2020 년) 만 쓴다. 누설 마스크는 Wei 등의 학습 지점에서 25 km 안의 셀을 뺀다. Liu 등은 여기서 쓴 ABoVE 자료의 이전 판으로 학습하였으므로[12], 알래스카·캐나다 값은 우리 라벨과 독립이 아니다. 제품 기준 시험에서는 관측 연도의 제품 값을 학습 겹에서 선형 재보정하고 같은 잔차 학습기 ($\lambda = 0.5$) 로 같은 블록 겹에서 보정하였다.

연도별 지도, 적용 가능 영역, 예측 구간. 알래스카와 레나 델타에서 재보정 Stefan 모델과 물리 잔차 모델을 지역의 모든 셀-연도로 학습하고, ESA CCI 영구동토 확률 50% 이상인 1 km 셀 (858,517 개, 38,086 개) 에 2011–2024 년 각 해의 계절 전체 기후로 적용하였다. 적용 가능 영역은 Meyer 와 Pebesma[35] 를 따라 정하였다. 23 개 입력의 표준화 공간 (2011–2024 년 평균 기후) 에서 가장 가까운 학습 행까지의 거리가, 각 학습 행에서 다른 블록의 가장 가까운 학습 행까지 거리의 95 번째 백분위수를 넘지 않으면 지도 셀을 영역 안으로 본다. 90% 예측 구간은 공간 블록 겹 밖 잔차의 5 번째와 95 번째 백분위수로 정하였다. 표시용으로 1 km 값을 250 m 음영 격자에 쌍선형 보간하였다.

계산. 모델 학습은 씨앗을 고정해 96 코어 클라우드 CPU 노드 (Rescale) 에서, 자료 준비·집계·그림은 로컬 서버에서 실행하였다. 실행 목록은 보충 표 S6 에 있다.

대형 언어 모델 사용. 코드 개발, 그림 스크립트 작성, 문장 다듬기에 대형 언어 모델 (Claude, Anthropic) 의 도움을 받았다. 모든 분석, 수치, 문장은 저자가 확인하였고, 원고의 모든 수치는 저장된 결과 표에서 생성된다. [저자 확인 필요.]

코드 가용성. 자료 준비, 모델링, 평가, 그림 코드는 [저장소·DOI] 에서 받을 수 있다. 본문의 모든 수치는 원고 매크로를 만드는 스크립트가 결과 표에서 생성한다.

자료 가용성. 모든 입력 자료는 공개 자료이다. ALT 관측: ABoVE 토양 수분·활동층 두께 v2(ORNL DAAC, https://doi.org/10.3334/ORNLDAAC/2369), ALLena 융해 깊이 자료 (PANGAEA, https://doi.org/10.1594/PANGAEA.973813), GTN-P CALM(PANGAEA, https://doi.org/10.1594/PANGAEA.972777). 기후: ERA5-Land 월평균 (Copernicus Climate Data Store). 공변량: Copernicus DEM GLO-30, SoilGrids 2.0, ESA CCI 영구동토 확률, MODIS MOD13Q1 ·MOD10A2 v6.1(AppEEARS). 제품: Wei 등 (https://doi.org/10.5281/zenodo.21667583), Liu 등 (https://doi.org/10.5281/zenodo.10070610), ESA CCI ALT v4 ·v5(CEDA), Aalto 등 (https://zenodo.org/records/5003804), Yi 와 Kimball(https://doi.org/10.3334/ORNLDAAC/1760). 셀-연도 라벨 표, 연도별 기후 입력 표, 정적 공변량 표, 모든 방법의 겹 밖 예측, 알래스카·레나 델타의 연도별 1 km 지도 (2011–2024 년) 는 게재 시 공개 저장소에 둔다 [저장소·DOI].

참고문헌

[1] Hjort, J. *et al.* Degrading permafrost puts Arctic infrastructure at risk by mid-century. *Nature Communications* **9**, 5147 (2018).

[2] Schuur, E. A. G., McGuire, A. D., Schädel, C. *et al.* Climate change and the permafrost carbon feedback. *Nature* **520**, 171–179 (2015).

[3] Biskaborn, B. K. *et al.* Permafrost is warming at a global scale. *Nat. Commun.* **10**, 264 (2019).

[4] Nelson, F. E. *et al.* Estimating active-layer thickness over a large region: Kuparuk River basin, Alaska, U.S.A. *Arct. Alp. Res.* **29**, 367–378 (1997).

[5] Streletskiy, D. A. *et al.* GTN-P CALM: 35 years of Active Layer Thickness (ALT) across latitudinal and elevational gradients in the Northern Hemisphere. PANGAEA (2025). URL https://doi.org/10.1594/PANGAEA.972777.

[6] Moore, M. A. *et al.* ABoVE: Soil moisture and active layer thickness in Alaska, USA and Canada, 2005–2024, version 2. ORNL Distributed Active Archive Center (2025). URL https://doi.org/10.3334/ORNLDAAC/2369.

[7] Veremeeva, A. *et al.* ALLena: Thaw depth measurements of the active layer in the Lena River Delta region from 1998 to 2022, Northeastern Siberia. PANGAEA (2025). URL https://doi.org/10.1594/PANGAEA.973813.

[8] Westermann, S. *et al.* ESA Permafrost Climate Change Initiative (Permafrost_cci): Permafrost active layer thickness for the Northern Hemisphere, v4.0. NERC EDS Centre for Environmental Data Analysis (2024). URL https://doi.org/10.5285/d34330ce3f604e368c06d76de1987ce5.

[9] Westermann, S. *et al.* ESA Permafrost Climate Change Initiative (Permafrost_cci): Permafrost active layer thickness for the Northern Hemisphere, v5.0. NERC EDS Centre for Environmental Data Analysis (2025).

[10] Aalto, J., Karjalainen, O., Hjort, J. & Luoto, M. Statistical forecasting of current and future circum-Arctic ground temperatures and active layer thickness. *Geophys. Res. Lett.* **45**, 4889–4898 (2018).

[11] Ran, Y. *et al.* New high-resolution estimates of the permafrost thermal state and hydrothermal conditions over the Northern Hemisphere. *Earth Syst. Sci. Data* **14**, 865–884 (2022).

[12] Liu, Y. *et al.* A 1 km annual active layer thickness dataset for the Northern Hemisphere permafrost region, 2003–2020. *Environmental Research Letters* **19** (2024). Fields to verify before submission.

[13] Wei, Y., Wu, Z., Wang, J. *et al.* A 1 km resolution dataset of Northern Hemisphere permafrost active layer thickness (2000–2024). *Earth System Science Data Discussions* (2026).

[14] Roberts, D. R. *et al.* Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography* **40**, 913–929 (2017).

[15] Ploton, P. *et al.* Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nat. Commun.* **11**, 4540 (2020).

[16] Meyer, H. & Pebesma, E. Machine learning-based global maps of ecological variables and the challenge of assessing them. *Nature Communications* **13**, 2208 (2022).

[17] Wadoux, A. M. J.-C., Heuvelink, G. B. M., de Bruin, S. & Brus, D. J. Spatial cross-validation is not the right way to evaluate map accuracy. *Ecol. Model.* **457**, 109692 (2021).

[18] Stefan, J. Über die Theorie der Eisbildung, insbesondere über die Eisbildung im Polarmeere. *Annalen der Physik* **278**, 269–286 (1891).

[19] Riseborough, D., Shiklomanov, N., Etzelmüller, B., Gruber, S. & Marchenko, S. Recent advances in permafrost modelling. *Permafrost and Periglacial Processes* **19**, 137–156 (2008).

[20] Willard, J., Jia, X., Xu, S., Steinbach, M. & Kumar, V. Integrating scientific knowledge with machine learning for engineering and environmental systems. *ACM Comput. Surv.* **55**, 66 (2022).

[21] Gautam, S., Mishra, U., Scott, S. N. & Lara, M. J. Machine learning and process-based modeling of spatiotemporal changes in active layer thickness across Alaska. *Sci. Rep.* **15**, 42420 (2025).

[22] Muñoz-Sabater, J. *et al.* ERA5-Land: a state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data* **13**, 4349–4383 (2021).

[23] European Space Agency. Copernicus global digital elevation model (GLO-30). Distributed by OpenTopography (2021).

[24] Poggio, L. *et al.* SoilGrids 2.0: producing soil information for the globe with quantified spatial uncertainty. *SOIL* **7**, 217–240 (2021).

[25] Didan, K. MODIS/Terra vegetation indices 16-day L3 global 250m SIN grid V061. NASA EOSDIS Land Processes DAAC (2021).

[26] Hall, D. K. & Riggs, G. A. MODIS/Terra snow cover 8-day L3 global 500m SIN grid, version 61. NASA National Snow and Ice Data Center DAAC (2021).

[27] Palmtag, J. *et al.* Detailed pedon data on soil carbon and nitrogen for the northern permafrost region, version 1. Bolin Centre Database (2022). URL https://doi.org/10.17043/palmtag-2022-pedon-1.

[28] Yi, Y. & Kimball, J. S. ABoVE: Active layer thickness from remote sensing permafrost model, Alaska, 2001–2015. ORNL DAAC, Oak Ridge, Tennessee, USA (2019).

[29] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. & Gulin, A. CatBoost: unbiased boosting with categorical features. *Advances in Neural*

Information Processing Systems **31**, 6639–6649 (2018).

[30] Kudryavtsev, V. A., Garagula, L. S., Kondrat'yeva, K. A. & Melamed, V. G. *Osnovy Merzlotnogo Prognoza [Fundamentals of Frost Forecasting in Geological Engineering Investigations]* (Moscow State University, 1974). In Russian. English translation: CRREL Draft Translation 606, US Army Cold Regions Research and Engineering Laboratory, Hanover, NH, 1977.

[31] Gorishniy, Y., Rubachev, I., Khrulkov, V. & Babenko, A. Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems* **34**, 18932–18943 (2021).

[32] Gorishniy, Y., Kotelnikov, A. & Babenko, A. TabM: advancing tabular deep learning with parameter-efficient ensembling. *International Conference on Learning Representations* (2025).

[33] Holzmüller, D., Grinsztajn, L. & Steinwart, I. Better by default: strong pre-tuned MLPs and boosted trees on tabular data. *Advances in Neural Information Processing Systems* **37** (2024).

[34] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*, Vol. 30, 4765–4774 (2017).

[35] Meyer, H. & Pebesma, E. Predicting into unknown space? Estimating the area of applicability of spatial prediction models. *Methods in Ecology and Evolution* **12**, 1620–1633 (2021).

감사의 글. [연구비·감사의 글.]

저자 기여. 백승원은 연구를 설계하고 자료를 구축하였으며 실험을 수행하고 원고를 작성하였다. [공저자 기여.]

추가 정보. **보충 자료** 보충 방법, 보충 그림 S1–S11, 보충 표 S1–S6 을 함께 제공한다.
이해 상충 저자들은 이해 상충이 없음을 밝힌다.

그림 설명

그림 1. ALT 관측, 입력 자료와 그 기간. (a) ESA CCI 영구동토 확률 (1997–2021 년 평균) 과 세 연구 지역, 2010–2024 년 ALT 라벨이 있는 1 km 셀 수. (b) 지역별 관측 연도당 셀-연도 라벨 수 (2010–2024 년). (c) 자료 기간: 지역별 라벨, 관측 연도 기후 입력에 쓴 ERA5-Land 월자료 (2010–2024 년), 정적 공변량 (연도 없음), 공개 제품 6 종의 제공 기간 (옅은 띠) 과 라벨 셀에서 비교에 쓴 연도 (진한 띠). 회색 음영은 분석 기간 2010–2024 년이다. (d) 2014 년 알래스카 CALM 셀 하나 (북위 71.3°, 서경 156.6°) 에서의 기후 입력 정의: ERA5-Land 누적 융해 도일 (TDD), 관측일까지 누적한 값 (학습·채점에 쓰는 관측 연도 입력; 날짜가 없는 CALM 계절 말 값의 관례인 9 월 1 일), 같은 해의 계절 전체 값 (지도에 사용), 2011–2024 년 평균 (평년 기후 입력).

그림 2. 물리 잔차 워크플로와 검증 설계. (a) 물리 잔차 모델의 구조. 2014 년 알래스카 입력을 예로 들었다. 관측 연도 기후 변수와 정적 지형·토양 공변량이 재보정 Stefan 모델 ($\mathrm{ALT} = E\sqrt{\mathrm{TDD}}$) 잔차의 gradient boosting 모델에 들어가고, 관측 ALT 는 학습에만 쓴다 (파선). 출력은 Stefan 추정값에 잔차의 $\lambda = 0.5$ 배를 더한 값과 적용 가능 영역 (2011–2024 년 평균 기후로 계산) 이다. (b) 비교한 네 구조: 직접 ML, 물리 입력 ML(Stefan ·Kudryavtsev 예측을 입력으로), 물리 유사라벨 (Stefan 예측으로 학습 자료 증강), 물리 + 잔차 ML. (c) 레나 델타 라벨 셀 (2010–2022 년) 에 표시한 다섯 검증 설계: 무작위, 공간 블록 (0.5°), 연도 홀드아웃, 블록 × 연도, 지역 홀드아웃 (알래스카·캐나다로 학습). 설계마다 예시 겹 하나를 표시하였고, 셀-연도 가운데 하나라도 시험 겹에 있으면 시험 셀 (검정) 로 그렸다.

그림 3. 관측 연도 기후 입력, 검증 설계, 잔차 이득의 조건. 모든 패널은 2010–2024 년 셀-연도 라벨과 겹 밖 예측을 쓴다. (a) 평년 기후 입력 (2011–2024 년 평균, 빈 표식) 과 관측 연도 기후 입력 (관측일까지 누적, 채운 표식) 의 공간 블록 RMSE. 재보정 Stefan 모델, 물리 잔차 모델, 직접 ML. 이 패널에서만 빈 표식과 채운 표식이 기후 입력을 뜻한다. (b) 다섯 검증 설계의 RMSE. 원천 계수 Stefan, 재보정 Stefan, 물리 잔차 모델, 직접 ML. 연도 홀드아웃과 블록 × 연도는 셀-연도 20 개 이상인 해를 쓰고, 지역 홀드아웃에서는 두 Stefan 모델이 같으며, 축 밖 값은 숫자로 적었다. (c) 공변량 묶음 여섯 가지에서 물리 잔차 모델과 재보정 Stefan 모델의 공간 블록 RMSE 차이. (d) 여덟 공변량의 지역 안 3 분위에서의 같은 차이. 검은 테두리는 95% 구간이 0 을 제외하는 칸, 빗금은 셀-연도 30 개 또는 블록 5 개 미만인 칸이며, 0.0 은 차이가 0.05 cm 미만임을 뜻한다. (a), (c), (d) 의 막대와 구간은 0.5° 블록 2,000 회 재추출의 95% 부트스트랩 구간이고, 음수는 물리 잔차 모델이 낫다는 뜻이다.

그림 4. 적은 라벨과 새 지역에서의 정확도. (a) 지역 안 라벨 수 사다리: 2010–2024 년 셀-연도에서 뽑은 같은 n 개 학습 라벨 (3 회 추출) 로 재보정한 Stefan 모델 대비 공간 블록 RMSE 차이. 띠는 물리 잔차 모델의 95% 블록 부트스트랩 구간이다. (b) 새 지역 전이: 다른 두 지역과 대상 지역 라벨 n 개로 학습한 모델의 대상 지역 공간 블록 겹 RMSE. (c) 외부 CALM 지역 (연구 지역 밖 2010–2024 년 관측): 같은 외부 지역에서 더한 라벨 수에 따른 RMSE. Wei 등, Liu 등, ESA CCI v5 값이 모두 있는 7 개 지역 474 개 셀-연도 (2010–2020 년) 에서 계산하였다. 굵고 옅은 선은 같은 라벨로 재보정한 Stefan 모델로 물리 잔차 모델과 거의 겹친다. 가로선은 제품이며, Wei 등과 Liu 등은 이 지점들로 학습하였고 ESA CCI v5 는 ALT 관측으로 학습하지 않았다.

그림 5. 같은 셀·같은 해의 공개 제품 비교. (a) Wei 등, Liu 등, ESA CCI v4 가 모두 관측 연도 값을 가진 셀-연도 (2010–2020 년) 에서 세 방법 (공간 블록 겹 밖 예측) 과 제품 5 종의 RMSE. 채운 표식은 모든 공통 셀-연도, 빈 표식은 Wei 등의 학습 지점

에서 25 km 넘게 떨어진 셀만 쓴 값이며, ESA CCI v5 와 Aalto 등은 공통 셀-연도 가운데 그 제품 값이 있는 셀-연도에서 채점하였고, 축 밖 값은 숫자로 적었다. (b) 관측 연도별 RMSE. 해마다 같은 셀-연도에서 물리 잔차 모델, 재보정 Stefan 모델, Wei 등, Liu 등 (2020 년까지) 을 계산하였고, 셀-연도 30 개 이상인 해 (알래스카 2010–2022 년, 레나 델타 2013–2017 년과 2020 년, 캐나다 2013 년, 2017–2019 년과 2021–2024 년) 만 표시하였다. 회색 막대는 해마다의 셀-연도 수 (로그 축) 이다.

그림 6. 연도가 명시된 1 km 지도. (a) 알래스카 물리 잔차 모델의 2011–2024 년 평균 ALT. 연도별 지도의 평균이며, 각 연도 지도는 그 해의 계절 전체 ERA5-Land 기후로 계산하였다. 점은 라벨 셀, 옅은 색은 적용 가능 영역 밖의 셀, 회색 육지는 지도 범위 밖 (ESA CCI 영구동토 확률 50% 미만, 물, 입력 결측) 이다. (b) 2011–2024 년 각 해의 평균 대비 편차. 모든 해에 같은 색 범위 (±15 cm) 를 쓴다. (c) 알래스카와 레나 델타의 예측 지역 평균 편차 (선, 2011–2024 년) 와 셀-연도 50 개 이상인 해의 관측 셀 평균 편차 (원; 알래스카 2011–2022 년, 레나 델타 2012–2021 년). 1 km 값은 표시용으로 250 m 에 보간하였다.

표 1 자료와 사용 연도. 위: 지역별 ALT 라벨 (관측 연도 기후 입력이 있는 2010–2024 년 셀-연도). 아래: 입력 자료와 제품의 제공 기간과 이 연구에서 쓴 연도. 블록은 공간 교차검증과 부트스트랩에 쓰는 0.5° 칸이며, 캐나다는 2020 년 라벨이 없다.

지역	셀-연도	셀	블록	연도	4 개 해 이상 셀	최다 연도
알래스카	15,540	13,253	73	2010–2024	203	2014 (51%)
레나 델타	2,436	2,206	16	2010–2022	25	2016 (28%)
캐나다 북서부	1,196	730	26	2010–2024	48	2022 (37%)
외부 CALM 지역	816	73	50	2010–2024	–	–

자료	해상도	제공 기간	사용 연도	역할
ERA5-Land 월평균[22]	0.1°	1950 년부터	2010–2024 년, 평균 2011–2024 년	기후 입력
Copernicus DEM[23]	30 m	정적	–	지형
SoilGrids 2.0[24]	250 m	정적	–	토양
MODIS MOD13Q1, MOD10A2[25,26]	250–500 m	2000 년부터	2010–2024 년	민감도 시험
ESA CCI 영구동토 확률[8]	1 km	1997–2021 년	평균	지도 범위
Wei 등[13]	1 km	2000–2024 년	2010–2024 년	비교
Liu 등[12]	1 km	2003–2020 년	2010–2020 년	비교
ESA CCI ALT v4[8]	1 km	1997–2021 년	2010–2021 년	비교
ESA CCI ALT v5[9]	1 km	1997–2023 년	2010–2023 년	비교
Yi 와 Kimball[28]	1 km	2001–2015 년	2010–2015 년 (알래스카)	비교
Aalto 등[10]	30″	2000–2014 년	시간 불변	비교

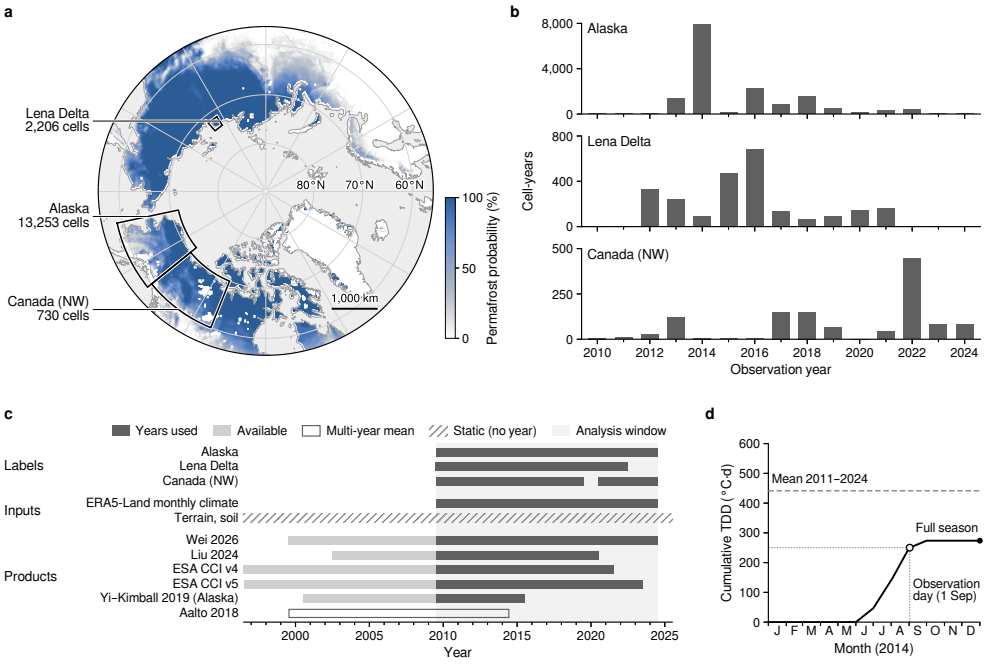

a
Lena Delta
2,206 cells
Alaska
13,253 cells
Canada (NW)
730 cells
80°N
70°N
60°N
1,000 km
100
50
0
Permafrost probability (%)
b
Alaska
Lena Delta
Canada (NW)
Cell-years
8,000
4,000
800
400
500
250
2010
2012
2014
2016
2018
2020
2022
2024
Observation year
c
Years used
Available
Multi-year mean
Static (no year)
Analysis window
Labels
Alaska
Lena Delta
Canada (NW)
Inputs
ERA5-Land monthly climate
Terrain, soil
Products
Wei 2026
Liu 2024
ESA CCI v4
ESA CCI v5
Yi–Kimball 2019 (Alaska)
Aalto 2018
2000
2005
2010
2015
2020
2025
Year
d
Cumulative TDD (°C·d)
600
500
400
300
200
100
0
Mean 2011–2024
Full season
Observation
day (1 Sep)
J F M A M J J A S O N D
Month (2014)

그림 1

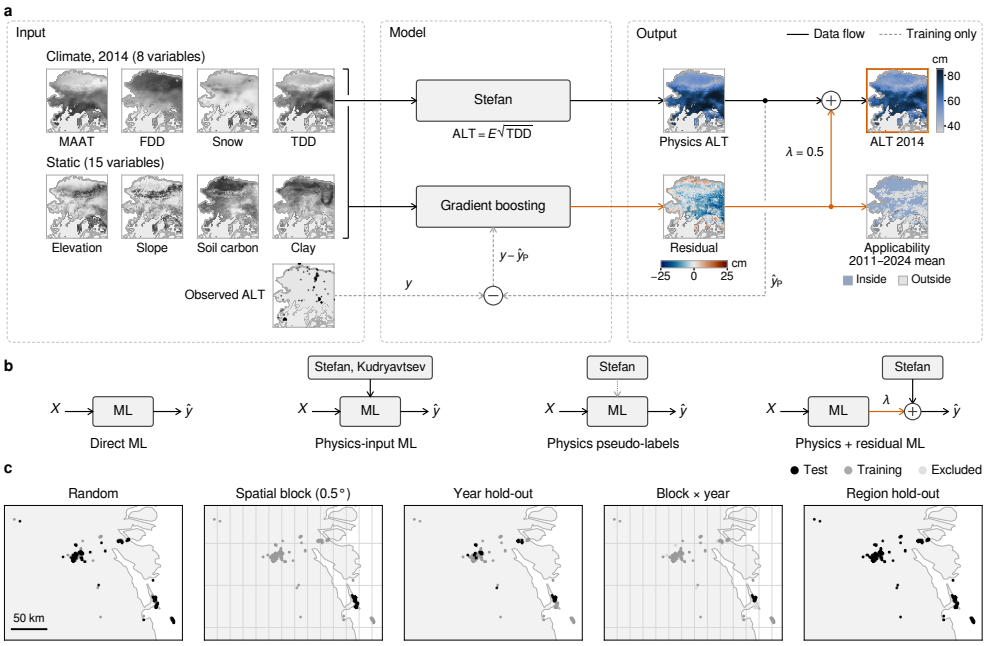

a
Input
Climate, 2014 (8 variables)
MAAT
FDD
Snow
TDD
Static (15 variables)
Elevation
Slope
Soil carbon
Clay
Observed ALT
Model
Stefan
ALT = E√TDD
Gradient boosting
y − ŷP
y
Output
Data flow
Training only
Physics ALT
Residual
−25 0 25 cm
λ = 0.5
ALT 2014
cm
80
60
40
Applicability
2011–2024 mean
Inside
Outside
ŷP
b
X
ML
ŷ
Direct ML
Stefan, Kudryavtsev
Physics-input ML
Stefan
Physics pseudo-labels
Stefan
λ
Physics + residual ML
c
Test
Training
Excluded
Random
Spatial block (0.5°)
Year hold-out
Block × year
Region hold-out
50 km

그림 2

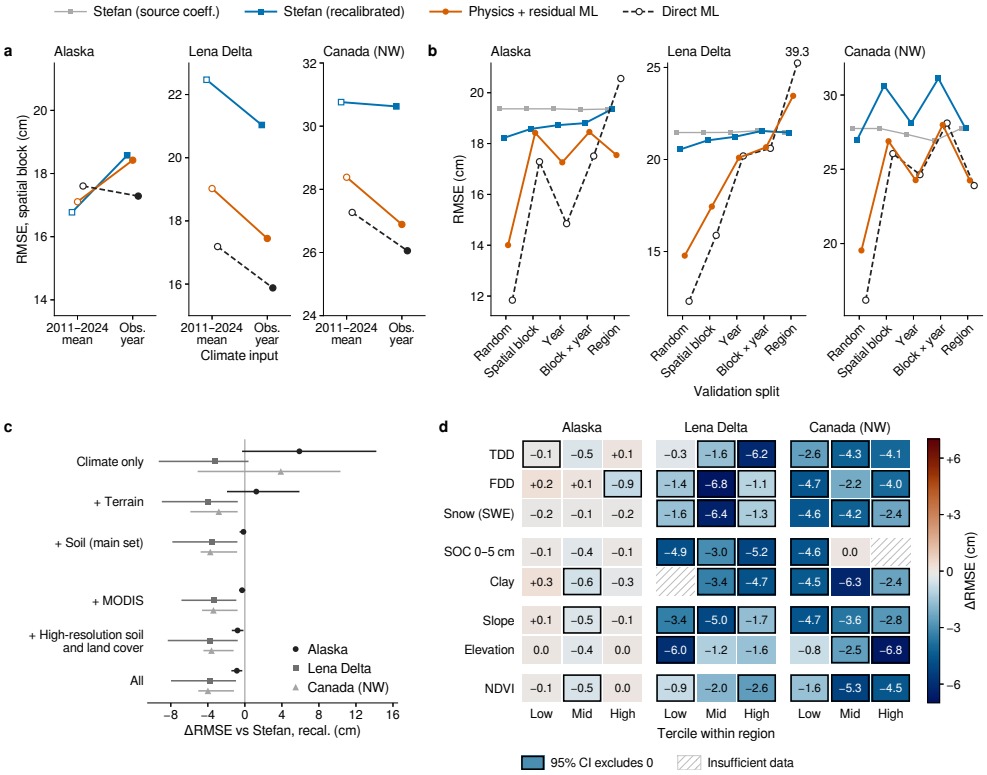

Stefan (source coeff.)
Stefan (recalibrated)
Physics + residual ML
Direct ML
a
Alaska
Lena Delta
Canada (NW)
RMSE, spatial block (cm)
2011–2024 mean
Obs. year
Climate input
b
RMSE (cm)
39.3
Random
Spatial block
Year
Block × year
Region
Validation split
c
Climate only
+ Terrain
+ Soil (main set)
+ MODIS
+ High-resolution soil and land cover
All
ΔRMSE vs Stefan, recal. (cm)
d
TDD
FDD
Snow (SWE)
SOC 0–5 cm
Clay
Slope
Elevation
NDVI
Low
Mid
High
Tercile within region
ΔRMSE (cm)
95% CI excludes 0
Insufficient data

그림 3

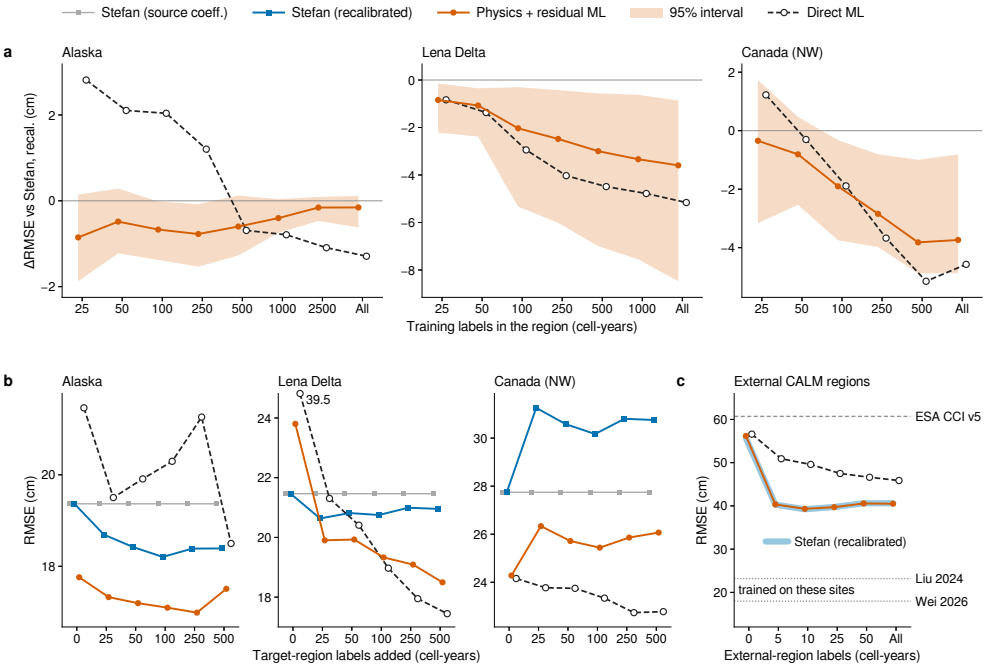

Stefan (source coeff.)
Stefan (recalibrated)
Physics + residual ML
95% interval
Direct ML
a
Alaska
Lena Delta
Canada (NW)
ΔRMSE vs Stefan, recal. (cm)
Training labels in the region (cell-years)
b
RMSE (cm)
39.5
Target-region labels added (cell-years)
c
External CALM regions
ESA CCI v5
Stefan (recalibrated)
Liu 2024
Wei 2026
trained on these sites
External-region labels (cell-years)

그림 4

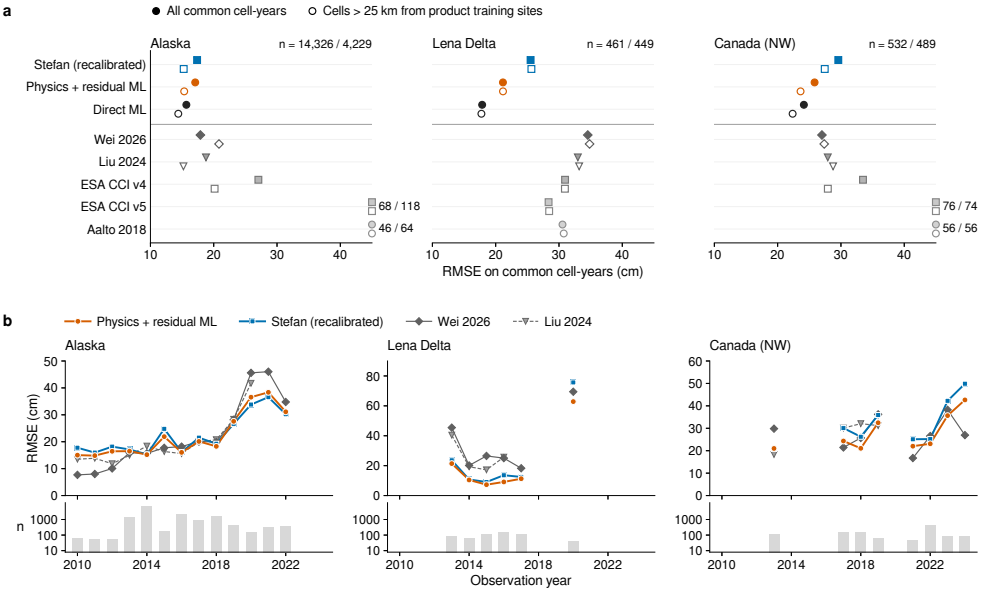

a
All common cell-years
Cells > 25 km from product training sites
Alaska
n = 14,326 / 4,229
Lena Delta
n = 461 / 449
Canada (NW)
n = 532 / 489
Stefan (recalibrated)
Physics + residual ML
Direct ML
Wei 2026
Liu 2024
ESA CCI v4
ESA CCI v5
Aalto 2018
68 / 118
46 / 64
76 / 74
56 / 56
RMSE on common cell-years (cm)
b
Physics + residual ML
Stefan (recalibrated)
Wei 2026
Liu 2024
Alaska
Lena Delta
Canada (NW)
RMSE (cm)
n
Observation year

그림 5

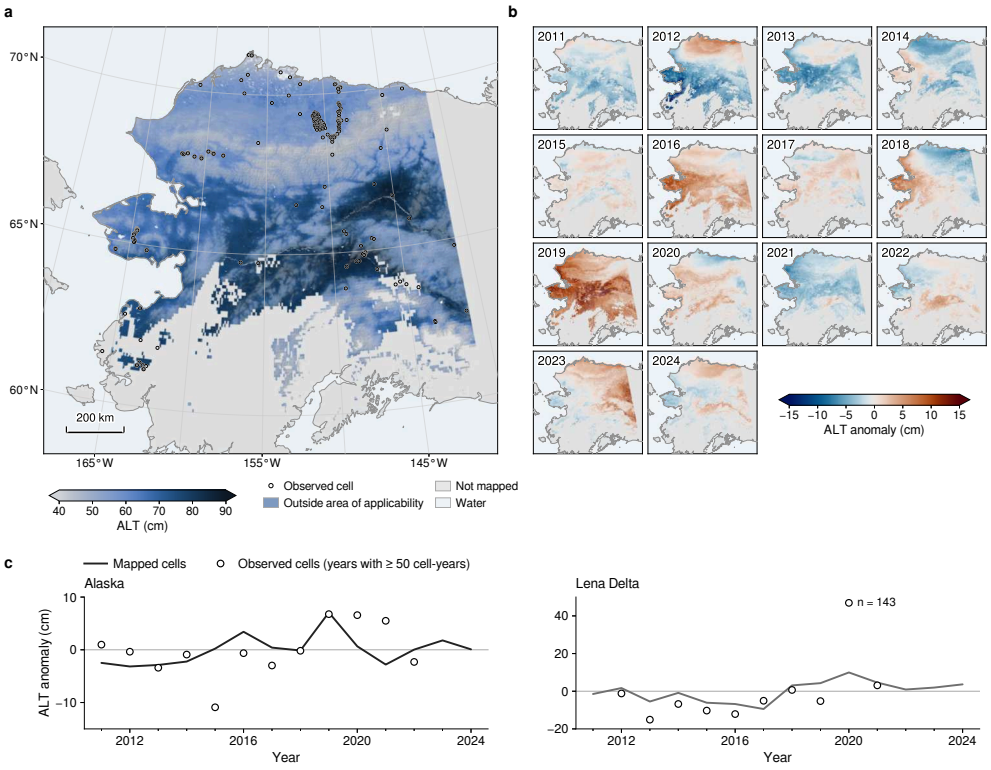

a
70°N
65°N
60°N
200 km
165°W
155°W
145°W
40 50 60 70 80 90
ALT (cm)
Observed cell
Outside area of applicability
Not mapped
Water
b
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
2024
−15 −10 −5 0 5 10 15
ALT anomaly (cm)
c
Mapped cells
Observed cells (years with ≥ 50 cell-years)
Alaska
ALT anomaly (cm)
10
0
−10
2012
2016
2020
2024
Year
Lena Delta
n = 143
40
20
0
−20
2012
2016
2020
2024
Year

그림 6