물리 잔차 기반 기계학습 워크플로를 활용한 영구동토 활동층 두께 예측과 지역별 편차 분석

백승원[1*] and [공저자] [극지연구소][2]

[1*] 에너지시스템공학부, 서울대학교, 서울, 대한민국.
[2] 극지연구소, 인천, 대한민국.

*Corresponding author(s). E-mail(s): [교신 저자 전자우편];

초록

활동층 두께 (ALT) 는 해마다 달라지지만, 기존 격자 ALT 제품은 대부분 여러 해의 조건으로 학습되었고 같은 위치·같은 해의 관측과 비교된 적이 드물다. 이 연구는 알래스카, 레나 델타, 캐나다 북서부의 셀-연도 ALT 관측 19,172 개 (2010–2024 년) 에 관측일까지 누적한 ERA5-Land 융해 도일을 결합하고, 지역 라벨로 재보정한 Stefan 모델의 잔차를 gradient boosting 으로 학습하는 물리 잔차 워크플로를 검증하였다. 공간 블록 교차검증에서 물리 잔차 모델은 Stefan 모델의 오차를 레나 델타에서 3.6 cm, 캐나다에서 3.7 cm 줄였고 알래스카에서는 같은 수준이었다. 레나 델타를 학습에서 제외하면 직접 기계학습의 오차는 Stefan 모델보다 18.0 cm 컸으나, 물리 잔차 모델은 Stefan 모델 수준을 유지하였다. 지역 라벨 25 개를 더하면 물리 잔차 모델의 레나 델타 오차는 23.8 cm 에서 19.9 cm 로 줄었고, 외부 CALM 지점에서는 라벨 5 개로 오차가 56.2 cm 에서 40.3 cm 로 감소하였다. 같은 셀·같은 해 비교에서 레나 델타의 오차 (21.1 cm) 는 공개 제품 5 종 (28.4–34.6 cm) 보다 낮았다. 따라서 Stefan 모델을 기준으로 두고 잔차만 학습하는 구조는 대상 지역 라벨이 적거나 없을 때 가장 유용하다. 이 워크플로는 적용 가능 영역이 명시된 2011–2024 년의 연도별 1 km ALT 지도를 제공한다.

핵심어: 영구동토, 활동층 두께, Stefan 모델, 물리 기반 기계학습, 공간 교차검증, ERA5-Land

서론

활동층은 영구동토 위에서 여름마다 녹고 겨울마다 다시 어는 지표 부근의 지층이다. 활동층 두께 (ALT) 는 계절 융해의 깊이를 정하며 지반 안정성, 지표 부근 수문, 분해에 노출되는 토양 유기탄소의 양을 좌우한다[1–3]. ALT 는 해마다의 열 조건에 반응하므로, 연도 간 변동은 CALM(Circumpolar Active Layer Monitoring) 같은 장기 관측망이 기록하는 신호의 본질적인 부분이다[4,5]. 그러나 관측은 드물고 공간적으로 모여 있

다. 대부분의 측정은 소수의 집중 현장 조사와 장기 격자에서 나오며, 한 번만 방문한 지점이 많다[6,7].

북반구 영구동토 지역에는 약 1 km 해상도의 격자 ALT 제품이 여러 개 있다. ESA CCI Permafrost 같은 과정 기반 추정은 위성 지표 온도로 지중 열전도 방정식을 푼다[8,9]. 통계·기계학습 (ML) 제품은 지점 관측을 기후·지형·토양 예측 변수와 연결한다[10–13]. 연도별 활용에는 세 가지 제약이 있다. 첫째, 대부분의 제품은 다년 평균 예측 변수나 여러 해의 지점-연도를 합친 자료로 학습되어, 제품 값이 특정 해의 기후와 연결되지 않는다. 둘째, 제품마다 검증 지점과 검증 방식이 달라 보고된 오차를 서로 비교할 수 없다. 예를 들어 Liu 등의 무작위 10 겹 RMSE 는 21.6 cm[12], Wei 등의 지점 하나 제외 RMSE 는 60.5 cm[13] 이다. 셋째, 공간적으로 모인 관측에 무작위 교차검증을 적용하면 새 위치에서 ML 모델의 정확도가 과대평가되므로[14–17], 관측이 없는 지역에서의 성능을 판단하기 어렵다.

물리 기반 모델은 다른 접근을 제공한다. Stefan 해는 융해 깊이를 그 계절의 융해 도일 (TDD) 과 토양의 열적 성질·수분에 따라 정해지는 계수 하나로 연결한다[4,18,19]. 이 해는 계절 융해의 진행을 재현하고 해마다의 기후에 반응하지만, 지역마다 계수 하나를 쓰면 토양 유기물과 지형에 따른 체계적인 잔차가 남는다. 물리 모델이 주된 반응을 맡고 학습기가 물리 모델이 놓친 부분을 보정하는 물리 기반 ML 은 여러 환경 분야에서 정확도와 외삽 능력을 높였고[20–22], 알래스카에서는 Stefan 모델이 검정 지점에서 랜덤 포레스트보다 정확도를 잘 유지하였다[23]. 그러나 기후 입력을 관측 연도와 맞추었을 때 이러한 결합의 성능, 라벨이 없는 지역으로의 전이, 새 지역에 필요한 라벨 수, 같은 셀·같은 해에서 공개 제품과의 비교는 밝혀지지 않았다.

이 연구는 셀-연도 설계로 이 문제를 다룬다. 각 ALT 관측은 명시된 해의 1 km 셀이며, 각 기후 입력은 그 해의 ERA5-Land 자료로 계산해 관측일까지 누적한다[24]. 알래스카, 레나 델타, 캐나다 북서부의 2010–2024 년 셀-연도 관측 19,172 개로 Stefan 모델, 직접 ML, 그리고 재보정한 Stefan 모델의 잔차를 gradient boosting 으로 학습하는 물리 잔차 워크플로를 비교하였다. 제품마다 다른 지점 집합에서 무작위 또는 지점 단위 교차검증을 주로 보고한 기존 ALT 지도 연구[11–13] 와 달리, 이 연구는 모든 방법과 제품을 같은 관측과 같은 검증 설계로 채점한다. 이 연구의 기여는 네 가지이다. (i) ALT 라벨과 기후 입력의 시간 불일치를 제거하고 관측 연도 입력의 효과를 정량화하였다. (ii) 물리 잔차 학습을 직접 ML, 물리 입력 ML, 물리 유사라벨과 다섯 가지 검증 설계 (지역 전체 제외 포함) 에서 비교하였다. (iii) 지역 안·지역 간 라벨 수 실험과 외부 CALM 지역 시험으로 표본 효율과 전이성을 정량화하였다. (iv) 모델과 공개 제품 6 종을 같은 셀·같은 해에서 제품 학습 지점 마스크와 함께 비교하고, 적용 가능 영역과 예측 구간을 갖춘 2011–2024 년 연도별 1 km 지도를 제시하였다.

자료와 방법

연구 지역과 활동층 관측

여러 해에 걸친 융해 깊이 관측이 조밀한 세 지역, 알래스카·레나 델타·캐나다 북서부를 대상으로 하였다 (그림 1, 표 1). 알래스카와 캐나다는 ABoVE 토양 수분·활동층 두께 자료 v2[6] 와 CALM 계절 말 격자 값[5] 을, 레나 델타는 ALLena 융해 깊이 자료[7] 를 사용하였다. ABoVE 탐침 측정은 8–10 월, $0 < \mathrm{ALT} < 300$ cm 인 값으로 제한하였다. 그보다 이른 측정은 계절 최대값이 아니라 그 시점의 융해 깊이를 나타내기 때문이다. ALLena 는 탐침 한계 표지가 없는 8–9 월 값으로 제한하고, 위치·연도별 계절 최댓값을 취하였다. 모든 관측은 1 km 셀에 배정해 셀·연도별로 평균하고 평균 관측일을 보존

하였다. 날짜가 없는 CALM 값은 244 번째 날 (9 월 1 일) 로 두었다. 연도별 기후 입력이 있는 2010–2024 년만 사용하였다. 라벨은 알래스카 15,540 개 셀-연도 (2010–2024 년), 레나 델타 2,436 개 (2010–2022 년), 캐나다 1,196 개 (2010–2019 년과 2021–2024 년) 이며, 0.5° 블록 73, 16, 26 개에 분포한다 (표 1). 자료 출처·판·약관은 보충 표 S1, 분석별 사용 연도는 보충 표 S2, 처리 단계는 보충 방법 S1 에 정리하였다.

표 1 자료와 사용 연도. 위: 지역별 ALT 라벨 (관측 연도 기후 입력이 있는 2010–2024 년 셀-연도). 아래: 입력 자료와 제품의 제공 기간과 이 연구에서 쓴 연도. 블록은 공간 교차검증과 부트스트랩에 쓰는 0.5° 칸이며, 캐나다는 2020 년 라벨이 없다.

지역	셀-연도	셀	블록	연도	4 개 해 이상 셀	최다 연도
알래스카	15,540	13,253	73	2010–2024	203	2014 (51%)
레나 델타	2,436	2,206	16	2010–2022	25	2016 (28%)
캐나다 북서부	1,196	730	26	2010–2024	48	2022 (37%)
외부 CALM 지역	805	72	49	2010–2024	–	–

자료	해상도	제공 기간	사용 연도	역할
ERA5-Land 월평균[24]	0.1°	1950 년부터	2010–2024 년, 평균 2011–2024 년	기후 입력
Copernicus DEM[25]	30 m	정적	–	지형
SoilGrids 2.0[26]	250 m	정적	–	토양
MODIS MOD13Q1, MOD10A2[27,28]	250–500 m	2000 년부터	2010–2024 년	민감도 시험
ESA CCI 영구동토 확률[8]	1 km	1997–2021 년	평균	지도 범위
Wei 등[13]	1 km	2000–2024 년	2010–2024 년	비교
Liu 등[12]	1 km	2003–2020 년	2010–2020 년	비교
ESA CCI ALT v4[8]	1 km	1997–2021 년	2010–2021 년	비교
ESA CCI ALT v5[9]	1 km	1997–2023 년	2010–2023 년	비교
Yi 와 Kimball[29]	1 km	2001–2015 년	2010–2015 년 (알래스카)	비교
Aalto 등[10]	30″	2000–2014 년	시간 불변	비교

관측 연도 기후 입력

2010 년 1 월–2024 년 12 월 ERA5-Land 월자료[24](2 m 기온, 표층 토양 온도, 적설 수당량) 를 각 1 km 셀의 가장 가까운 육지 격자에서 추출하였다. 셀 c, 연도 y 의 융해 도일은 다음과 같다.

$$\mathrm{TDD}_{c,y} = \sum_{m=1}^{12} \max(T_{c,y,m},\, 0)\, d_{y,m} \tag{1}$$

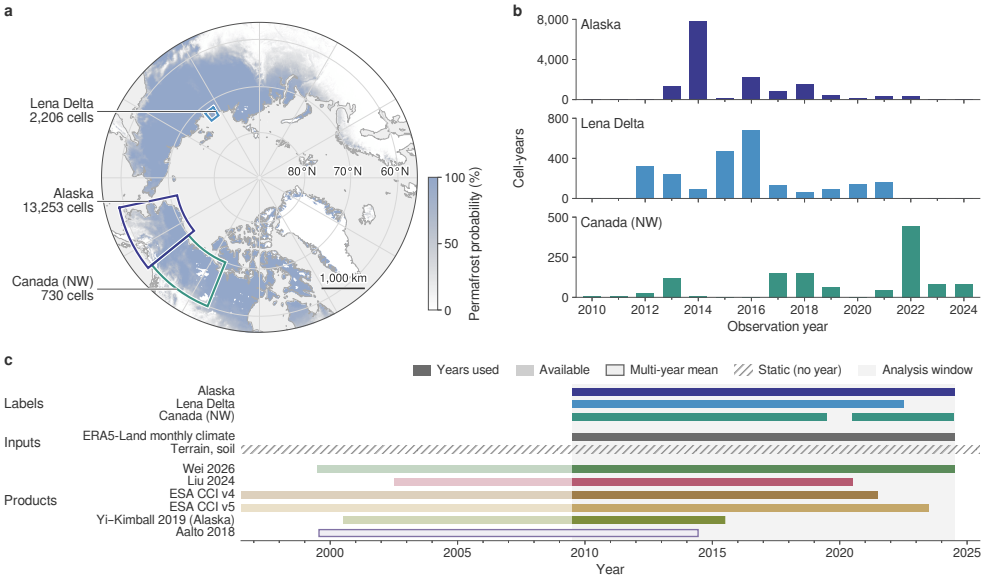


그림 1 연구 지역, 관측, 자료 기간. **a**, ESA CCI 영구동토 확률 (1997–2021 년 평균) 과 세 연구 지역, 2010–2024 년 ALT 라벨이 있는 1 km 셀 수. **b**, 관측 연도별 셀-연도 라벨 수 (2010–2024 년). **c**, 라벨, 기후 입력에 쓴 ERA5-Land 월자료, 정적 공변량, 공개 제품 6 종의 기간. 제품마다 제공 기간과 라벨 셀에서 비교에 쓴 연도를 구분하였고, 음영은 분석 기간 2010–2024 년이다.

여기서 $T_{c,y,m}$ 은 월평균 기온, $d_{y,m}$ 은 m 월의 일수이다. 관측은 대부분 융해 계절이 끝나기 전에 이루어졌으므로, 모델 입력은 관측일 t 까지 누적한 TDD 이다.

$$\mathrm{TDD}^{\mathrm{obs}}_{c,y} = C_{c,y,k-1} + \frac{t - t_{k-1}}{d_{y,k}} \left(C_{c,y,k} - C_{c,y,k-1}\right) \tag{2}$$

$C_{c,y,k}$ 는 k 월 말까지의 누적 TDD, k 는 t 가 속한 달, t_{k-1} 은 전달의 마지막 날이다. 이와 함께 기후 변수 일곱 개, 즉 연평균 기온, $\sqrt{\mathrm{TDD}}$, 가장 따뜻한 달과 가장 추운 달의 평균 기온, 직전 겨울 (10 월 $y-1$–4 월 y) 의 동결 도일, 표층 토양 온도 평균, 수문년 (10 월 $y-1$–9 월 y) 적설 수당량 평균을 셀·연도별로 계산하였다 (보충 표 S3, 보충 방법 S2). 같은 셀-연도에서 두 가지 대안 입력을 함께 평가하였다. 관측 연도의 계절 전체 TDD 와, 연도별 값의 2011–2024 년 평균 (평년 기후 입력) 이다. 후자는 기존 제품의 다년 입력에 해당한다. 연도별 지도는 각 해의 계절 전체 TDD 를 쓰므로 계절 말 ALT 를 나타낸다.

정적 공변량

지형 변수 여섯 개 (고도, 경사, 사면 방향의 사인·코사인, 지형 위치 지수, 거칠기) 는 30 m Copernicus DEM[25] 에서 각 셀 둘레 33×33 화소 창 (약 1 km) 으로 계산하였다. 토양 변수 아홉 개 (5–15 cm 의 점토, 모래, 실트, 용적 밀도, 조립질, pH 와 0–5, 5–15, 15–30 cm 의 토양 유기탄소) 는 250 m SoilGrids 2.0[26] 에서 추출하였다. 따라서 주 특징 벡터 $\mathbf{x}$ 는 기후 8 개, 지형 6 개, 토양 9 개의 23 개 변수로 이루어진다. 민감도 시험에는 기후만, 기후와 지형, 주 묶음에 2010–2024 년 MODIS 여름 NDVI ·EVI 와 눈 소

실 시기 (MOD13Q1 ·MOD10A2 v6.1)[27,28] 를 더한 묶음, 주 묶음에 고해상 토양 탄소·피복 분류[30] 를 더한 묶음, 전년 기후를 포함한 전체 변수를 사용하였다. ESA CCI 영구동토 확률 (1997–2021 년 평균)[8] 은 예측 변수가 아니라 지도 범위 (확률 50% 이상) 를 정하는 데에만 사용하였다.

모델 구성

Stefan 모델은 융해 깊이를 다음과 같이 나타낸다.

$$\widehat{\mathrm{ALT}}_{\mathrm{S}} = E\,\sqrt{\mathrm{TDD}^{\mathrm{obs}}} \tag{3}$$

$E(\mathrm{cm}\,(^{\circ}\mathrm{C\,d})^{-1/2})$ 는 토양의 열적 성질과 수분을 요약한다[18,19]. 이 관계는 레나 델타 관측 지점에서 계절 안에 잘 성립하며, 반복 관측된 셀에서는 연도 간에도 더 큰 산포와 함께 성립한다 (보충 그림 S1). n 개 학습 라벨 y_i 와 $s_i = \sqrt{\mathrm{TDD}_i^{\mathrm{obs}}}$ 에 대해 계수는 원점을 지나는 최소제곱으로 재보정한다.

$$\hat{E} = \frac{\sum_{i=1}^{n} y_i\, s_i}{\sum_{i=1}^{n} s_i^2} \tag{4}$$

원천 계수 Stefan 모델은 다른 두 지역에서 맞춘 $\hat{E}$ 를, 재보정 Stefan 모델은 대상 지역 학습 라벨로 맞춘 $\hat{E}$ 를 쓴다. 물리 잔차 모델은 재보정 Stefan 예측을 기준값으로 두고 학습한 보정량을 더한다 (그림 2).

$$\widehat{\mathrm{ALT}} = \hat{E}\,s + \lambda\, g(\mathbf{x}), \qquad g = \arg\min_{f} \sum_{i=1}^{n} \Big[\Big(y_i - \hat{E}\,s_i\Big) - f(\mathbf{x}_i)\Big]^2 \tag{5}$$

g 는 CatBoost gradient boosting 회귀기[31](반복 600, 학습률 0.03, 깊이 6, L2 정칙화 3) 이며, $\lambda = 0.5$ 는 보정량을 물리 기준값 쪽으로 수축한다 ($\lambda = 0.25$, 1 과 내부 블록 교차검증으로 고른 값을 민감도로 시험하였다). 비교한 세 구조는 물리 정보를 다른 위치에 넣는다. 직접 ML 은 $\mathbf{x}$ 만으로 ALT 를 학습하고, 물리 입력 ML 은 재보정 Stefan 과 Kudryavtsev[32] 예측을 특징으로 더하며, 물리 유사라벨은 채점 겹 셀의 공변량과 학습 겹 Stefan 예측으로 만든 같은 수의 행을 학습 자료에 더한다. 모든 학습 모델은 무작위 씨앗 3 개로 학습해 예측을 평균하였다. 학습기 민감도에서는 CatBoost 대신 랜덤 포레스트, 다층 퍼셉트론, TabM, FT-Transformer[33–35] 를 사용하였고, 지역별 전체 라벨로 학습한 잔차 모델과 직접 모델의 SHAP 값[36] 을 계산하였다.

검증 설계와 불확실성

모든 모델은 다섯 가지 설계의 겹 밖 예측으로 평가하였다[14,15]. 셀-연도 단위 무작위 5 겹 교차검증, 0.5° 블록을 셀-연도 수가 고르게 겹에 배정한 공간 블록 5 겹 교차검증 (주 설계), 셀-연도 20 개 이상인 각 관측 연도를 나머지 해로 학습한 모델로 예측하는 연도 홀드아웃, 채점 셀-연도의 블록 겹과 연도를 모두 학습에서 빼는 블록 × 연도 홀드아웃, 시험 지역에서 100 km 안의 학습 셀을 뺀 뒤 다른 두 지역으로 학습한 모델로

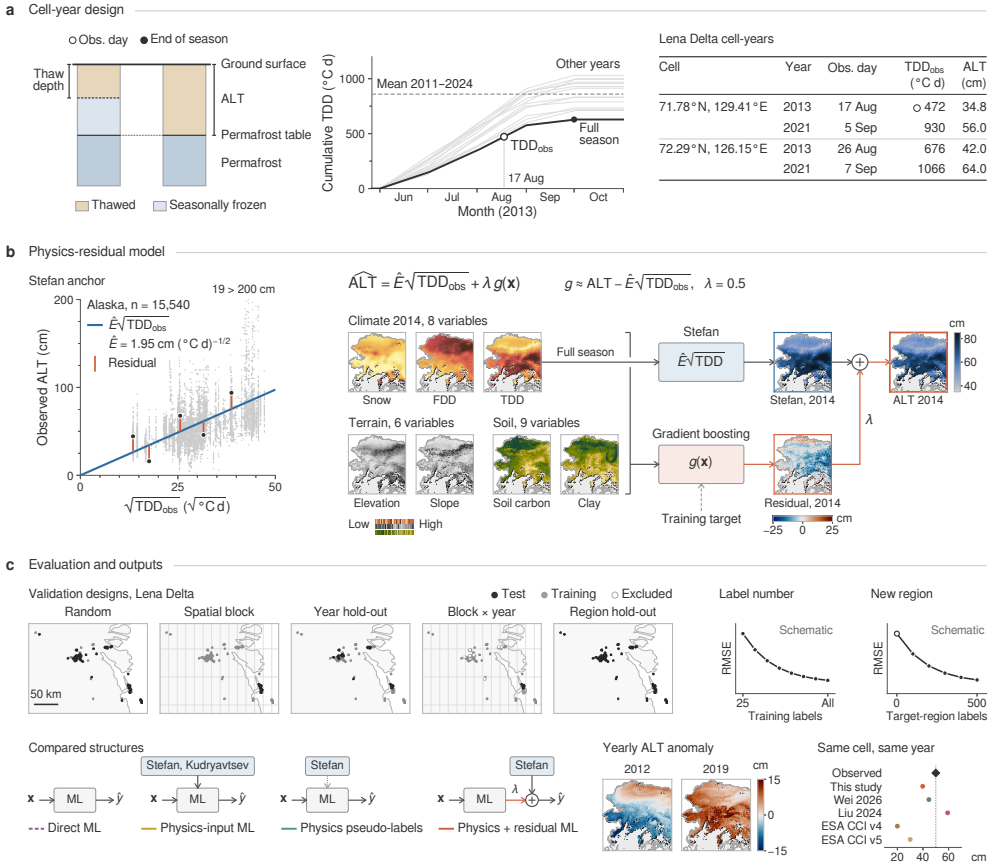


그림 2 셀-연도 설계, 물리 잔차 모델, 평가. **a**, 각 라벨은 한 해의 1 km 셀 하나이며, 기후 입력은 관측일까지 누적한 융해 도일 (TDD_{obs}) 이다. 레나 델타 셀의 2013 년 곡선을 예로 들었고, 표는 2011–2024 년 중 레나 델타 라벨 셀의 평균 TDD 가 가장 낮은 해 (2013 년) 와 가장 높은 해 (2021 년) 의 셀-연도이다. **b**, 알래스카 셀-연도 15,540 개로 적합한 Stefan 기준값과, 기후·지형·토양 입력 23 개로 그 잔차를 학습하는 gradient boosting(가중치 $\lambda = 0.5$). 지도는 2014 년 계절 전체 TDD 를 쓴다 (알래스카). **c**, 레나 델타 라벨 셀의 검증 설계 (설계마다 한 겹, 시험 연도 2016 년), 라벨 수·새 지역 실험 (개략도), 비교한 모델 구조, 2011–2024 년 평균 대비 연도별 ALT 편차, 같은 해 제품 4 종과 비교한 레나 델타 셀-연도 하나 (2013 년 9 월 3 일). 이 셀-연도는 제품 4 종 값이 모두 있고 계절 TDD 의 90% 이상이 누적된 뒤 관측한 셀-연도 42 개 가운데 우리 모델의 절대오차가 중앙값인 것이다.

예측하는 지역 홀드아웃이다. 정확도는 다음과 같이 나타낸다.

$$\mathrm{RMSE} = \left[\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2\right]^{1/2}, \qquad \Delta\mathrm{RMSE}_{A,B} = \mathrm{RMSE}_A - \mathrm{RMSE}_B \tag{6}$$

ΔRMSE 의 두 항은 같은 셀-연도에서 계산하며, 음수이면 방법 A 가 낫다. 불확실성은 짝지은 블록 부트스트랩으로 정량화하였다. 0.5° 블록을 복원 추출로 $B = 2000$ 회 (라벨 수 실험은 1000 회) 재추출하고, 재추출된 블록의 모든 셀-연도로 ΔRMSE 를 다시

계산하여, 반복값의 2.5 와 97.5 백분위수를 95% 구간으로 정하였다.

$$\mathrm{CI}_{95} = \left[Q_{0.025}\left(\Delta\mathrm{RMSE}^{(b)}\right),\ Q_{0.975}\left(\Delta\mathrm{RMSE}^{(b)}\right) \right], \quad b = 1, \ldots, B \tag{7}$$

구간이 0 을 제외하면 차이가 판정된 것으로 기술한다. 이득의 조건은 공변량 여덟 개 (관측 연도의 계절 전체 TDD, 동결 도일, 적설 수당량, 토양 유기탄소, 점토, 경사, 고도, 여름 NDVI) 의 지역 안 3 분위에서 분석하였고, 셀-연도 30 개 또는 블록 5 개 미만인 3 분위는 평가하지 않았다. 연도별 RMSE 는 셀-연도 30 개 이상인 해에서, 관측과 예측의 연도 간 변화 상관은 여러 해 관측된 셀에서 계산하였다.

라벨 수·전이 실험

지역 안 실험에서는 공간 블록 겹마다 학습 라벨을 $n = 25, 50, 100, 250, 500, 1000, 2500$ 개 또는 전량으로 줄이고 (무작위 3 회), 같은 n 개 라벨로 Stefan 계수를 재보정한 뒤 시험 겹 전체를 채점하였다. 전이 실험에서는 다른 두 지역의 전체 라벨과 대상 지역 학습 겹에서 뽑은 $n = 0, 25, 50, 100, 250, 500$ 개 라벨로 학습한 모델로 대상 지역의 공간 블록 겹을 채점하였다. $\hat{E}$ 는 대상 라벨 n 개로 다시 맞추었고 ($n \geq 3$), 잔차 학습기는 원천 계수 기준값을 쓰는 원천 행과 다시 맞춘 기준값을 쓰는 대상 행으로 학습하였다. 외부 시험에는 세 연구 지역과 산악 영구동토 (스위스, 카자흐스탄) 밖의 2010–2024 년 CALM 관측[5] 을 사용하였다. 검열값, 이른 측정·화재·침수·영구동토면 미도달 표지가 있는 값, 연구 라벨에서 100 km 안의 지점을 제외하여 8 개 지역의 73 개 셀, 816 개 셀-연도를 남겼다 (보충 방법 S3). 각 외부 지역은 블록 단위로 (블록이 하나인 그린란드는 셀 단위로) 채점하였으며, 세 연구 지역과 같은 외부 지역의 다른 블록에서 뽑은 라벨 $n = 0, 5, 10, 25, 50$ 개 또는 전량으로 학습하였다. 학습 범위 밖인 평균 ALT 약 6 m 의 스발바르 시추공 한 곳은 채점에서 제외하여, 셀-연도 805 개, 셀 72 개, 블록 49 개가 남았다. 실행 목록은 보충 표 S4 에 있다.

공개 제품 비교

라벨 셀에서 제품 6 종을 추출하였다. Wei 등[13](1 km, 2000–2024 년), Liu 등[12](1 km, 2003–2020 년), ESA CCI Permafrost ALT v4(1997–2021 년) 와 v5(1997–2023 년)[8,9], Yi 와 Kimball[29](알래스카, 2001–2015 년), Aalto 등[10](2000–2014 년 기준기, 셀당 값 하나) 이다. 연도별 제품은 관측 연도의 값을 사용하였다 (보충 방법 S4). 제품과 모델은 Wei 등, Liu 등, ESA CCI v4 가 모두 관측 연도 값을 가진 공통 셀-연도 (2010–2020 년) 에서 비교하였다. Wei 등은 학습 지점 좌표를 공개하였으며, 누설 마스크는 이 지점에서 25 km 안의 라벨 셀을 제외한다. Liu 등은 이 연구에서 쓴 ABoVE 관측의 이전 판으로 학습하였으므로[12], 알래스카·캐나다 값은 우리 라벨과 독립이 아니다. 잔차 학습기가 제품도 보정할 수 있는지 시험하기 위해, 관측 연도의 제품 값 p 를 학습 겹에서 다음과 같이 재보정하고

$$\hat{p} = a + b\,p \tag{8}$$

잔차 $y - \hat{p}$ 를 식 (5) 과 같은 공변량, 학습기, λ, 겹으로 학습하였다 (보충 방법 S5).

연도별 지도, 적용 가능 영역, 예측 구간

알래스카와 레나 델타에서 재보정 Stefan 모델과 물리 잔차 모델을 지역의 모든 셀-연도로 학습하고, ESA CCI 영구동토 확률 50% 이상인 1 km 셀 (858,517 개, 38,086 개)

에 2011–2024 년 각 해의 계절 전체 기후로 적용하였다. 적용 가능 영역은 Meyer 와 Pebesma[37] 를 따랐다. $\mathbf{z}$ 를 표준화한 23 차원 특징 벡터 (2011–2024 년 평균 기후) 라 할 때, 지도 셀 k 의 비유사도는 모든 학습 행 j 에 대한 $d_k = \min_j \|\mathbf{z}_k - \mathbf{z}_j\|_2$ 이며, 다음을 만족하면 적용 가능 영역 안으로 본다.

$$d_k \le \tau, \qquad \tau = Q_{0.95}\left\{ \min_{j:\, b(j)\neq b(i)} \|\mathbf{z}_i - \mathbf{z}_j\|_2 \;:\; i \in \text{학습 행} \right\} \tag{9}$$

$b(\cdot)$ 는 공간 블록이다. 지도 값의 90% 예측 구간은 공간 블록 겹 밖 잔차의 5 와 95 백분위수로 정하였다. 표시용으로 1 km 값을 250 m 음영 격자에 쌍선형 보간하였다.

계산

모델은 씨앗을 고정해 클라우드 노드 (Rescale; 96 코어 CPU 노드, 신경망 학습기는 NVIDIA A100 GPU 노드 1 대) 에서 학습하였고, 자료 준비·집계·그림은 로컬 서버에서 수행하였다 (보충 표 S4).

코드 가용성

자료 준비, 모델링, 평가, 그림 코드는 [저장소·DOI] 에서 받을 수 있다. 본문의 모든 수치는 원고 매크로를 만드는 스크립트가 저장된 결과 표에서 생성한다.

결과

관측 연도 기후 입력의 효과

관측은 시간적으로 고르지 않다 (그림 1b, 표 1). 알래스카 셀-연도의 51% 가 2014 년에 관측되었고, 레나 델타 라벨은 13 개 해에 분포한다. 측정은 대부분 8 월에 이루어졌으며 (관측일 중앙값 알래스카 224, 레나 델타 234, 캐나다 237 번째 날), 관측일까지 누적한 TDD 는 계절 전체 값의 중앙값 0.73, 0.81, 0.89 배였다 (식 (2)).

평년 기후 입력을 관측 연도 기후 입력으로 바꾸면 레나 델타에서 재보정 Stefan 모델 (-1.4 [-2.6, -0.8] cm) 과 물리 잔차 모델 (-1.6 [-2.4, -1.0] cm) 의, 캐나다에서 물리 잔차 모델 (-1.5 [-2.0, -0.4] cm) 의 공간 블록 RMSE 가 감소하였다 (그림 3a). 알래스카에서는 변화가 판정되지 않았다 (Stefan $+1.8$ [-0.1, $+3.9$] cm). 라벨이 한 해에 몰려 있어 관측 연도 입력이 공간 분포 이상의 정보를 거의 더하지 못하기 때문으로 해석된다. 관측 연도 입력은 각 예측을 명시된 해의 기후와 연결하므로, 아래에 제시하는 연도별 지도의 전제가 된다.

공간·시간·지역 검증에서의 정확도

방법의 순위는 검증 설계에 따라 달라졌다 (그림 3b, 보충 표 S5). 무작위 교차검증에서 직접 ML 의 오차가 가장 낮았고 (알래스카 11.8 cm), 공간 블록 교차검증에서는 직접 ML 의 오차가 알래스카 5.4, 레나 델타 3.6, 캐나다 9.9 cm 증가하였다. 연도 홀드아웃에서는 라벨이 여러 해에 분포한 레나 델타에서 직접 ML 의 오차가 15.9 cm 에서 20.2 cm 로 증가하였고, 블록 $\times$ 연도 설계는 세 지역 모두에서 지역 라벨로 적합하는 모든 방법의 지역 안 오차가 가장 컸다. 지역 전체를 학습에서 제외하면 레나 델타에서 직접 ML 의 오차는 39.3 cm 로, 다른 지역 계수를 쓴 Stefan 모델의 21.5 cm 보다

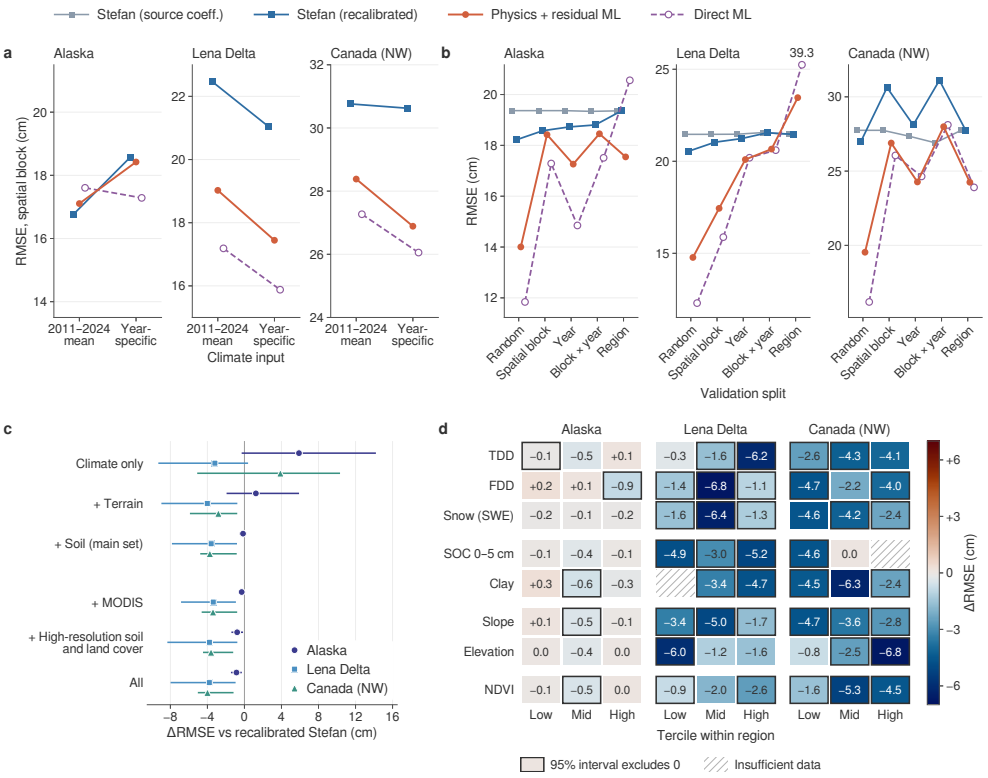


그림 3 관측 연도 기후 입력, 검증 설계, 잔차 이득의 조건. 모든 패널은 2010–2024 년 셀-연도 라벨과 겹 밖 예측을 사용한다. **a**, 평년 기후 입력 (2011–2024 년 평균) 과 관측 연도 기후 입력 (관측일까지 누적) 의 공간 블록 RMSE. **b**, 다섯 검증 설계의 RMSE. 지역 홀드아웃에서는 재보정 Stefan 모델이 원천 계수 모델과 같으며, 축 범위 밖 값은 숫자로 표기하였다. **c**, 공변량 묶음 여섯 가지에서 물리 잔차 모델과 재보정 Stefan 모델의 ΔRMSE. **d**, 여덟 공변량의 지역 안 3 분위에서의 같은 ΔRMSE. 테두리 칸은 95% 구간이 0 을 제외하고, 빗금 칸은 셀-연도 30 개 또는 블록 5 개 미만이다. 구간은 0.5° 블록 2000 회 재추출의 95% 짝지은 블록 부트스트랩 구간이며, 음수는 물리 잔차 모델이 낫다는 뜻이다.

컸다 (ΔRMSE +17.8 [+8.0, +23.9] cm). 같은 시험에서 물리 잔차 모델은 Stefan 모델 수준을 유지하였고 (+2.0 [−0.8, +3.4] cm), 캐나다에서는 Stefan 모델보다 정확하였다 (−3.5 [−5.1, −0.1] cm). 따라서 공간 블록 교차검증을 주 설계로, 지역 홀드아웃을 전이성 시험으로 사용한다.

물리 잔차 학습의 이득과 그 조건

관측 연도 입력을 사용한 공간 블록 교차검증에서 물리 잔차 모델은 재보정 Stefan 모델의 RMSE 를 레나 델타에서 21.0 cm 에서 17.4 cm 로 (ΔRMSE −3.6 [−7.8, −0.8] cm), 캐나다에서 30.6 cm 에서 26.9 cm 로 (−3.7 [−4.8, −0.8] cm) 낮추었고, 알래스카에서는 두 모델 모두 약 18.4 cm 였다 (−0.2 [−0.6, +0.1] cm). 이득은 잔차 학습기에 주어진 공변량에 따라 달라졌다 (그림 3c). 기후 공변량만 쓰면 잔차 모델은 알래스카 (+5.9 [−0.3, +14.2] cm) 와 캐나다 (+3.9 [−5.1, +10.3] cm) 에서 Stefan 모델을 개선하지 못하였고, 지형과 토양 공변량을 더해야 위의 이득이 나타났다. MODIS 식

생·눈 소실 시기 (2010–2024 년) 나 고해상 토양·피복 분류를 더한 효과는 레나 델타와 캐나다에서 0.5 cm 미만이었고, 알래스카에서는 고해상 분류가 작은 이득을 더하였다 (−0.8 [−1.4, −0.2] cm).

결과는 물리 모델이 학습기에 들어가는 방식에 따라 달라졌다 (보충 그림 S2). Stefan 유사라벨로 학습 자료를 증강하면 Stefan 모델을 재현하는 데 그쳤고 (레나 델타 −0.3 [−0.4, −0.1] cm), Stefan 예측을 입력 특징으로 쓰면 직접 ML 과 비슷한 결과를 보였다. 지역의 라벨을 모두 쓰면 직접 ML 의 점추정 오차는 세 지역 모두에서 물리 잔차 모델보다 낮았으나 (알래스카 17.3 cm 대 18.4 cm, 레나 델타 15.9 cm 대 17.4 cm, 캐나다 26.1 cm 대 26.9 cm), 재보정한 Stefan 모델과의 차이는 캐나다에서만 판정되었고 (−4.6 [−6.2, −0.2] cm) 지역 홀드아웃에서는 오차가 커졌다. CatBoost 대신 랜덤 포레스트, 다층 퍼셉트론, TabM, FT-Transformer 를 사용하여도 레나 델타와 캐나다에서 물리 잔차 이득의 부호는 바뀌지 않았다.

여덟 공변량의 지역 안 3 분위로 나누어 보면, 이득은 레나 델타 (23 개 3 분위 가운데 19 개에서 구간이 0 제외) 와 캐나다 (23 개 가운데 17 개) 의 대부분 조건에서 나타났고 Stefan 모델의 오차가 클수록 컸다. 3 분위 간 Stefan 오차와 이득의 상관은 레나 델타 −0.99, 캐나다 −0.79 였다 (그림 3d). 레나 델타의 가장 따뜻한 TDD 3 분위에서 이득은 −6.2 [−12.0, −0.7] cm 였으나, 알래스카에서는 어느 3 분위도 0.9 cm 를 넘게 바뀌지 않았다. 이는 잔차 학습기가 토양과 지형 때문에 실효 Stefan 계수가 지역 값에서 벗어나는 부분을 보정함을 시사한다. 이 해석과 일치하게, 잔차 모델의 평균 절대 SHAP 값 가운데 지형 변수가 레나 델타에서 50%, 토양 변수가 캐나다에서 39% 를 차지하였다 (보충 그림 S3).

표본 효율과 새 지역으로의 전이

라벨 수 실험은 라벨이 적을 때의 거동을 보여 준다 (그림 4a). 한 지역의 2010–2024 년 셀-연도에서 학습 라벨 25 개를 뽑으면, 물리 잔차 모델은 같은 라벨로 재보정한 Stefan 모델과 같거나 더 정확하였고 (알래스카 −0.9 [−1.9, +0.1], 레나 델타 −0.8 [−2.2, −0.1], 캐나다 −0.3 [−3.2, +1.7] cm), 라벨 100 개에서는 세 지역 모두에서 이득의 구간이 0 을 제외하였다 (−0.7 [−1.4, −0.0], −2.0 [−5.3, −0.3], −1.9 [−3.7, −0.3] cm). 라벨 25 개로 학습한 직접 ML 은 알래스카 (+2.8 [−0.3, +4.5] cm) 와 캐나다 (+1.2 [−1.5, +3.4] cm) 에서 Stefan 모델보다 점추정 오차가 컸다. 물리 입력 ML 과 물리 유사라벨은 전체 라벨 결과와 같은 경향을 보였다 (보충 그림 S4).

전이 실험에서는 다른 두 지역과 대상 지역 라벨 n 개로 학습한 모델로 대상 지역을 예측하였다 (그림 4b). 대상 라벨이 없을 때 레나 델타에서 직접 ML 은 39.5 cm 로, 원천 계수 Stefan 모델 (21.5 cm) 과 물리 잔차 모델 (23.8 cm) 보다 오차가 컸다. 대상 라벨 25 개를 더하면 물리 잔차 모델은 19.9 cm, 직접 ML 은 21.3 cm 로 감소하였다. 알래스카에서는 물리 잔차 모델이 모든 n 에서 가장 정확하였다 (대상 라벨 0 개에서 17.8 cm). 캐나다에서는 원천 지역으로 학습한 직접 ML 이 가장 정확하였고 (24.2 cm), 캐나다 라벨 25 개로 Stefan 계수를 재보정하면 오차가 27.7 cm 에서 31.3 cm 로 증가하였으며 이 기준값을 쓰는 물리 잔차 모델도 24.3 cm 에서 26.3 cm 로 증가하였다. 캐나다 지점들의 융해 깊이 범위가 넓기 때문이다.

같은 절차를 모델 개발에 쓰지 않은 외부 CALM 지역 8 곳의 2010–2024 년 채점 셀-연도 805 개에 적용하였다 (그림 4c, 보충 그림 S5). Wei 등, Liu 등, ESA CCI v5 값이 모두 있는 7 개 지역의 셀-연도 474 개에서, 세 연구 지역으로 학습한 물리 잔차 모델은 지역 라벨 없이 56.2 cm 였다. 같은 외부 지역의 라벨 5 개를 더하면 40.3 cm, 25 개를 더하면 39.7 cm 로 감소하였고, 직접 ML 은 라벨 25 개에서 47.5 cm 였다. 라벨

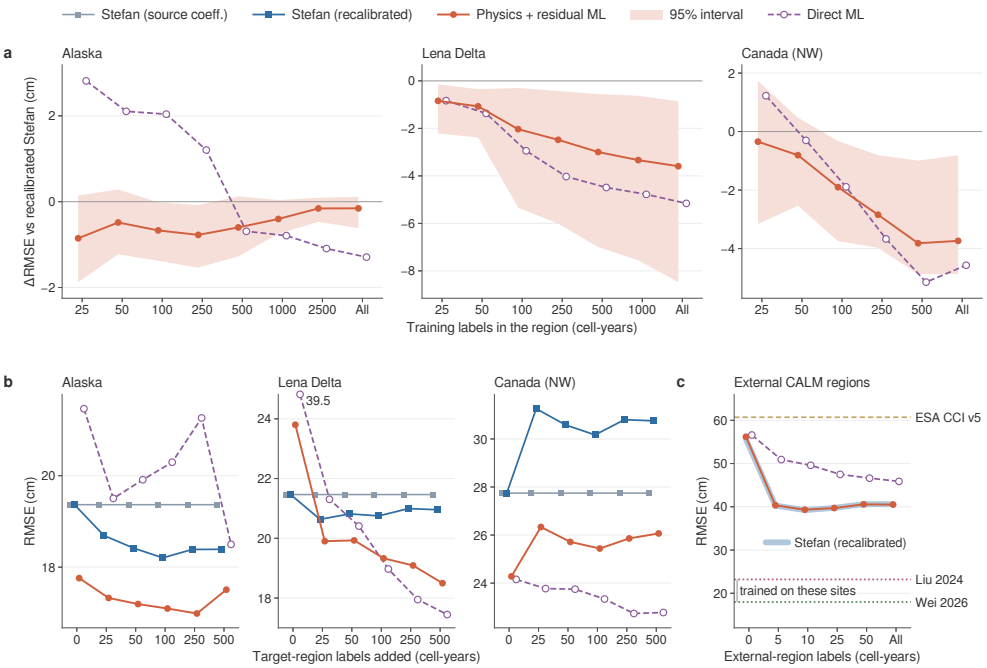


그림 4 적은 라벨과 새 지역에서의 정확도. **a**, 각 지역에서 같은 n 개 학습 라벨 (2010–2024 년 라벨, 3 회 추출) 로 재보정한 Stefan 모델 대비 각 방법의 ΔRMSE. 띠는 물리 잔차 모델의 95% 블록 부트스트랩 구간이다. **b**, 다른 두 지역과 대상 지역 라벨 n 개로 학습한 모델의 지역별 RMSE. **c**, 외부 CALM 지역 (2010–2024 년 관측) 에서 같은 외부 지역 라벨 수에 따른 RMSE. Wei 등, Liu 등, ESA CCI v5 값이 모두 있는 셀-연도 474 개 (2010–2020 년) 에서 계산하였고, 가로선은 제품이며 Wei 등과 Liu 등은 이 지점들을 학습 자료에 포함한다.

5 개에서 물리 잔차 모델은 ALT 관측으로 학습하지 않은 ESA CCI v5 보다 정확하였다 (같은 474 개 셀-연도에서 60.7 cm, ESA CCI v5 값이 있는 셀-연도 700 개 전체에서 ΔRMSE −19.5 [−31.3, −9.2] cm). 이 지점들을 학습 자료에 포함한 Wei 등과 Liu 등은 18.0 cm 와 23.2 cm 였다. 오차 감소의 대부분은 Stefan 계수의 재보정에서 나왔고, 잔차 학습기는 이 지점들에서 오차를 추가로 줄이지 못하였다 (셀-연도 805 개 전체, 라벨 5 개에서 +0.4 [−0.5, +1.2] cm). 합산 값에는 지역별로 다른 반응이 섞여 있다. 라벨 5 개에서 오차는 서시베리아, 중앙 시베리아, 유럽 러시아, 스발바르에서 줄었으나, 라벨 없이도 오차가 10 cm 미만이던 추코트카 (8.8 cm 에서 14.6 cm) 와 캄차카 (7.9 cm 에서 11.7 cm), 그리고 북동 시베리아 (32.6 cm 에서 34.8 cm) 에서는 늘었다. 서·중부 시베리아와 스발바르의 활동층이 연구 지역의 범위보다 두껍기 때문이다.

같은 셀·같은 해의 공개 제품 비교

공통 셀-연도 (2010–2020 년) 에서 물리 잔차 모델은 레나 델타에서 21.1 cm 로, ESA CCI v5(28.4 cm), Aalto 등 (30.6 cm), ESA CCI v4(31.0 cm), Liu 등 (33.0 cm), Wei 등 (34.6 cm) 보다 정확하였다 (그림 5a, 보충 표 S6). 제품 학습 지점에서 25 km 안의 셀을 제외하면 짝지은 차이는 Wei 등 대비 −12.5 [−15.6, −5.8] cm, ESA CCI v5 대비 −5.0 [−9.5, −2.5] cm 였다. 알래스카 (17.1 cm 대 Wei 등 17.9 cm, Liu 등 18.8 cm) 와 캐나다 (25.8 cm 대 27.0 cm, 27.9 cm) 에서는 모델과 두 ML 제품이 같은 수준이었다.

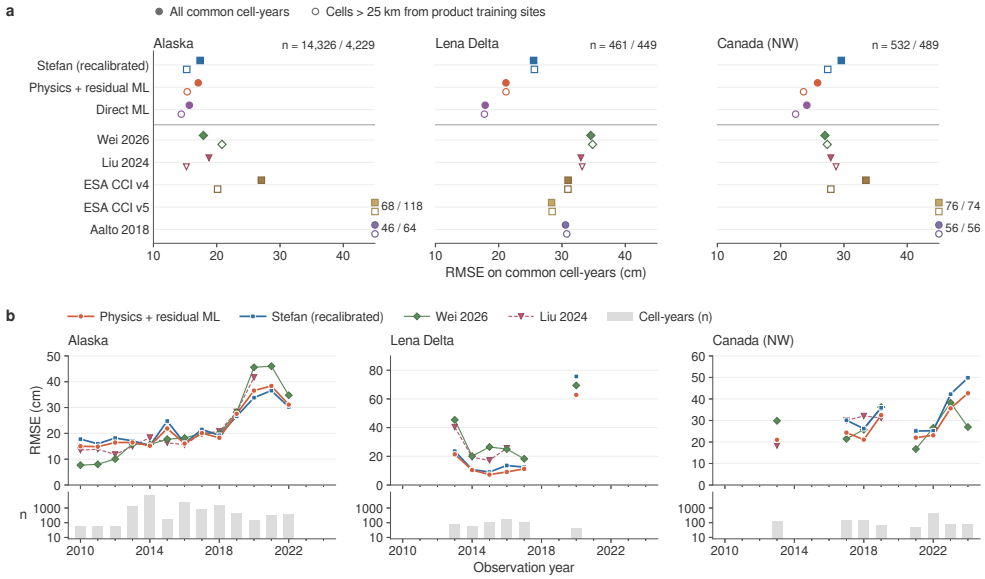


그림 5 같은 셀·같은 해의 공개 제품 비교. **a**, 공통 셀-연도 (2010–2020 년) 에서 세 방법 (공간 블록 겹 밖 예측) 과 제품 5 종의 RMSE. 모든 셀과 Wei 등 학습 지점에서 25 km 넘게 떨어진 셀을 구분하였다. ESA CCI v5 와 Aalto 등은 값이 있는 셀-연도에서 채점하였고, 축 밖 값은 숫자로 적었다. **b**, 해마다 같은 셀-연도에서 계산한 관측 연도별 RMSE. 셀-연도 30 개 이상인 해 (알래스카 2010–2022 년, 레나 델타 2013–2017 년과 2020 년, 캐나다 2013 년, 2017–2019 년과 2021–2024 년) 만 나타내었고, Liu 등은 2020 년까지이며, 막대는 해마다의 셀-연도 수이다.

이러한 지역 차이는 제품의 학습 자료와 대응한다. 알래스카 라벨 셀은 Wei 등의 학습 지점에서 중앙값 7 km 떨어져 있고 Liu 등은 같은 알래스카·캐나다 현장 자료의 이전 판으로 학습한 반면, 레나 델타 셀은 중앙값 107 km 떨어져 있다 (보충 그림 S6). 두 제품 모두 델타 북부의 얇은 활동층을 과대 추정하며, 북위 72° 이북의 평균 편향은 +21.1 cm 와 +19.9 cm 이다. 레나 델타 라벨 없이 학습한 모델도 같은 셀-연도에서 이미 Wei 등보다 정확하였으므로 (26.0 cm 대 30.3 cm, ΔRMSE −4.3 [−6.1, −0.8] cm), 이 지역의 우위는 지역 라벨에만 의존하지 않는다.

같은 해의 지도는 이 차이를 공간적으로 보여 준다 (그림 6). 2014 년 알래스카에서는 세 지도가 관측 셀에서 비슷하였다 (RMSE: 우리 모델의 겹 밖 예측 17.1 cm, Wei 등 15.8 cm, Liu 등 16.4 cm). 이 관측 셀 95 개 중 85 개는 Wei 등의 학습 지점에서 25 km 안에 있다. 지도 간 차이는 적용 가능 영역 밖인 고도 600 m 이상의 산지에서 가장 컸다. 북위 68–70° 에서 제품은 우리 지도보다 +21.9 cm(Wei 등), +55.2 cm(Liu 등) 깊었다. 관측 셀 14 개가 모두 이 학습 지점에서 25 km 보다 먼 2016 년 레나 델타에서는 두 제품이 델타 전반에서 관측보다 깊었고 (평균 편차 +23.6 cm, +27.3 cm, RMSE 26.2 cm, 30.4 cm), 우리 모델의 RMSE 는 12.7 cm 였다.

연도별로 보면 물리 잔차 모델은 셀-연도 30 개 이상인 레나 델타의 6 개 해 (2013–2017 년과 2020 년) 모두에서 Wei 등과 Stefan 모델보다 오차가 낮았고, 알래스카 (2010–2022 년) 에서는 Wei 등 대비 13 개 해 가운데 7 개 해, Stefan 모델 대비 13 개 해 가운데 9 개 해, 캐나다에서는 8 개 해 가운데 Stefan 모델 대비 7 개 해에서 낮았다 (그림 5b). 여러 해 관측된 알래스카 셀에서 관측과 예측의 연도 간 변화 상관은 물리

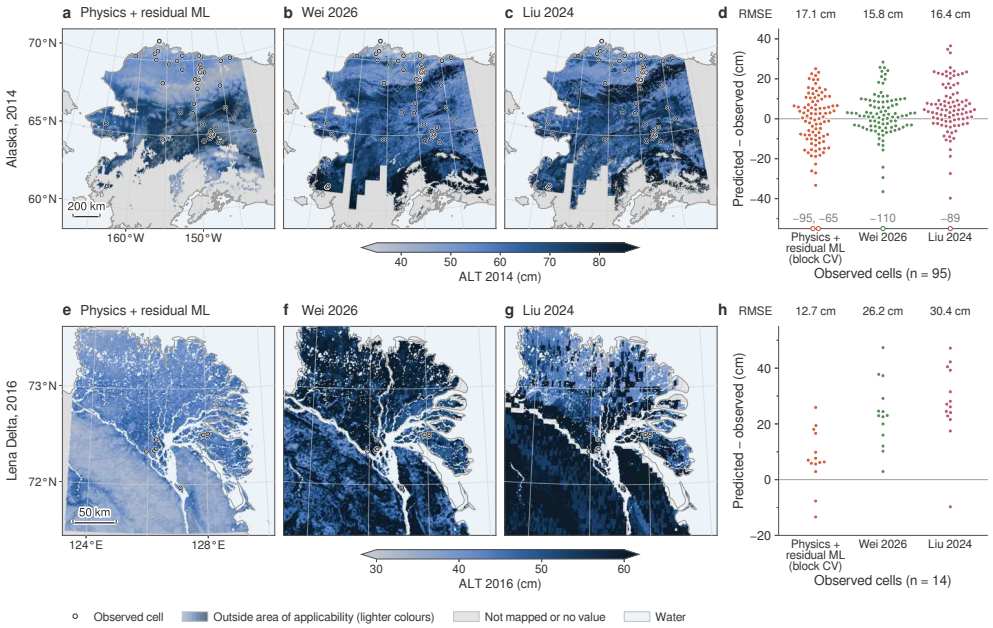


그림 6 같은 해의 물리 잔차 모델 지도와 공개 제품 지도. **a**–**c**, 2014 년 알래스카의 물리 잔차 모델, Wei 등, Liu 등 지도 (같은 색 범위). **d**, 2014 년 관측 셀 중 세 지도 모두 값이 있는 95 개 셀의 예측 빼기 관측 ALT 와 지도별 RMSE. 우리 모델의 예측은 공간 블록 겹 밖 값이다. 축 범위 밖 값은 숫자로 표기하였다. 제품 값에는 학습 지점 마스크를 적용하지 않았으며, 95 개 중 85 개 셀은 Wei 등의 학습 지점에서 25 km 안에 있다. **e**–**h**, 2016 년 레나 델타의 같은 비교 (14 개 셀, 모두 학습 지점에서 25 km 보다 멂). 지도 범위는 ESA CCI 영구동토 확률 50% 이상인 지역이며, 1 km 값을 표시용으로 250 m 에 보간하였다.

잔차 모델 0.28, Wei 등 0.15, Liu 등 0.12 였으며, 레나 델타에서는 제품이 연도 간 변화를 더 잘 따랐다 (0.55 와 0.42 대 0.29).

잔차 학습기는 제품을 기준값으로 하여 적용할 수도 있다 (식 (8)). 레나 델타 라벨로 Wei 등의 재보정 제품에 잔차 학습기를 더하면 오차가 −2.3 [−7.4, −0.4] cm 변하였고, Stefan 기준 모델은 제품 기준 모델보다 여전히 정확하였다 (−2.8 [−6.2, −0.1] cm, 보충 그림 S7). 알래스카와 캐나다에서는 두 기준값의 차이가 구분되지 않았다.

연도가 명시된 1 km ALT 지도 (2011–2024 년)

알래스카와 레나 델타의 모든 셀-연도로 학습한 물리 잔차 모델을 2011–2024 년 각 해의 ERA5-Land 기후로 적용하였다 (그림 7). 지도는 알래스카 858,517 개, 레나 델타 38,086 개 셀이다. 2011–2024 년 평균 대비 지역 평균 편차는 알래스카에서 2012 년 −3.2 cm 부터 2019 년 +7.1 cm 까지, 레나 델타에서 2017 년 −9.4 cm 부터 2020 년 +10.0 cm 까지였으며, 공간 분포도 해마다 달랐다 (그림 7b). 레나 델타에서 관측 셀의 평균 편차는 셀-연도 50 개 이상인 10 개 해 (2012–2021 년) 가운데 8 개 해에서 예측 지역 편차와 부호가 같았다 ($r = 0.75$). 관측 편차가 +46.9 cm(셀-연도 143 개) 에 이른 2020 년을 빼도 상관은 0.72 였다. 해마다 관측 셀 구성이 바뀌는 알래스카에서는 일치가 약하였고 ($r = 0.25$), 예측의 연도 간 범위 (10.2 cm) 는 관측 셀 평균의 범위 (17.7 cm) 보다 작았다 (그림 7c). 적용 가능 영역은 알래스카 셀의 56%, 레나 델타 셀의 62% 를 포함하며, 영역 밖의 셀은 주로 산지와 영구동토 지대의 남쪽 가장자리에 있다 (보

충 그림 S8). 90% 예측 구간의 반폭은 25.5 cm 와 24.5 cm 이다. 잔차 학습기가 더하는 보정량은 대부분 ±10 cm 안에 있고 (보충 그림 S9), 장기 관측 셀의 시계열은 보충 그림 S10 에 나타내었다.

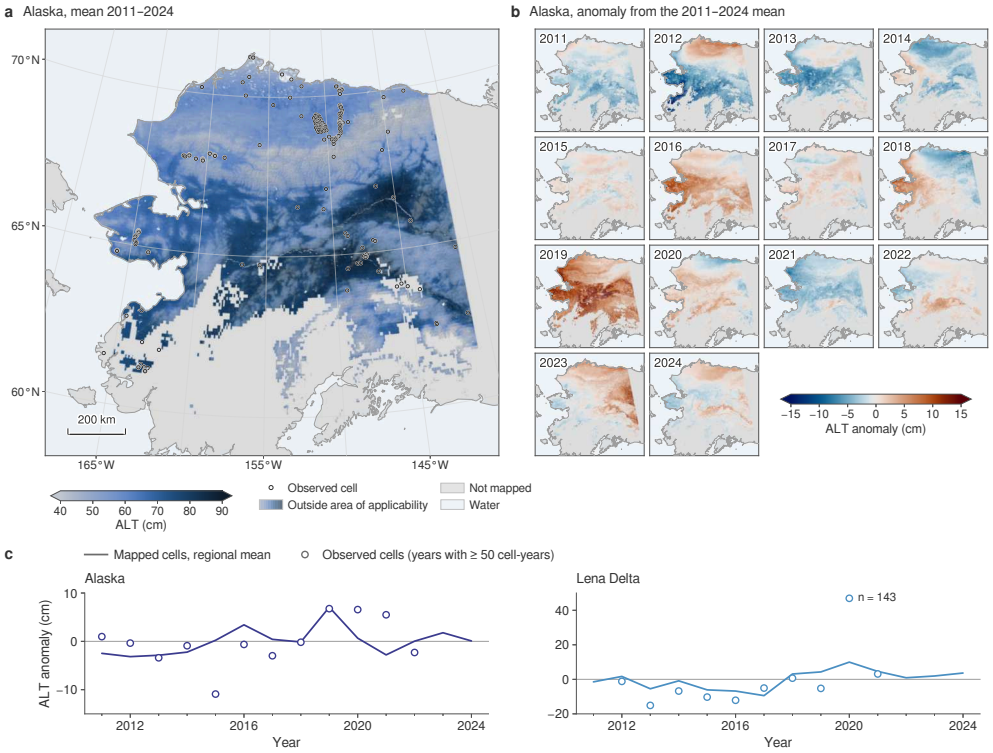


그림 7 연도가 명시된 1 km ALT 지도 (2011–2024 년). a, 연도별 지도로 계산한 알래스카 물리 잔차 모델의 2011–2024 년 평균 ALT. 각 연도 지도는 그 해의 계절 전체 ERA5-Land 기후를 사용하며, 옅은 색은 적용 가능 영역 밖, 회색 육지는 지도 범위 밖이다. **b**, 2011–2024 년 평균 대비 각 해의 ALT 편차 (모든 해 같은 색 범위 ±15 cm). **c**, 예측 지도의 지역 평균 편차와 셀-연도 50 개 이상인 해의 관측 셀 평균 편차 (알래스카 2011–2022 년, 레나 델타 2012–2021 년). 관측 편차는 각 관측 셀의 2011–2024 년 지도 평균을 기준으로 계산하고 같은 해들의 예측 편차 평균에 중심을 맞추었으며, 레나 델타 2020 년 값에는 셀-연도 수를 표기하였다. 1 km 값은 표시용으로 250 m 에 보간하였다.

고찰

물리 기준값과 전이성

결과는 물리 지식이 모델에 들어가는 방식이 ML 이 지역 Stefan 모델을 넘어서는지, 그 개선이 새 지역으로 전이되는지를 결정함을 보여 준다. 물리 잔차 구성 (식 (5)) 에서 Stefan 항은 해마다의 융해기 기후에 대한 반응을 맡아 물리적으로 제한된 형태로 새 지역과 새 해에 외삽되고, 학습기는 토양과 지형에 따른 실효 계수의 편차를 보정한다. 이 역할 분담을 뒷받침하는 결과는 네 가지이다. 이득에는 지형과 토양 공변량이 필요하였고, Stefan 오차가 가장 큰 조건에서 가장 컸으며, 잔차 학습기의 기여 분석은

레나 델타에서 지형, 캐나다에서 토양 유기탄소를 가리켰고, Stefan 유사라벨은 학습기를 Stefan 모델 쪽으로 끌어당겨 정확도를 높이지 못하였다. 기후 반응을 라벨에서 직접 배워야 하는 직접 ML 은 한 지역의 라벨을 모두 쓸 때 물리 잔차 모델보다 점추정 오차가 낮았으나, 레나 델타를 학습에서 제외하면 오차가 Stefan 모델보다 17.8 cm 컸다. 이 대비는 과정 지식이 주로 자료가 부족하거나 외삽이 필요할 때 성능을 높인다는 호소학·수문학의 물리 기반 학습 연구와 일치한다[20–22]. 대부분의 영구동토 지역에는 ALT 관측이 적거나 없으므로, 지도 작성에는 관측이 많은 지역에서 라벨을 모두 쓴 정확도보다 대상 지역 라벨 없이 유지되는 정확도가 더 중요하다.

선행 연구와의 비교

기존 ALT 지도 연구는 기후 입력, 검증 설계, 비교 기준에서 이 연구와 다르다. ML 제품은 여러 해에 걸쳐 모은 관측을 다년 예측 변수와 연결하고, 각자의 지점 집합에서 무작위 또는 지점 단위 교차검증 결과를 보고한다[11–13]. 이 연구의 자료에서 무작위 교차검증은 직접 ML 의 공간 블록 오차를 3.6–9.9 cm 과소 추정하였고, 레나 델타를 학습에서 제외하면 직접 ML 의 오차는 39.3 cm 로 커져 다른 지역 계수를 쓴 Stefan 모델 (21.5 cm) 보다 컸다. 따라서 무작위 또는 지점 단위 분할에서 얻은 오차는 학습 관측이 없는 지역에서 ML 제품의 정확도를 나타내지 않는다. Gautam 등[23] 은 2014 년에 관측한 알래스카 CALM 68 개 지점에서 랜덤 포레스트와 Stefan 모델을 비교하였고, 무작위 검정 분할에서 랜덤 포레스트의 결정계수는 학습 0.84 에서 검정 0.24 로 떨어진 반면 Stefan 모델은 0.54 를 유지하였다. 이 연구는 이 비교를 세 지역의 2010–2024 년 셀-연도와 지역 홀드아웃으로 확장하고, 학습기가 Stefan 모델을 대체하지 않고 보정하도록 두 접근을 결합하였다. ESA CCI Permafrost 같은 과정 기반 제품은 ALT 관측으로 학습하지 않으며[8,9], 외부 CALM 지점에서 ESA CCI v5 의 오차 (60.7 cm) 는 지역 라벨 5 개를 쓴 우리 모델의 오차 (40.3 cm) 보다 컸다.

모든 모델과 제품을 같은 셀·같은 해에서 제품 학습 지점 마스크와 함께 채점하면 이러한 차이를 비교할 수 있다. 제품의 지역별 순위는 제품의 학습 자료를 따랐다. 제품이 인근 관측으로 학습한 지역 (알래스카, 캐나다) 에서는 제품이 우리 모델만큼 정확하였고, 그렇지 않은 지역 (레나 델타) 에서는 얇은 활동층을 과대 추정하여 레나 델타 라벨 없이 학습한 모델보다도 덜 정확하였다. 잔차 학습기는 제품을 기준값으로 쓸 때에도 정확도를 높였으므로 (식 (8)), 지역 라벨과 잔차 학습을 결합하면 물리 모델뿐 아니라 기존 제품도 그 제품이 학습하지 않은 지역에 맞게 보정할 수 있다. 같은 셀·같은 해 비교 절차와 학습 지점 마스크는 다른 제품과 지역에도 적용할 수 있다.

새 지역·새 연도 적용 절차

라벨 수 실험 결과는 새 지역에 방법을 적용하는 순서로 정리된다. 지역 라벨이 없을 때는 다른 지역 계수를 쓴 Stefan 모델이나 다른 지역으로 학습한 물리 잔차 모델이 직접 ML 보다 안전한 출발점이다. 직접 ML 의 레나 델타 오차는 대상 지역 라벨 없이 39.5 cm 였다. 레나 델타 라벨 25 개는 물리 잔차 모델의 오차를 23.8 cm 에서 19.9 cm 로 줄여 원천 계수 Stefan 모델 (21.5 cm) 보다 낮추었고, 외부 CALM 지역에서는 라벨 5 개로 오차가 56.2 cm 에서 40.3 cm 로 감소하였다. 이는 수문학의 지역화 연구에서 보고된 소수 지역 관측의 가치와 일치한다[38]. 필요한 라벨 수는 새 지역이 학습 범위에서 얼마나 떨어져 있는지에 따라 달라진다. 융해 깊이 범위가 넓은 캐나다에서는 라벨 25 개로 재보정하면 오차가 증가하였으므로, 지역의 토양과 지형 범위를 포괄하는 라벨 25–100 개가 적절한 목표이다. 각 지도는 명시된 해의 ERA5-Land 기후로 계

산되고 적용 가능 영역과 예측 구간을 함께 제공하므로, 같은 워크플로로 감시용 연도별 지도를 만들고, 같은 해의 관측이나 제품과 비교하며, 추가 관측이 필요한 적용 가능 영역 밖의 지역을 표시할 수 있다.

한계와 향후 과제

알래스카 라벨의 절반이 2014 년 자료여서 이 지역에서는 관측 연도 입력의 효과를 판정하지 못하였다. 레나 델타 라벨은 한 자료원의 16 개 블록에서 나와 신뢰 구간이 넓다. 기후 입력은 월자료이고 토양 공변량은 정적이어서 단기 기상과 토양 수분 변화는 반영되지 않는다. 주로 산지와 영구동토 지대의 남쪽 가장자리에 있는 약 3 m 보다 두꺼운 활동층은 학습 범위 밖이며, 외부 시험은 잔차 학습기가 지역 라벨 없이는 이러한 조건으로 전이되지 않음을 보여 준다. 일 단위 기후 입력, 적설·토양 수분 정보, CALM 과 집중 조사 자료가 함께 있는 서시베리아 같은 네 번째 지역의 라벨이 다음 과제이다.

결론

이 연구는 라벨, 기후 입력, 채점이 같은 1 km 셀과 같은 해를 가리키는 셀-연도 설계로 활동층 두께 모델을 평가하였다. 기후 입력을 관측 연도와 맞추면 관측이 여러 해에 분포한 지역에서 공간 블록 오차가 감소하고, 모든 예측이 명시된 해에 대응한다. 지역 라벨로 재보정한 Stefan 모델에 gradient boosting 잔차 모델을 더한 물리 잔차 모델은 Stefan 모델의 오차를 레나 델타에서 3.6 cm, 캐나다에서 3.7 cm 줄였고, 학습에서 제외한 지역에서도 Stefan 모델 수준을 유지하였으며, 레나 델타와 외부 CALM 지역에서 지역 라벨 5–25 개로 오차를 줄였다. 직접 ML 은 라벨을 모두 쓴 지역 안 검증에서는 점추정 오차가 더 낮았으나, 레나 델타 라벨 없이 학습하면 그 지역에서 오차가 Stefan 모델보다 18.0 cm 컸다. 같은 셀·같은 해에서 이 모델은 제품이 학습하지 않은 지역에서 공개 제품 5 종보다 정확하였고, 제품이 인근 관측으로 학습한 지역에서는 Wei 등·Liu 등과 같은 수준이었다. 따라서 Stefan 모델을 기준으로 두고 잔차만 학습하는 구조는 대상 지역 라벨이 적거나 없을 때 가장 유용하며, 이는 영구동토 지역의 일반적인 관측 조건이다. 이 워크플로는 적용 가능 영역과 예측 구간을 갖춘 연도별 1 km ALT 지도와, 다른 영구동토 지역에서 ALT 모델과 제품을 평가하고 보정하는 절차를 제공한다.

자료 가용성. 모든 입력 자료는 공개 자료이다. ALT 관측: ABoVE 토양 수분·활동층 두께 v2(ORNL DAAC, https://doi.org/10.3334/ORNLDAAC/2369), ALLena 융해 깊이 자료 (PANGAEA, https://doi.org/10.1594/PANGAEA.973813), GTN-P CALM(PANGAEA, https://doi.org/10.1594/PANGAEA.972777). 기후: ERA5-Land 월평균 (Copernicus Climate Data Store). 공변량: Copernicus DEM GLO-30, SoilGrids 2.0, ESA CCI 영구동토 확률, MODIS MOD13Q1 ·MOD10A2 v6.1(AppEEARS). 제품: Wei 등 (https://doi.org/10.5281/zenodo.21667583), Liu 등 (https://doi.org/10.5281/zenodo.10070610), ESA CCI ALT v4 ·v5(CEDA), Aalto 등 (https://zenodo.org/records/5003804), Yi 와 Kimball(https://doi.org/10.3334/ORNLDAAC/1760). 셀-연도 라벨 표, 연도별 기후 입력 표, 정적 공변량 표, 모든 방법의 겹 밖 예측, 알래스카·레나 델타의 연도별 1 km 지도 (2011–2024 년) 는 게재 시 공개 저장소에 둔다 [저장소·DOI].

참고문헌

[1] Hjort, J. *et al.* Degrading permafrost puts Arctic infrastructure at risk by mid-century. *Nature Communications* **9**, 5147 (2018).

[2] Schuur, E. A. G., McGuire, A. D., Schädel, C. *et al.* Climate change and the permafrost carbon feedback. *Nature* **520**, 171–179 (2015).

[3] Biskaborn, B. K. *et al.* Permafrost is warming at a global scale. *Nat. Commun.* **10**, 264 (2019).

[4] Nelson, F. E. *et al.* Estimating active-layer thickness over a large region: Kuparuk River basin, Alaska, U.S.A. *Arct. Alp. Res.* **29**, 367–378 (1997).

[5] Streletskiy, D. A. *et al.* GTN-P CALM: 35 years of Active Layer Thickness (ALT) across latitudinal and elevational gradients in the Northern Hemisphere. PANGAEA (2025). URL https://doi.org/10.1594/PANGAEA.972777.

[6] Moore, M. A. *et al.* ABoVE: Soil moisture and active layer thickness in Alaska, USA and Canada, 2005–2024, version 2. ORNL Distributed Active Archive Center (2025). URL https://doi.org/10.3334/ORNLDAAC/2369.

[7] Veremeeva, A. *et al.* ALLena: Thaw depth measurements of the active layer in the Lena River Delta region from 1998 to 2022, Northeastern Siberia. PANGAEA (2025). URL https://doi.org/10.1594/PANGAEA.973813.

[8] Westermann, S. *et al.* ESA Permafrost Climate Change Initiative (Permafrost_cci): Permafrost active layer thickness for the Northern Hemisphere, v4.0. NERC EDS Centre for Environmental Data Analysis (2024). URL https://doi.org/10.5285/d34330ce3f604e368c06d76de1987ce5.

[9] Westermann, S. *et al.* ESA Permafrost Climate Change Initiative (Permafrost_cci): Permafrost active layer thickness for the Northern Hemisphere, v5.0. NERC EDS Centre for Environmental Data Analysis (2025).

[10] Aalto, J., Karjalainen, O., Hjort, J. & Luoto, M. Statistical forecasting of current and future circum-Arctic ground temperatures and active layer thickness. *Geophys. Res. Lett.* **45**, 4889–4898 (2018).

[11] Ran, Y. *et al.* New high-resolution estimates of the permafrost thermal state and hydrothermal conditions over the Northern Hemisphere. *Earth Syst. Sci. Data* **14**, 865–884 (2022).

[12] Liu, Y. *et al.* A 1 km annual active layer thickness dataset for the Northern Hemisphere permafrost region, 2003–2020. *Environmental Research Letters* **19** (2024). Fields to verify before submission.

[13] Wei, Y., Wu, Z., Wang, J. *et al.* A 1 km resolution dataset of Northern Hemisphere permafrost active layer thickness (2000–2024). *Earth System Science Data Discussions* (2026).

[14] Roberts, D. R. *et al.* Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography* **40**, 913–929 (2017).

[15] Ploton, P. *et al.* Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nat. Commun.* **11**, 4540 (2020).

[16] Meyer, H. & Pebesma, E. Machine learning-based global maps of ecological variables and the challenge of assessing them. *Nature Communications* **13**, 2208 (2022).

[17] Wadoux, A. M. J.-C., Heuvelink, G. B. M., de Bruin, S. & Brus, D. J. Spatial cross-validation is not the right way to evaluate map accuracy. *Ecol. Model.* **457**, 109692 (2021).

[18] Stefan, J. Über die Theorie der Eisbildung, insbesondere über die Eisbildung im Polarmeere. *Annalen der Physik* **278**, 269–286 (1891).

[19] Riseborough, D., Shiklomanov, N., Etzelmüller, B., Gruber, S. & Marchenko, S. Recent advances in permafrost modelling. *Permafrost and Periglacial Processes* **19**, 137–156 (2008).

[20] Willard, J., Jia, X., Xu, S., Steinbach, M. & Kumar, V. Integrating scientific knowledge with machine learning for engineering and environmental systems. *ACM Comput. Surv.* **55**, 66 (2022).

[21] Read, J. S. *et al.* Process-guided deep learning predictions of lake water temperature. *Water Resour. Res.* **55**, 9173–9190 (2019).

[22] Jia, X. *et al.* Physics-guided machine learning for scientific discovery: an application in simulating lake temperature profiles. *ACM/IMS Trans. Data Sci.* **2**, 20 (2021).

[23] Gautam, S., Mishra, U., Scott, S. N. & Lara, M. J. Machine learning and process-based modeling of spatiotemporal changes in active layer thickness across Alaska. *Sci. Rep.* **15**, 42420 (2025).

[24] Muñoz-Sabater, J. *et al.* ERA5-Land: a state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data* **13**, 4349–4383 (2021).

[25] European Space Agency. Copernicus global digital elevation model (GLO-30). Distributed by OpenTopography (2021).

[26] Poggio, L. *et al.* SoilGrids 2.0: producing soil information for the globe with quantified spatial uncertainty. *SOIL* **7**, 217–240 (2021).

[27] Didan, K. MODIS/Terra vegetation indices 16-day L3 global 250m SIN grid V061. NASA EOSDIS Land Processes DAAC (2021).

[28] Hall, D. K. & Riggs, G. A. MODIS/Terra snow cover 8-day L3 global 500m SIN grid, version 61. NASA National Snow and Ice Data Center DAAC (2021).

[29] Yi, Y. & Kimball, J. S. ABoVE: Active layer thickness from remote sensing permafrost model, Alaska, 2001–2015. ORNL DAAC, Oak Ridge, Tennessee, USA (2019).

[30] Palmtag, J. *et al.* Detailed pedon data on soil carbon and nitrogen for the northern permafrost region, version 1. Bolin Centre Database (2022). URL https://doi.org/10.17043/palmtag-2022-pedon-1.

[31] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. & Gulin, A. CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems* **31**, 6639–6649 (2018).

[32] Kudryavtsev, V. A., Garagula, L. S., Kondrat'yeva, K. A. & Melamed, V. G. *Osnovy Merzlotnogo Prognoza [Fundamentals of Frost Forecasting in Geological Engineering Investigations]* (Moscow State University, 1974). In Russian. English translation: CRREL Draft Translation 606, US Army Cold Regions Research and Engineering Laboratory, Hanover, NH, 1977.

[33] Gorishniy, Y., Rubachev, I., Khrulkov, V. & Babenko, A. Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems* **34**, 18932–18943 (2021).

[34] Gorishniy, Y., Kotelnikov, A. & Babenko, A. TabM: advancing tabular deep learning with parameter-efficient ensembling. *International Conference on Learning Representations* (2025).

[35] Holzmüller, D., Grinsztajn, L. & Steinwart, I. Better by default: strong pre-tuned MLPs and boosted trees on tabular data. *Advances in Neural Information Processing Systems* **37** (2024).

[36] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*, Vol. 30, 4765–4774 (2017).

[37] Meyer, H. & Pebesma, E. Predicting into unknown space? Estimating the area of applicability of spatial prediction models. *Methods in Ecology and Evolution* **12**, 1620–1633 (2021).

[38] Pool, S., Viviroli, D. & Seibert, J. Value of a limited number of discharge observations for improving regionalization: a large-sample study across the United States. *Water Resour. Res.* **55**, 363–377 (2019).

감사의 글. [연구비·감사의 글.]

저자 기여. 백승원은 연구를 설계하고 자료를 구축하였으며 분석을 수행하고 원고를 작성하였다. [공저자 기여.]

추가 정보. **보충 자료** 보충 방법 S1–S5, 보충 표 S1–S6, 보충 그림 S1–S10 을 함께 제공한다.

이해 상충 저자들은 이해 상충이 없음을 밝힌다.